Claus Unterberg

Kognitive und strukturelle Transformation durch Künstliche Intelligenz

Eine vergleichende Analyse
der Auswirkungen auf
Lernprozesse und Berufsfelder
in Deutschland 2025
mit einem Fokus
auf die Bildung.

Januar 2026

Inhalt

Vorwort 5
Teil I: Theoretische Fundierung und struktureller Kontext 9
1. Makroökonomischer und demografischer Rahmen 9
1.1 Demografischer Wandel und Fachkräftemangel 9
1.2 Produktivitätsstagnation und ökonomischer Druck 11
2. Sektorspezifische Ausgangssituationen 13
2.1 Bildungssektor: Zwischen Überforderung und Innovationsdruck 13
2.2 Logistiksektor: Technologischer Wandel als komparative Perspektive 15
Teil II: Kognitive Metamorphose – KI in Lernprozessen 18
3. Theoretische Rahmenkonzepte 18
3.1 Task-Based Approach und die Zukunft der Arbeit 18
3.2 Das Moravec'sche Paradoxon: Kognition versus Motorik 21
3.3 Desirable Difficulties und kognitive Architektur 25
3.4 Von prozeduraler zu konstruktiver KI-Nutzung 29
Teil III: Empirische Evidenz und Bildungsgerechtigkeit 33
4. Empirische Evidenz: Der 'Krücken-Effekt' und die Ambivalenz der Assistenz ... 33
4.1 Die PNAS-Studie von Bastani et al.:
Methodisches Design und zentrale Befunde 33
4.2 Kognitive Verflachung in verbalen Domänen: Die Georgiou-Studie 37
4.3 Transfer-Problematik in der Informatikausbildung: Die Vivian-Studie 40
Persönliche Anmerkung: Die Prüfungsfrage als blinder Fleck 42
5. Der Mythos des 'Equalizers': Bildungsungerechtigkeit im neuen Gewand 45
5.1 Notenverzerrung ohne Kompetenzgewinn:
Die Statistik-Fallstudie von Dunn 45
5.2 Der Matthäus-Effekt: Wer hat, dem wird gegeben 47
Teil IV: Methodische Reflexion und Plattform-Realitäten 49
6. Plattform-Analyse und Intelligent Tutoring Systems 49
6.1 Khanmigo versus konventionelle Informationssuche:
Die Slijepcevic-Studie 49
6.2 Die Evidenzkrise der EdTech-Forschung 51
7. Methodische Limitationen und Forschungsethik 53
7.1 Die Krise der Messbarkeit 53

7.2 Stichprobenproblematik und Generalisierbarkeit 54
7.3 Ethische Dimensionen der KI-Forschung im Bildungskontext 55
Teil V: Synthese und komparative Analyse 56
8. Komparative Synthese: Pädagogik versus Logistik 56
8.1 Augmentation versus Substitution: Zwei Pfade der Automatisierung 56
8.2 Das Paradoxon der Komplexität: Empathie versus Physik 58
8.3 Regulatorische Asymmetrie: Föderal versus zentral 60
8.4 Geschwindigkeit der Disruption: Inkrementell versus disruptiv 62
8.5 Qualifikatorische Polarisierung und der Matthäus-Effekt 64
8.6 Tabellarische Gegenüberstellung der Transformationsdimensionen 65
Teil VI: Implikationen und Handlungsempfehlungen 67
9. Handlungsempfehlungen für den Bildungssektor 67
9.1 Pädagogische Guardrails als Standardanforderung 67
9.2 Curriculum für KI-Literalität:
Von Prompting zu epistemischer Kompetenz 69
9.3 Prüfungsformate transformieren: Von Produkt zu Prozess 70
9.4 KI-Kompetenz als Schlüsselqualifikation:
Von der Bedrohung zum Bildungsziel 71
9.5 Lehrkräftebildung und professionelle Entwicklung 73
9.6 Regulatorische Kohärenz und Datenschutz 74
10. Handlungsempfehlungen für den Logistiksektor 75
10.1 Sozialverträgliche Gestaltung der Automatisierung 75
10.2 Qualifizierungsoffensive für Beschäftigte 76
10.3 Regulierung und Sicherheitsstandards 77
11. Übergreifende Empfehlungen: Forschung,
Governance und gesellschaftlicher Dialog 78
11.1 Unabhängige Evaluationsinfrastruktur 78
11.2 Partizipative Governance und demokratische Deliberation 79
11.3 Langfristige Forschungsagenda 80
12. Schlussbemerkung: Zwischen Notwendigkeit und Gestaltbarkeit 81
Literaturverzeichnis 83

Vorwort

Die vorliegende Untersuchung entstand aus der Beobachtung einer paradoxen Situation: Während künstliche Intelligenz in nahezu allen Bereichen des gesellschaftlichen Lebens als transformative Kraft diskutiert wird, fehlt es an systematischen, evidenzbasierten Analysen, die über technikdeterministische Prognosen oder kulturpessimistische Abwehrreflexe hinausgehen. Zwischen den Extremen unkritischer Technologieeuphorie und reflexhafter Ablehnung bleibt ein Raum für differenzierte Auseinandersetzung – ein Raum, den diese Arbeit zu füllen versucht.

Im Zentrum steht die Frage, wie generative KI-Systeme menschliche Lern- und Arbeitsprozesse verändern. Diese Frage wird nicht abstrakt-theoretisch, sondern anhand konkreter empirischer Evidenz untersucht. Die methodische Entscheidung, den Fokus auf den Bildungssektor zu legen, ist begründet in der besonderen Dringlichkeit: Schüler und Studierende nutzen bereits heute massenhaft Systeme wie ChatGPT, oft ohne pädagogische Anleitung, während Schulen und Hochschulen noch nach angemessenen Antworten suchen. Die komparative Perspektive zur Logistikbranche erlaubt es, fundamentale Muster technologischer Transformation zu identifizieren, die über Einzelbranchen hinausweisen.

Die Arbeit gliedert sich in sechs Teile, die aufeinander aufbauen, aber auch eigenständig lesbar sind. Teil I legt die theoretische Fundierung: Wir analysieren die makroökonomischen und demografischen Rahmenbedingungen, die den Einsatz von KI nicht als beliebige Option, sondern als strukturelle Notwendigkeit erscheinen lassen. Der Fachkräftemangel, die alternde Gesellschaft, die Produktivitätsstagnation – diese Faktoren schaffen einen enormen Druck auf Bildungs- und Arbeitssysteme, der technologische Lösungen attraktiv macht.

Teil II wendet sich den kognitiven Prozessen zu. Hier werden die theoretischen Rahmenkonzepte eingeführt, die für das Verständnis der KI-Transformation zentral sind: der Task-Based Approach, der Arbeit als Bündel automatisierbarer und nicht-automatisierbarer Tätigkeiten konzipiert; das Moravec'sche Paradoxon, das erklärt, warum KI bei manchen Aufgaben brilliert und bei anderen scheitert; das Konzept der Desirable Difficulties, das zeigt, warum Lernen anstrengend sein muss; und die Unterscheidung zwischen prozeduraler und konstruktiver KI-Nutzung, die determiniert, ob Technologie Kompetenz aufbaut oder untergräbt.

Teil III präsentiert die empirische Evidenz aus mehreren methodisch robusten Studien der Jahre 2024 und 2025. Die Befunde sind ernüchternd: Unreglementierte KI-Nutzung schadet dem Lernen messbar, führt zu kognitiver Atrophie und verschärft bestehende Bildungsungleichheiten. Der "Krücken-Effekt", den Bastani et al. dokumentierten, das "Lazy Thinking", das Georgiou beschrieb, die Transfer-Problematik, die Vivian aufdeckte – all diese Phänomene verweisen auf eine gemeinsame Gefahr:

dass KI nicht als Werkzeug zur Augmentation, sondern als Substitut für eigenes Denken genutzt wird. Gleichzeitig zeigt die Analyse auch, unter welchen Bedingungen produktive Nutzung möglich ist: mit pädagogischen Guardrails, mit expliziter Förderung metakognitiver Kompetenzen, mit Prüfungsformaten, die echtes Verständnis statt bloßer Reproduktion messen.

Teil IV wendet sich den methodischen und strukturellen Rahmenbedingungen zu. Wir analysieren kommerzielle KI-Tutorsysteme wie Khanmigo und zeigen, dass die Versprechen der EdTech-Industrie empirisch oft nicht haltbar sind. Die Evidenzkrise der Branche – industriefinanzierte Studien mit strukturellen Interessenkonflikten, Publication Bias, methodische Schwächen – wird offengelegt. Gleichzeitig reflektieren wir die Limitationen auch der unabhängigen Forschung: kleine Stichproben, kurze Zeiträume, Messprobleme, ethische Dilemmata. Diese methodische Reflexion ist notwendig, um die Aussagekraft der Befunde angemessen einzuordnen.

Teil V entwickelt die komparative Synthese. Durch die systematische Gegenüberstellung von Bildungssektor und Logistikbranche werden fundamentale Unterschiede sichtbar: Augmentation versus Substitution als Transformationslogik, sozial-emotionale versus sensomotorische Komplexität als Schutz vor Automatisierung, föderale versus zentrale Regulierung, inkrementelle versus disruptive Transformation. Die tabellarische Verdichtung zeigt: Trotz aller Unterschiede teilen beide Sektoren die Herausforderung, menschliche Arbeit neu zu definieren, wenn Maschinen zunehmend Tätigkeiten übernehmen können, die bisher als genuin menschlich galten.

Teil VI überführt die Analyse in konkrete Handlungsempfehlungen. Für den Bildungssektor werden pädagogische Guardrails als Standardanforderung definiert, ein Curriculum für KI-Literalität skizziert, die Transformation von Prüfungsformaten gefordert und die Notwendigkeit massiver Investitionen in Lehrkräftebildung begründet. Für den Logistiksektor werden Strategien sozialverträglicher Automatisierung entwickelt, Qualifizierungsoffensiven konzipiert und regulatorische Standards diskutiert. Übergreifend wird die Notwendigkeit unabhängiger Evaluationsinfrastrukturen, partizipativer Governance und langfristiger Forschungsagenden begründet.

Diese Arbeit versteht sich als Beitrag zu einer dringend notwendigen gesellschaftlichen Debatte. Die Transformation durch KI vollzieht sich bereits, während wir über sie nachdenken. Das Zeitfenster für proaktive Gestaltung ist begrenzt. Die zentrale These lautet: Technologie ist weder unvermeidbar gut noch unvermeidbar schlecht – sie ist ambivalent, kontingent und gestaltbar. Der Unterschied zwischen einer Dystopie kognitiver Atrophie und Massenarbeitslosigkeit einerseits und einer Zukunft, in der KI menschliche Kapazitäten erweitert, liegt nicht primär in der Technologie selbst, sondern in den sozialen, politischen und pädagogischen Entscheidungen, die wir treffen.

Als Physik- und Chemielehrer und Fortbildner für Lehrerinnen und Lehrer im Bereich künstlicher Intelligenz bin ich täglich mit diesen Fragen konfrontiert. Wenn Schüler

ihre Hausaufgaben mit ChatGPT erledigen, wenn Kolleginnen und Kollegen in Fortbildungen zwischen Begeisterung und Skepsis schwanken, wenn Schulverwaltungen nach Richtlinien suchen – dann sind dies keine abstrakten Szenarien, sondern meine konkrete Berufsrealität. Diese persönliche Betroffenheit motivierte die Untersuchung, durfte aber nicht ihre methodische Strenge kompromittieren. Die Analyse folgt den Prinzipien evidenzbasierter Forschung: Sie wertet systematisch empirische Studien aus, identifiziert methodische Limitationen, prüft konkurrierende Erklärungen und vermeidet vorschnelle Verallgemeinerungen.

Dass diese Arbeit teilweise selbst mit Unterstützung von KI-Systemen entstand, ist kein Widerspruch, sondern eine bewusste methodische Entscheidung. Die Technologie, deren Implikationen wir untersuchen, als Werkzeug der Untersuchung selbst zu nutzen, erlaubt eine Form der reflexiven Praxis. Konkret kamen verschiedene Systeme für unterschiedliche Aufgaben zum Einsatz: Googles Gemini für initiale Recherchen und Qualitätskontrolle von Fakten, Anthropics Claude für Formulierungshilfen und die Strukturierung komplexer Argumentationen, OpenAIs ChatGPT für die Generierung von Bildern – häufig auf Basis von Prompts, die zuvor mit Claude entwickelt wurden. Diese arbeitsteilige Nutzung mehrerer KI-Systeme entspricht dem, was in Teil III als „konstruktive Nutzung" beschrieben wurde: Die KI fungiert nicht als Black Box, die fertige Produkte liefert, sondern als dialogisches Werkzeug, bei dem der Autor die epistemische Autorität behält.

Ich erfahre so am eigenen Leib, wo KI produktiv unterstützt – bei der Literaturrecherche, beim Aufdecken blinder Flecken, bei der effizienten Bearbeitung von Routineaufgaben – und wo sie an Grenzen stößt: bei der kritischen Bewertung widersprüchlicher Evidenz, bei der Entwicklung originärer theoretischer Synthesen, bei der ethischen Urteilsbildung. Diese Erfahrung fließt in die Analyse ein, ohne dass ich behaupten würde, damit einen Königsweg gefunden zu haben. Die Frage, wie man produktiv mit KI arbeitet, ohne epistemisch abhängig zu werden, bleibt eine offene – eine Frage, die jede Leserin und jeder Leser für sich beantworten muss.

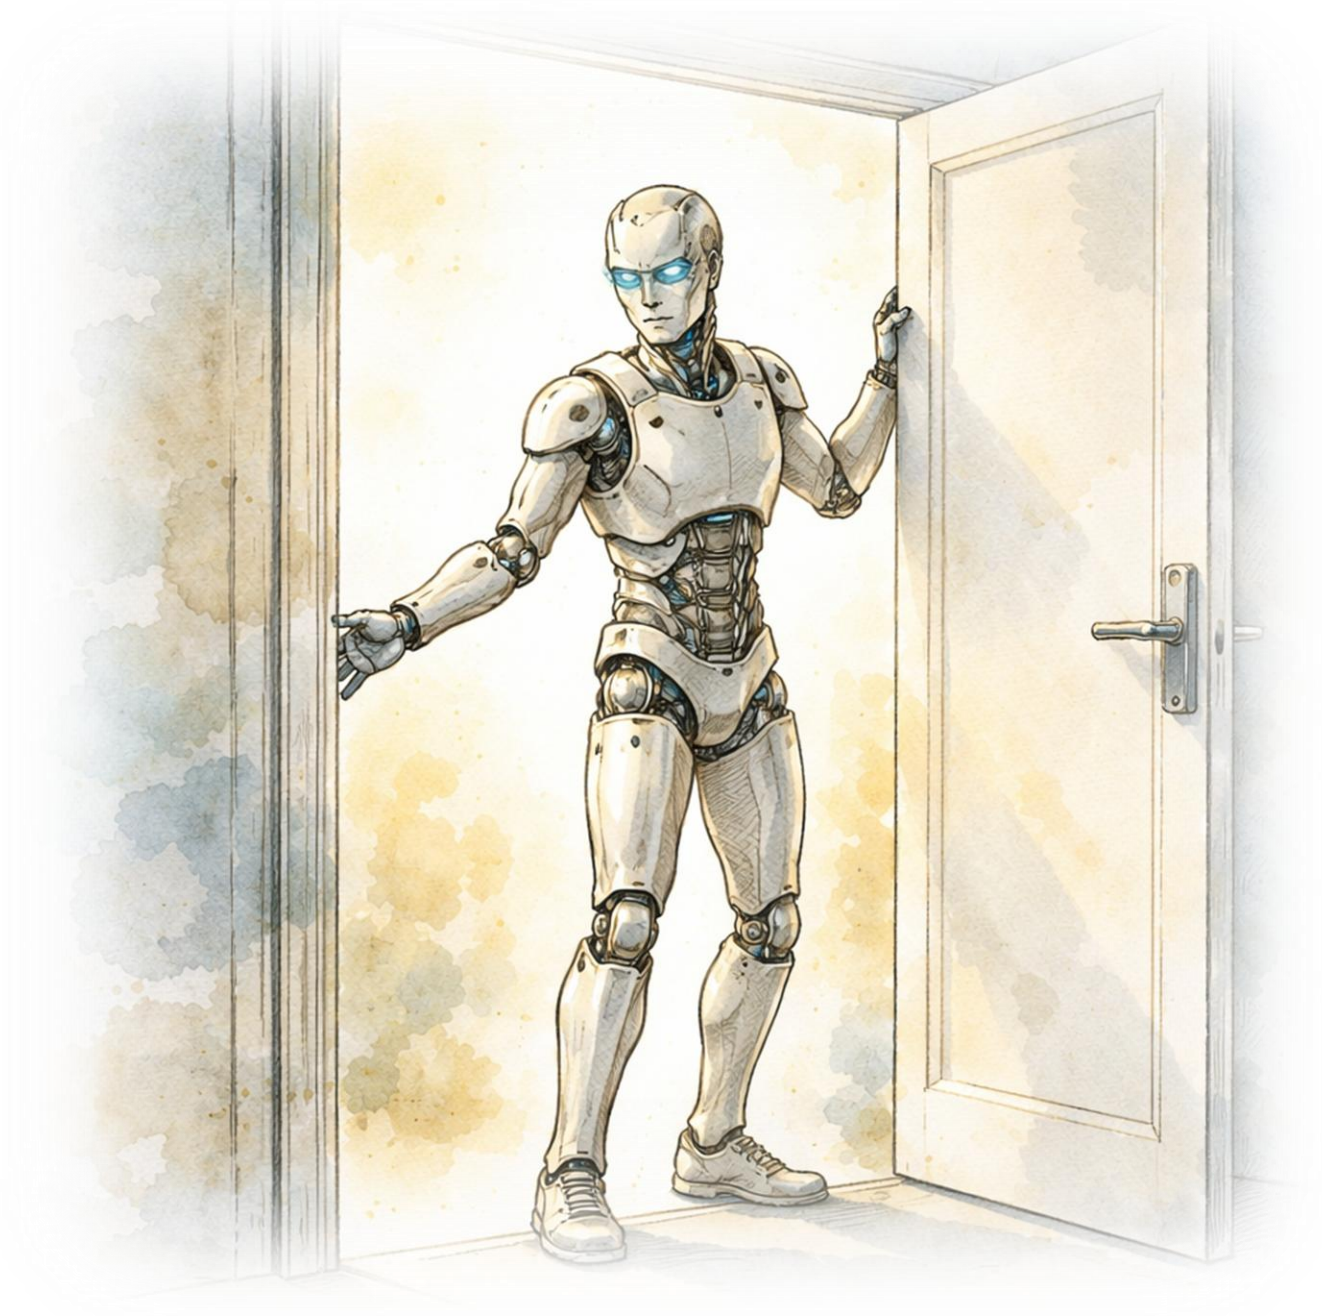

Teil I: Theoretische Fundierung und struktureller Kontext

1. Makroökonomischer und demografischer Rahmen

1.1 Demografischer Wandel und Fachkräftemangel

Deutschland steht vor einer demografischen Transformation historischen Ausmaßes. Die Bevölkerungsstruktur verschiebt sich fundamental: Während die geburtenstarken Jahrgänge der Babyboomer-Generation in den Ruhestand eintreten, rücken deutlich schwächer besetzte jüngere Kohorten nach. Laut der 16. koordinierten Bevölkerungsvorausberechnung des Statistischen Bundesamtes wird der Anteil der über 67-Jährigen von aktuell 20 Prozent (2024) auf 25 bis 27 Prozent im Jahr 2038 steigen. Die absolute Zahl der Menschen im Rentenalter wird von derzeit 16,4 Millionen auf mindestens 20 Millionen bis Mitte der 2030er Jahre wachsen. Parallel dazu wird die Zahl der Menschen im Erwerbsalter (20 bis 66 Jahre) abnehmen – selbst bei optimistischen Annahmen zur Nettozuwanderung um 1,6 Millionen, bei pessimistischen Szenarien um bis zu 4,8 Millionen Menschen bis Mitte der 2030er Jahre.

Der Altenquotient – das Verhältnis der über 65-Jährigen zu den 20- bis unter 65-Jährigen – illustriert die Dramatik dieser Verschiebung. Kamen 1950 noch 16 Personen im Rentenalter auf 100 Personen im Erwerbsalter, liegt das Verhältnis 2024 bereits bei etwa 39 zu 100. Dieser Trend wird sich fortsetzen und verschärfen. Die Konsequenzen sind weitreichend: Das Verhältnis von Beitragszahlern zu Leistungsempfängern in den Sozialversicherungssystemen verschlechtert sich dramatisch. Der Pflegebedarf steigt massiv – die Zahl der über 80-Jährigen wird von aktuell etwa 6 Millionen auf 8 bis 10 Millionen im Jahr 2050 anwachsen. Gleichzeitig schrumpft die Erwerbsbevölkerung, die diese Leistungen finanzieren und erbringen soll.

Diese demografische Entwicklung trifft auf Arbeitsmärkte, die bereits heute Knappheiten aufweisen. Der Fachkräftemangel ist kein theoretisches Zukunftsszenario, sondern empirische Realität in zahlreichen Sektoren. Allerdings ist die Situation differenzierter, als pauschale Alarmrufe suggerieren. Die Datenlage zeigt ein komplexes Bild: Im Bildungssektor variiert die Situation stark nach Schulform, Fach und Region. Während für Grundschulen in den kommenden Jahren eher ein Überangebot an Lehrkräften prognostiziert wird – die Bertelsmann-Stiftung[1] spricht von einem Plus von 45.800 Lehrkräften bis 2035 – herrscht in der Sekundarstufe I, in MINT-Fächern und an Berufsschulen akuter Mangel. Besonders dramatisch ist die Situation in naturwissenschaftlich-technischen Fächern: In Nordrhein-Westfalen liegt die Deckungsquote

[1] Bertelsmann Stiftung (2024). Lehrkräftebedarfsprognose 2035: Szenarien und Handlungsoptionen. Gütersloh.

für Physik bei nur 18 Prozent, für Informatik bei 4,6 Prozent, für Technik bei 3,6 Prozent bis zum Schuljahr 2030/31. Die Kultusministerkonferenz[2] prognostiziert einen Gesamtbedarf von 49.000 bis 68.000 fehlenden Lehrkräften bis 2035, wobei die Ständige Wissenschaftliche Kommission der KMK davon ausgeht, dass dieser Mangel mindestens 20 Jahre bestehen bleiben wird.

Im Logistiksektor – der in dieser Untersuchung als komparative Perspektive zur Bildung herangezogen wird – zeigt sich eine andere Facette des Fachkräftemangels. Hier geht es weniger um fehlende Hochqualifizierte als um den Mangel an Berufskraftfahrern. Die Branche kämpft mit einer alternden Belegschaft (Durchschnittsalter über 47 Jahre), unattraktiven Arbeitsbedingungen (lange Abwesenheit von zu Hause, hohe physische Belastung, vergleichsweise moderate Bezahlung) und mangelndem Nachwuchs. Gleichzeitig steigt die Nachfrage nach Transportdienstleistungen durch E-Commerce und globalisierte Lieferketten kontinuierlich. Diese strukturelle Diskrepanz zwischen Angebot und Nachfrage treibt sowohl die Löhne als auch die Suche nach technologischen Alternativen.

Die demografische Krise wirkt als Katalysator für technologische Transformation. Wenn menschliche Arbeitskraft knapp und teuer wird, steigt der ökonomische Anreiz, Prozesse zu automatisieren. Künstliche Intelligenz wird in diesem Kontext nicht nur als Option, sondern als strukturelle Notwendigkeit wahrgenommen – eine Antwort auf das Problem schrumpfender Erwerbsbevölkerung bei gleichzeitig wachsendem Bedarf an Bildungs-, Gesundheits- und Logistikleistungen. Diese Logik prägt die politischen und unternehmerischen Diskurse in beiden hier untersuchten Sektoren: Im Bildungswesen wird KI als mögliche Entlastung überforderter Lehrkräfte und als Instrument zur Individualisierung des Lernens bei steigenden Schülerzahlen diskutiert. In der Logistik wird autonomes Fahren als Lösung des Fahrermangels und als Effizienzsteigerung propagiert.

[2] Kultusministerkonferenz (2024). Lehrereinstellungsbedarf und -angebot in der Bundesrepublik Deutschland 2024–2035. Dokumentation Nr. 237. Berlin: Sekretariat der KMK.

1.2 Produktivitätsstagnation und ökonomischer Druck

Parallel zur demografischen Herausforderung konfrontiert die deutsche Wirtschaft eine hartnäckige Produktivitätsstagnation. Die Arbeitsproduktivität – gemessen als Bruttoinlandsprodukt je Erwerbstätigenstunde – wuchs in Deutschland in den 2010er Jahren im Durchschnitt nur noch um etwa 0,5 Prozent pro Jahr, deutlich langsamer als in den Dekaden zuvor und auch langsamer als in vergleichbaren Industrienationen. Dieses verlangsamte Produktivitätswachstum ist problematisch, weil es die ökonomische Basis für Wohlstandssteigerungen und die Finanzierung des Sozialstaats erodiert. Wenn weniger Menschen mehr leisten sollen – sei es in der Pflege, im Bildungswesen oder in der Logistik – dann muss die Produktivität pro Kopf steigen. Gelingt dies nicht, drohen entweder sinkende Lebensstandards oder fiskalische Krisen.

Die Ursachen dieser Produktivitätsschwäche sind vielfältig und umstritten. Diskutiert werden unzureichende Investitionen in digitale Infrastruktur, regulatorische Hemmnisse, Defizite in der Aus- und Weiterbildung, sowie strukturelle Verschiebungen hin zu weniger produktivitätsdynamischen Dienstleistungssektoren. Unabhängig von der genauen Diagnose besteht Konsens, dass technologische Innovation – und insbesondere die Diffusion digitaler Technologien – eine Schlüsselrolle für die Wiederbelebung des Produktivitätswachstums spielen muss. Künstliche Intelligenz wird in diesem Diskurs als potenzielle 'General Purpose Technology' gehandelt – eine Basistechnologie mit breitem Anwendungsspektrum, die ähnlich transformativ wirken könnte wie Dampfmaschine, Elektrizität oder Computer.

Im Bildungssektor manifestiert sich der Produktivitätsdruck in Form chronischer Unterfinanzierung und Überlastung. Lehrkräfte verbringen einen erheblichen Teil ihrer Arbeitszeit mit administrativen und repetitiven Tätigkeiten – Korrektur standardisierter Tests, Erstellung von Zeugnissen, Verwaltung von Anwesenheitslisten, Formatierung von Arbeitsblättern. Diese Tätigkeiten absorbieren Ressourcen, die für die eigentliche pädagogische Kernarbeit fehlen. Gleichzeitig steigen die Anforderungen: Inklusion, Digitalisierung, individuelle Förderung, Integration von Schülern mit Migrationshintergrund oder besonderen Bedürfnissen – all dies erfordert zusätzliche Zeit und Expertise. Die Hoffnung, die mit KI verbunden wird, lautet: Automatisierung der Routinen, um Raum für das Wesentliche zu schaffen. Ob diese Hoffnung berechtigt ist oder ob KI neue Probleme schafft, ist Gegenstand der empirischen Analyse in den folgenden Teilen.

In der Logistikbranche ist der Produktivitätsdruck unmittelbar ökonomisch spürbar. Transportunternehmen operieren in einem hochkompetitiven, preissensitiven Markt mit geringen Gewinnmargen. Die Personalkosten – insbesondere die Löhne der Fahrer – machen einen erheblichen Anteil der Gesamtkosten aus. Gleichzeitig limitieren gesetzliche Lenk- und Ruhezeiten die Auslastung der Fahrzeuge. Ein Lkw, der nachts parkt, weil der Fahrer seine Höchstarbeitszeit erreicht hat, generiert keinen Umsatz, verursacht aber Kapitalkosten. Autonome Fahrzeuge versprechen hier dramatische

Produktivitätssteigerungen: 24/7-Betrieb ohne Pausen, optimierte Routenplanung, keine Lohnkosten für Fahrer. Die ökonomische Logik ist so zwingend, dass die Frage nicht ist, ob diese Technologie kommt, sondern wann und wie schnell.

Diese doppelte Zange – demografischer Druck und Produktivitätsstagnation – schafft einen Kontext, in dem technologische Lösungen nicht nur erwünscht, sondern zunehmend als unvermeidlich erscheinen. Die Narrative von 'Innovation oder Abstieg', 'Automatisierung oder Wohlstandsverlust' gewinnen an Plausibilität. Dieser Kontext ist wichtig, um die Dringlichkeit zu verstehen, mit der KI-Technologien in beiden Sektoren vorangetrieben werden. Gleichzeitig ist es genau dieser Druck, der das Risiko unzureichend reflektierter, vorschneller Implementierungen erhöht. Wenn die Probleme drängend sind, sinkt die Bereitschaft, Technologien kritisch zu evaluieren, potenzielle Nebenwirkungen zu antizipieren und alternative Lösungswege zu erwägen. Die vorliegende Analyse versteht sich als Korrektiv zu diesem Beschleunigungsdruck – nicht um Innovation zu blockieren, sondern um sie informierter, reflexiver und sozial verantwortlicher zu gestalten.

2. Sektorspezifische Ausgangssituationen

2.1 Bildungssektor: Zwischen Überforderung und Innovationsdruck

Das deutsche Bildungssystem befindet sich in einer paradoxen Situation. Einerseits wird von Lehrkräften mehr erwartet als je zuvor: Sie sollen nicht nur Wissen vermitteln, sondern individuelle Lernprozesse begleiten, soziale Kompetenzen fördern, digitale Bildung implementieren, inklusiv unterrichten, Eltern beraten, mit multiprofessionellen Teams kooperieren und kontinuierlich ihre eigene Professionalität weiterentwickeln. Andererseits fehlen die Ressourcen – personell, finanziell, infrastrukturell –, um diese Anforderungen angemessen zu erfüllen. Schulgebäude sind vielerorts sanierungsbedürftig, die digitale Ausstattung ist lückenhaft, Fortbildungsangebote sind unterfinanziert, und der bereits diskutierte Lehrkräftemangel erzwingt Notlösungen wie fachfremden Unterricht oder Unterrichtsausfall.

In diese angespannte Lage platzt nun die Verfügbarkeit generativer KI-Systeme. Seit der Veröffentlichung von ChatGPT im November 2022 hat sich die Bildungslandschaft disruptiv verändert. Schüler haben plötzlich Zugang zu einem Werkzeug, das auf nahezu jede Frage plausibel klingende Antworten generiert, Essays schreibt, Programmcode produziert, Mathematikaufgaben löst und in dutzenden Sprachen übersetzt. Diese Systeme sind kostenlos oder kostengünstig verfügbar, jederzeit zugänglich und – zumindest oberflächlich betrachtet – außerordentlich hilfreich. Die Reaktionen im Bildungssektor sind gespalten: Ein Teil der Lehrkräfte sieht in KI eine Chance zur Individualisierung des Lernens, zur Entlastung von Routineaufgaben, zur Förderung digital kompetenten Arbeitens. Ein anderer Teil sieht primär die Risiken: Plagiarismus, Verlust eigenständigen Denkens, Abhängigkeit von kommerziellen Systemen, datenschutzrechtliche Probleme.

Die institutionelle Antwort auf diese Herausforderung ist bisher fragmentiert und zögerlich. Deutschland verfügt über ein föderales Bildungssystem mit 16 Landesschulsystemen, die jeweils eigene Regulierungen entwickeln – ein Flickenteppich von Verboten, Erlaubnissen, Experimenten und Ignoranz (detailliert in Kapitel 8.3). Diese regulatorische Unsicherheit wird verschärft durch datenschutzrechtliche Bedenken: Die DSGVO setzt strenge Grenzen für die Verarbeitung personenbezogener Daten von Schülern, was die Nutzung vieler kommerzieller KI-Tools rechtlich prekär macht.

Parallel zur schulischen Unsicherheit floriert ein kommerzieller EdTech-Markt, der KI-basierte Lösungen für nahezu jedes pädagogische Problem verspricht: adaptive Lernsysteme, die automatisch den Schwierigkeitsgrad anpassen; KI-Tutoren, die 24/7 verfügbar sind und individuelles Feedback geben; automatisierte Korrekturtools, die Lehrkräften Arbeit abnehmen sollen. Diese Versprechen sind attraktiv, insbesondere für überlastete Lehrkräfte und budgetbewusste Schulträger. Die empirische Evidenz für die Wirksamkeit dieser Systeme ist jedoch – wie in Teil IV dieser Arbeit detailliert

analysiert wird – oft dünn, methodisch fragwürdig oder durch Interessenkonflikte kontaminiert. Die Gefahr besteht, dass ökonomische und technologische Imperative pädagogische Rationalität überschreiben – dass Systeme nicht deshalb eingesetzt werden, weil sie nachweislich Lernen verbessern, sondern weil sie verfügbar, marketingwirksam oder kostensparend erscheinen.

Der Bildungssektor steht somit im Zentrum dieser Untersuchung, weil hier die Transformation durch KI bereits in vollem Gange ist, die Konsequenzen aber noch kaum verstanden sind. Die Fragen, die sich stellen, sind fundamental: Verändert KI-Nutzung die Art, wie Schüler denken und lernen? Fördert sie tiefes Verständnis oder oberflächliches Scheinwissen? Demokratisiert sie Bildung oder verschärft sie Ungleichheiten? Entlastet sie Lehrkräfte oder degradiert sie sie zu Techniker-Assistenten? Diese Fragen lassen sich nicht durch theoretische Spekulation beantworten, sondern erfordern empirische Untersuchung – genau das, was in den Teilen III und IV dieser Arbeit geleistet wird.

2.2 Logistiksektor: Technologischer Wandel als komparative Perspektive

Die Logistikbranche dient in dieser Untersuchung als komparative Perspektive, um fundamentale Muster der KI-Transformation zu identifizieren, die über den Bildungssektor hinausweisen. Während der Fokus der empirischen Analyse auf Lernprozessen liegt, erlaubt der Blick auf die Logistik, strukturelle Unterschiede und Gemeinsamkeiten in der Art und Weise zu erkennen, wie KI und Automatisierung verschiedene Arbeitsbereiche transformieren. Der Güterverkehr in Deutschland ist eine kritische Infrastruktur: Täglich bewegen hunderttausende Lkw Waren im Wert von Milliarden Euro. Diese Branche beschäftigt direkt und indirekt Millionen Menschen und ist essentiell für die Funktionsfähigkeit der arbeitsteiligen Wirtschaft. Gleichzeitig steht sie – wie der Bildungssektor – unter massivem Transformationsdruck.

Die technologische Vision, die hier vorangetrieben wird, ist die des autonomen Fahrens. Seit den 2010er Jahren investieren Automobilhersteller, Logistikunternehmen und Tech-Konzerne Milliarden in die Entwicklung selbstfahrender Fahrzeuge. Für den Güterverkehr ist das Versprechen besonders verlockend: Lkw, die ohne menschliche Fahrer über Autobahnen rollen, die nicht durch Lenk- und Ruhezeiten limitiert sind, die präziser fahren und dadurch Kraftstoff sparen, die keinen Lohn verlangen und nicht streiken. Die ökonomischen Anreize sind derart massiv, dass die Frage nicht ist, ob diese Technologie entwickelt wird, sondern wann sie marktreif sein wird und wie schnell sie sich durchsetzen kann.

Technologisch ist autonomes Fahren auf Autobahnen – der sogenannten 'mittleren Meile' zwischen städtischen Bereichen – bereits heute in Reichweite. Level-4-Autonomie[3], bei der das Fahrzeug in definierten Szenarien vollständig selbstständig operiert, wird in Pilotprojekten erprobt. Die 'erste Meile' (Abholung der Ware im Werk) und die 'letzte Meile' (Auslieferung in urbanen Gebieten) bleiben hingegen technologisch herausfordernd, weil sie komplexe, unvorhersehbare Verkehrssituationen, enge Straßen und sensomotorische Feinarbeit beim Rangieren erfordern – genau jene Aufgaben, die laut Moravec's Paradoxon für KI besonders schwierig sind. Als Brückentechnologie gewinnt daher die Teleoperation an Bedeutung: Menschliche Operatoren überwachen mehrere autonome Fahrzeuge von Kontrollzentren aus und greifen bei Bedarf ferngesteuert ein.

Regulatorisch hat Deutschland mit der Straßenverkehr-Fernlenk-Verordnung (StVFernLV[4]), die am 1. Dezember 2025 in Kraft trat, einen klaren rechtlichen Rahmen geschaffen (detailliert in Kapitel 8.3). Der Kontrast zur fragmentierten, zögerlichen

---

[3] SAE International (2021). Taxonomy and Definitions for Terms Related to Driving Automation Systems for On-Road Motor Vehicles (J3016_202104). SAE Standard.

[4] Bundesministerium für Digitales und Verkehr (2025). Straßenverkehr-Fernlenk-Verordnung (StVFernLV): Verordnung über das Fernlenken von Kraftfahrzeugen im Straßenverkehr. *Bundesgesetzblatt* Teil I, Nr. 384.

Regulierung im Bildungssektor zeigt unterschiedliche Governance-Kulturen: Im Wirtschaftssektor dominiert das Primat der Wettbewerbsfähigkeit, im Bildungssektor das Primat der Fürsorge und föderalen Autonomie.

Die soziale Dimension dieser Transformation ist gravierend. Wenn signifikante Teile der Fahraufgabe automatisiert werden, sind potenziell hunderttausende Arbeitsplätze betroffen. Der Beruf des Berufskraftfahrers – traditionell ein Zugang zu stabiler Beschäftigung für Menschen ohne akademische Ausbildung – könnte fundamental transformiert oder teilweise obsolet werden. Neue Jobs entstehen (Teleoperatoren, Flottenmanager, Systemüberwacher), aber diese erfordern andere, oft höhere Qualifikationen: IT-Affinität, Bildschirmarbeit, Multitasking-Fähigkeit. Die Gefahr einer Spaltung ist real: Jüngere, technikaffine, weiterbildungsbereite Fahrer können in die neuen Rollen wechseln. Ältere Fahrer ohne digitale Kompetenzen riskieren, abgehängt zu werden.

Die komparative Funktion der Logistik in dieser Untersuchung liegt darin, Kontraste und Parallelen zum Bildungssektor sichtbar zu machen. Beide Sektoren erleben KI-getriebene Transformation, aber die Transformationslogiken unterscheiden sich fundamental: Im Bildungssektor dominiert – zumindest normativ – das Augmentationsparadigma (KI als Werkzeug zur Unterstützung menschlicher Lehrtätigkeit), während in der Logistik das Substitutionsparadigma greift (KI ersetzt menschliche Arbeit auf der Langstrecke). Im Bildungssektor schützt die sozial-emotionale Komplexität pädagogischer Beziehungen den Kern des Lehrerberufs vor Automatisierung, während in der Logistik die sensomotorische Komplexität urbaner Verkehrssituationen den Fahrer in bestimmten Segmenten schützt. Diese Muster – detailliert analysiert in Teil V – helfen zu verstehen, welche Arten von Arbeit unter welchen Bedingungen automatisierbar sind und welche menschlich bleiben.

Wichtig ist festzuhalten: Die Logistikperspektive dient in dieser Arbeit nicht der empirischen Tiefenanalyse, sondern der konzeptuellen Kontrastierung. Während wir für den Bildungssektor detaillierte empirische Studien zu Lernprozessen auswerten, bleibt die Behandlung der Logistik primär auf der strukturell-vergleichenden Ebene. Diese methodische Entscheidung ist begründet im Erkenntnisinteresse: Es geht darum zu verstehen, wie KI menschliches Lernen und Arbeiten verändert – und dafür ist der Bildungssektor, in dem die Transformation bereits massenhaft stattfindet und evaluierbar ist, der primäre Untersuchungsgegenstand. Die Logistik liefert den kontrastiven Horizont, der verhindert, dass wir Besonderheiten des Bildungssektors fälschlicherweise für universelle Gesetzmäßigkeiten der KI-Transformation halten.

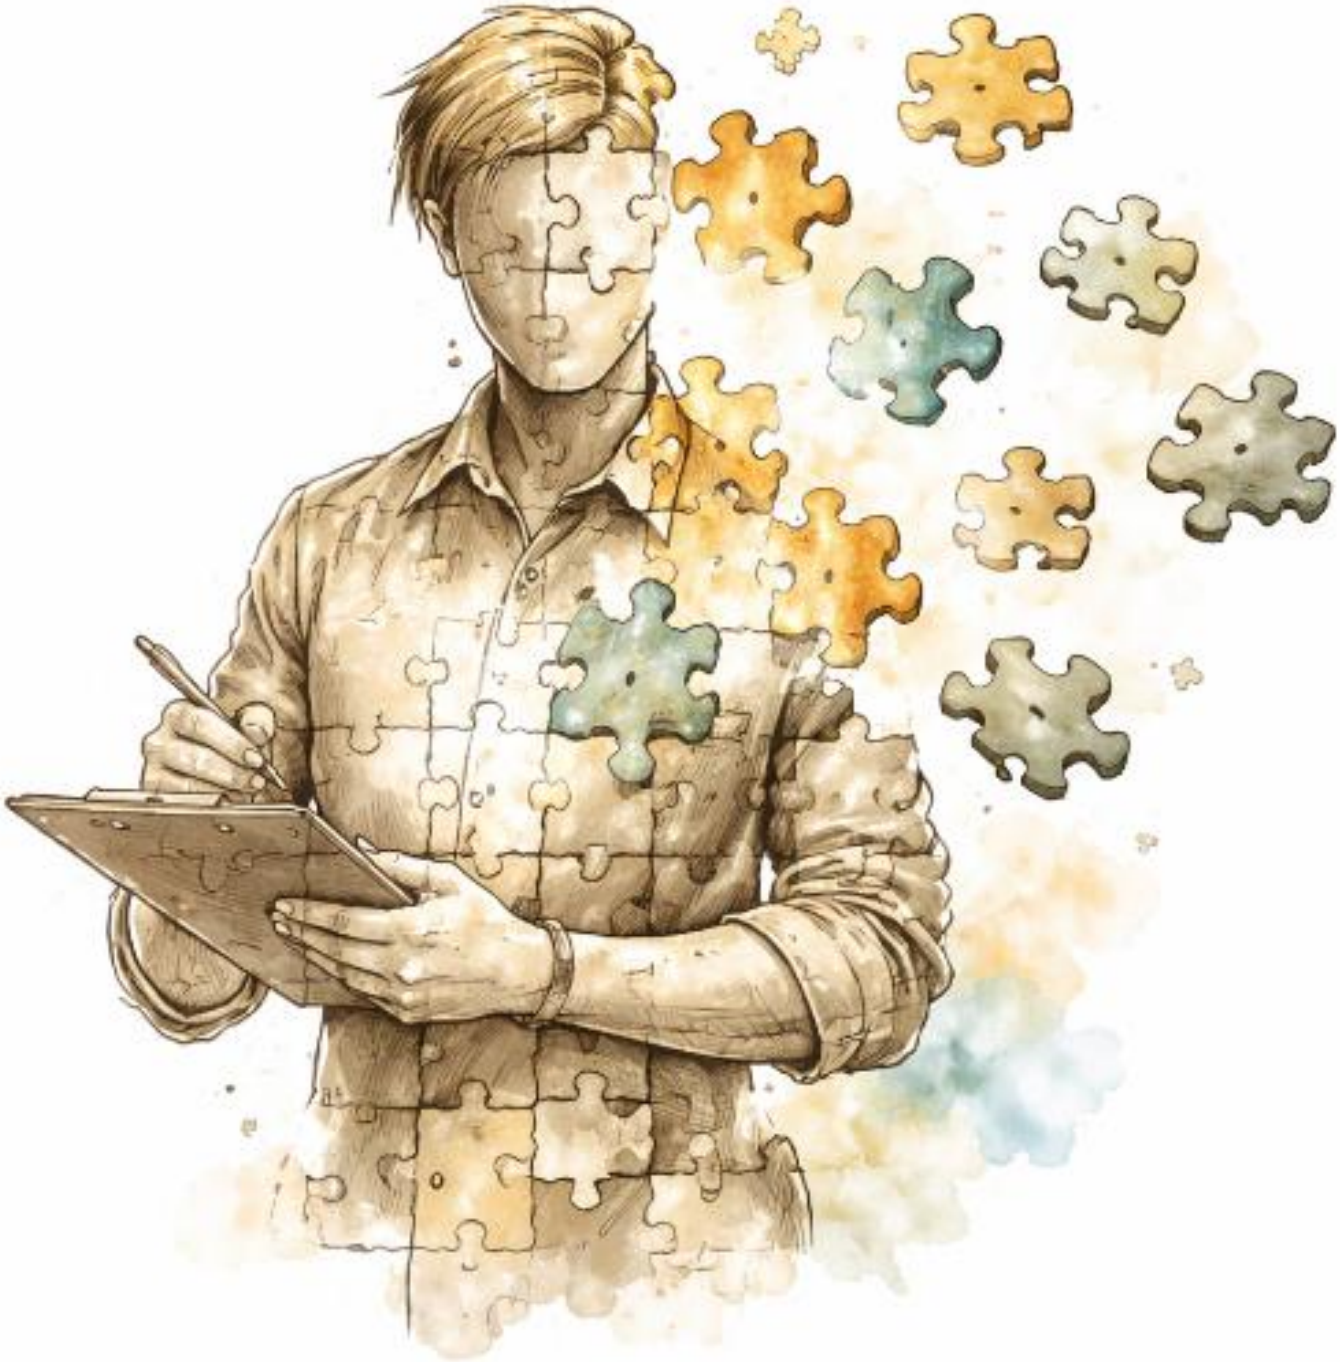

Teil II: Kognitive Metamorphose – KI in Lernprozessen

3. Theoretische Rahmenkonzepte

3.1 Task-Based Approach[5] und die Zukunft der Arbeit

Um die unterschiedlichen Auswirkungen von Künstlicher Intelligenz auf verschiedene Berufsfelder – in unserem Fall auf Lehrkräfte und LKW-Fahrer – analytisch zu erfassen, bedarf es eines theoretischen Rahmens, der über die simplifizierenden Dichotomien von 'Automatisierung versus menschliche Arbeit' oder 'Jobkiller versus Jobcreator' hinausgeht. Der sogenannte Task-Based Approach, maßgeblich entwickelt von den Ökonomen David Autor, David Dorn und Gordon Hanson[6], bietet hier eine differenzierte Perspektive, die in der gegenwärtigen Transformationsforschung zunehmend als Standard etabliert hat.

Die Grundidee dieses Ansatzes ist bestechend einfach, aber in ihren Implikationen weitreichend: Berufe werden nicht als monolithische, unteilbare Einheiten konzipiert, sondern als Bündel von distinkten Aufgaben (Tasks). Ein Lehrer erfüllt nicht 'die Aufgabe des Lehrens', sondern ein komplexes Set von Teil-Tätigkeiten: die Planung von Unterrichtssequenzen, die Vermittlung von Fachinhalten, die Korrektur von Klausuren, die individuelle Förderung einzelner Schüler, die Kommunikation mit Eltern, die Teilnahme an Konferenzen, die Dokumentation von Lernfortschritten, die Verwaltung von Materialien, die Reflexion der eigenen pädagogischen Praxis und vieles mehr. Ein LKW-Fahrer wiederum kombiniert Tätigkeiten wie das Steuern des Fahrzeugs auf der Autobahn, das Rangieren in engen Ladehöfen, die Sicherung der Ladung, die Kommunikation mit Disponenten, die Kontrolle technischer Parameter des Fahrzeugs, die Navigation in unbekanntem Terrain und die Interaktion mit Kunden bei der Übergabe.

Der entscheidende Erkenntnisgewinn des Task-Based Approach liegt nun darin, dass nicht Berufe als Ganzes automatisiert werden, sondern spezifische Tasks innerhalb dieser Berufe. Die Automatisierbarkeit einer Task hängt dabei von mehreren Faktoren ab: ihrer Routinehaftigkeit (wie stark folgt die Tätigkeit einem standardisierten, algorithmisierbaren Muster?), ihrer kognitiven versus manuellen Natur (erfordert sie primär Denkleistung oder physische Geschicklichkeit?), ihrer Interaktionsintensität

---

[5] Autor, D. H., Levy, F., & Murnane, R. J. (2003). The Skill Content of Recent Technological Change: An Empirical Exploration. *The Quarterly Journal of Economics*, 118(4), 1279–1333. https://doi.org/10.1162/003355303322552801

[6] Autor, D. H., Dorn, D., & Hanson, G. H. (2015). Untangling Trade and Technology: Evidence from Local Labour Markets. *The Economic Journal*, 125(584), 621–646.

(wie stark ist menschliche Kommunikation und Empathie involviert?) und ihrer Kontextabhängigkeit (lässt sich die Aufgabe in einem stabilen, vorhersehbaren Umfeld ausführen oder erfordert sie ständige Anpassung an neue, unvorhersehbare Situationen?).

Autor und seine Kollegen entwickelten eine einflussreiche Taxonomie, die Tasks in vier Kategorien einteilt: Routine-kognitive Aufgaben sind solche, die einem klaren, logischen Ablauf folgen und primär mentale Prozesse involvieren – Beispiele wären die Buchhaltung, die Rechtschreibkorrektur oder die Berechnung von Statistiken. Diese Tasks sind hochgradig automatisierbar durch Software und Algorithmen. Routine-manuelle Aufgaben folgen ebenfalls standardisierten Abläufen, erfordern aber physische Ausführung – etwa Fließbandarbeit, einfache Montage oder repetitives Verpacken. Diese Tasks werden klassischerweise durch Robotik automatisiert. Non-routine kognitive Aufgaben hingegen erfordern kreatives, abstraktes Denken, Problemlösung in neuartigen Situationen oder komplexe Entscheidungsfindung – hierzu zählen wissenschaftliche Forschung, strategische Planung oder künstlerische Kreation. Non-routine manuelle Aufgaben schließlich involvieren physische Geschicklichkeit in unvorhersehbaren Umgebungen – etwa die Arbeit eines Chirurgen, eines Handwerkers auf einer Baustelle oder eben eines LKW-Fahrers, der in einer überfüllten Innenstadtstraße navigieren muss.

Wenn wir diese Taxonomie auf unsere beiden Untersuchungsgegenstände anwenden, ergeben sich aufschlussreiche Muster. Im Beruf der Lehrkraft finden wir eine starke Konzentration von non-routine kognitiven Tasks: die Diagnose individueller Lernstände, die spontane Reaktion auf Unterrichtsstörungen, die kreative Entwicklung neuer Erklärungsansätze für schwierige Konzepte, die empathische Begleitung von Schülern in persönlichen Krisen. Diese Tätigkeiten sind schwer formalisierbar und erfordern ein hohes Maß an situativer Intelligenz und emotionaler Kompetenz. Gleichzeitig enthält das Tätigkeitsprofil aber auch eine nicht unerhebliche Anzahl routine-kognitiver Tasks: die standardisierte Korrektur von Multiple-Choice-Tests, die Übertragung von Noten in digitale Systeme, die Erstellung von Teilnehmerlisten, die Formatierung von Arbeitsblättern nach vorgegebenen Layoutvorgaben. Genau diese routine-kognitiven Anteile sind es, die durch generative KI substituiert werden können – und zwar nicht nur substituiert im Sinne einer gleichwertigen Ersetzung, sondern oft sogar mit höherer Geschwindigkeit und Konsistenz.

Im Beruf des LKW-Fahrers zeigt sich ein anderes Muster. Die Autobahnfahrt bei gutem Wetter und konstantem Verkehrsfluss ist eine weitgehend routine-manuelle Task: das Fahrzeug wird in der Spur gehalten, der Abstand zum Vordermann wird reguliert, die Geschwindigkeit wird an Verkehrszeichen angepasst. All dies folgt klaren, wenn auch impliziten Regeln und kann durch Level-4-Autonomie-Systeme bereits heute zuverlässig bewältigt werden. Die Ladungssicherung auf einem unebenen Hof bei Regen, das Rangieren in einer engen Gasse mit parkenden Autos, die Improvisation bei einem plötzlichen technischen Defekt oder die Kommunikation mit

einem gestressten Disponenten hingegen sind non-routine Tasks – teils manuell, teils kognitiv, teils sozial –, die sich der Automatisierung widersetzen. Das Resultat ist eine Fragmentierung des Berufs: Die 'mittlere Meile' (die Autobahnstrecke) wird automatisiert, während die 'erste' und 'letzte Meile' (Abholung vom Werk, Auslieferung in der Stadt) menschlich bleiben.

Diese Task-basierte Perspektive hat weitreichende Implikationen für die Zukunft der Arbeit. Sie impliziert erstens, dass die meisten Berufe nicht vollständig verschwinden werden, sondern sich transformieren. Der Lehrer der Zukunft wird weniger Zeit mit Korrektur und mehr Zeit mit pädagogischer Beziehungsarbeit verbringen. Der Fahrer der Zukunft wird weniger Zeit auf der Autobahn und mehr Zeit in komplexen urbanen Umgebungen oder als Teleoperator am Bildschirm verbringen. Zweitens bedeutet sie, dass die Qualifikationsanforderungen sich verschieben: Während repetitive Fähigkeiten an Wert verlieren, gewinnen metakognitive Kompetenzen – die Fähigkeit zur Problemdiagnose, zur kreativen Anpassung, zur Kooperation mit KI-Systemen – an Bedeutung. Drittens legt sie nahe, dass die soziale Ungleichheit innerhalb von Berufsgruppen zunehmen könnte: Jene Arbeitskräfte, die in der Lage sind, die non-routine Anteile ihrer Arbeit zu kultivieren und die Routine-Anteile intelligent an Maschinen zu delegieren, werden profitieren. Jene, die in routinehaften Tätigkeiten verhaftet bleiben oder die Zusammenarbeit mit KI nicht beherrschen, werden marginalisiert.

Die empirische Forschung der letzten Jahre hat die Vorhersagen des Task-Based Approach weitgehend bestätigt. Eine Studie des Instituts für Arbeitsmarkt- und Berufsforschung[7] (IAB) aus dem Jahr 2024 untersuchte die Automatisierungsrisiken in Deutschland und kam zu dem Schluss, dass lediglich 12% aller Arbeitsplätze einem hohen Automatisierungsrisiko (über 70% ihrer Tasks sind automatisierbar) ausgesetzt sind. Dies ist deutlich niedriger als die alarmistischen Prognosen früherer Studien, die von bis zu 50% sprachen. Der Unterschied erklärt sich genau durch die Task-basierte Granularität: Während frühere Studien ganze Berufe als 'automatisierbar' klassifizierten, sobald die Mehrheit ihrer Tasks theoretisch automatisiert werden könnte, zeigt die differenziertere Analyse, dass in den meisten Berufen ein kritischer Kern von non-routine Tasks verbleibt, der menschliche Präsenz erfordert.

Für die weitere Analyse in diesem Bericht bedeutet der Task-Based Approach, dass wir nicht fragen 'Wird KI den Lehrerberuf oder den Fahrerberuf überflüssig machen?', sondern vielmehr 'Welche spezifischen Tasks innerhalb dieser Berufe werden transformiert, welche menschlichen Fähigkeiten werden dadurch frei für andere Tätigkeiten, und welche neuen Kompetenzanforderungen entstehen?' Diese Reframing ist nicht nur analytisch präziser, sondern auch politisch produktiver, denn sie lenkt

[7] Dengler, K., & Matthes, B. (2024). Folgen der Digitalisierung für die Arbeitswelt: Substituierbarkeitspotenziale von Berufen und Veränderungen seit 2016. *IAB-Forschungsbericht* 08/2024. Institut für Arbeitsmarkt- und Berufsforschung, Nürnberg.

die Aufmerksamkeit auf die gestaltbaren Aspekte der Transformation – auf Weiterbildung, Arbeitsorganisation und die intelligente Mensch-Maschine-Arbeitsteilung – anstatt in Fatalismus oder blinden Technikoptimismus zu verfallen.

3.2 Das Moravec'sche Paradoxon[8]: Kognition versus Motorik

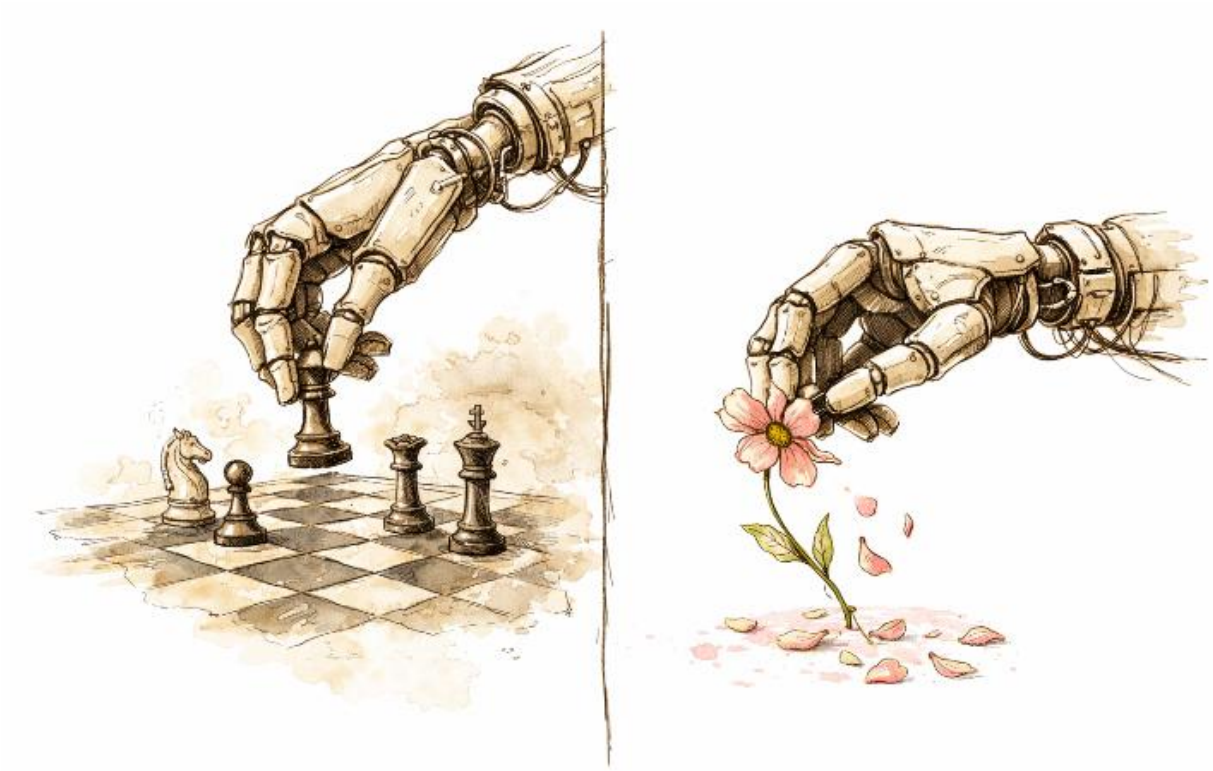

Wenn man die gegenwärtige Landschaft der KI-Fähigkeiten betrachtet, stößt man auf ein zunächst paradoxes Phänomen: Systeme wie GPT-4 oder Claude können eloquente philosophische Essays verfassen, komplexe juristische Argumentationen nachvollziehen oder kreative Marketingkonzepte entwickeln – Tätigkeiten, die wir intuitiv als 'hochintelligent' und 'typisch menschlich' erachten. Gleichzeitig scheitern selbst die fortschrittlichsten Robotersysteme an Aufgaben, die ein dreijähriges Kind mühelos bewältigt: das Greifen einer Tasse, ohne sie umzustoßen, das Erkennen einer Person in wechselnder Beleuchtung oder das Balancieren auf unebenem Untergrund. Diese Diskrepanz ist nicht zufällig, sondern verweist auf eine fundamentale Einsicht über die Natur von Intelligenz und die evolutionären Grundlagen menschlicher Kognition.

Hans Moravec, ein österreichisch-kanadischer Robotikforscher, der in den 1980er Jahren am Carnegie Mellon Robotics Institute arbeitete, war einer der ersten, der dieses

[8] Moravec, H. (1988). *Mind Children: The Future of Robot and Human Intelligence*. Cambridge, MA: Harvard University Press.

Phänomen systematisch artikulierte. Seine Beobachtung, später als 'Moravec's Paradox' bekannt, lautet: 'Es ist vergleichsweise einfach, Computer dazu zu bringen, die Leistungen Erwachsener bei Intelligenztests oder beim Damespiel zu erbringen, aber es ist schwierig oder unmöglich, ihnen die Fähigkeiten eines Einjährigen zu verleihen, wenn es um Wahrnehmung und Mobilität geht.' Diese Inversion unserer intuitiven Erwartungen hat einen tieferen evolutionären Grund: Was wir als 'schwierig' empfinden (abstrakte Mathematik, logisches Schlussfolgern, Schachspielen), sind evolutionär gesehen sehr junge Fähigkeiten, die erst in den letzten Jahrtausenden der menschlichen Kulturgeschichte entstanden sind. Die neuronalen Schaltkreise für diese Tätigkeiten sind relativ oberflächlich und explizit – sie können durch symbolische Regeln und Algorithmen approximiert werden.

Was wir hingegen als 'leicht' empfinden (sehen, hören, sich bewegen, Objekte manipulieren), sind evolutionär uralte Fähigkeiten, die über Millionen von Jahren optimiert wurden. Sie basieren auf massiv parallelen, hochgradig spezialisierten neuronalen Netzwerken, die in unserem Gehirn unbewusst operieren. Ein Kind, das lernt zu laufen, aktiviert Milliarden von Neuronen, die Gleichgewicht, propriozeptive Rückmeldung, visuelle Tiefenwahrnehmung und motorische Koordination in Echtzeit integrieren – eine Rechenleistung, die jeder Supercomputer zu replizieren versagt. Moravec fasste dies in der prägnanten Formulierung zusammen: 'Encoded in the large, highly evolved sensory and motor portions of the human brain is a billion years of experience about the nature of the world and how to survive in it.'

Dieses Paradoxon hat direkte Implikationen für die Automatisierung von Arbeit. Es erklärt, warum die Wissensarbeiter – Anwälte, Berater, Journalisten, Lehrer – sich plötzlich durch generative KI bedroht fühlen, während Handwerker, Pflegekräfte oder eben Fahrer in komplexen Verkehrssituationen vorerst relativ sicher sind. Die Tätigkeiten der ersten Gruppe mögen gesellschaftlich hochgeschätzt sein und erfordern jahrelange akademische Ausbildung, aber sie operieren in der Domäne abstrakter Symbole, linguistischer Muster und formaler Logik – genau jener Bereich, in dem Maschinen bereits heute brillieren. Die Tätigkeiten der zweiten Gruppe mögen gesellschaftlich weniger prestigeträchtig sein, aber sie erfordern sensomotorische Intelligenz, kontextuelle Adaptation und physische Geschicklichkeit – Fähigkeiten, die für KI nach wie vor fundamental schwierig sind.

Im Bildungssektor manifestiert sich das Moravec'sche Paradoxon in einer bemerkenswerten Verschiebung dessen, was als 'Kernkompetenz' von Lehrkräften gilt. Traditionell wurde der Lehrer als 'Wissensvermittler' konzipiert – als jemand, der über Fachwissen verfügt und dieses in verständlicher Form an Schüler weitergibt. Diese Funktion ist heute durch KI partiell substituierbar: Ein Schüler kann ChatGPT fragen 'Erkläre mir die Photosynthese' und erhält eine kohärente, didaktisch aufbereitete Antwort, oft besser strukturiert als die spontane Erklärung einer überarbeiteten Lehrkraft in der fünften Stunde. Die KI kann unendlich geduldig sein, sie wiederholt Erklärungen in variierenden Formulierungen, sie passt die Komplexität an das vermeintliche

Niveau des Schülers an. Was die KI jedoch nicht kann – und hier greift Moravec – ist die empathische Wahrnehmung der emotionalen Verfassung eines Schülers, der gerade von seinen Mitschülern gemobbt wurde. Sie kann nicht die subtilen non-verbalen Signale deuten, die anzeigen, dass ein Schüler zwar vorgibt zu verstehen, in Wahrheit aber völlig verloren ist. Sie kann nicht die soziale Dynamik einer Klassengemeinschaft moderieren, nicht den Moment erkennen, in dem ein humorvoller Kommentar die Spannung löst, nicht die biografische Brücke schlagen, die einem Schüler zeigt, dass Lernen mit seinem Leben zu tun hat.

Mit anderen Worten: Die kognitiv-analytischen Anteile des Lehrens (Wissensvermittlung, Aufgabenstellung, Bewertung nach klaren Kriterien) sind durch KI augmentierbar oder sogar substituierbar, während die sozial-emotionalen und relationalen Anteile (Beziehungsaufbau, Motivierung, Konfliktlösung, individuelle Förderung im ganzheitlichen Sinne) nach wie vor zutiefst menschliche Domänen sind. Dies führt zu einer paradoxen Situation: Gerade jene Aspekte des Lehrerberufs, die in der öffentlichen Wahrnehmung oft als 'soft skills' bagatellisiert werden, erweisen sich als die am schwersten automatisierbaren und damit wertvollsten Ressourcen. Die Professionalisierung des Lehrerberufs in einer KI-Ära wird daher möglicherweise eine Neubewertung dieser emotionalen und relationalen Kompetenzen erfordern – weg von der Vorstellung des Lehrers als wandelnde Enzyklopädie, hin zum Lehrer als empathischer Lernbegleiter und Beziehungsarchitekt.

Im Logistiksektor zeigt sich das Paradoxon in umgekehrter Form. Die scheinbar einfache Tätigkeit des 'Fahrens auf der Autobahn' – ein Kontext mit relativ standardisierten Verkehrsregeln, klarer Fahrbahnmarkierung und vorhersehbaren Bewegungsmustern – ist für autonome Systeme bereits heute beherrschbar. Tesla's Autopilot, Waymo's selbstfahrende Taxis oder die in Entwicklung befindlichen autonomen Lkw von MAN und Daimler demonstrieren, dass die Autobahnfahrt unter idealen Bedingungen automatisiert werden kann. Die 'letzte Meile' hingegen – das Navigieren durch enge Altstadtgassen, das Reagieren auf einen unvorhersehbaren Fußgänger, der hinter einem geparkten Auto hervorspringt, das Einschätzen, ob eine Zufahrt breit genug für den Lkw ist, oder das Rangieren auf einem schlammigen Bauhof – stellt die Systeme vor nahezu unlösbare Probleme. Hier ist nicht nur präzise Wahrnehmung gefordert (Was ist dieser unklare Schatten am Straßenrand – ein Müllsack oder ein Hund?), sondern auch sensomotorische Feinabstimmung (Wie viel Lenkeinschlag bei welcher Geschwindigkeit auf nassem Untergrund?) und vor allem: die Fähigkeit zur Improvisation in neuartigen Situationen.

Das Moravec'sche Paradoxon erklärt auch, warum die Prognosen über autonome Fahrzeuge in den letzten Jahren immer wieder nach hinten korrigiert werden mussten. Um 2015 herum herrschte in der Tech-Industrie ein fast euphorischer Optimismus: Autonome Lkw würden bis 2020 großflächig im Einsatz sein, hieß es. Diese Vorhersagen basierten auf einer Unterschätzung genau jener Probleme, die Moravec identifiziert

hatte. Die Entwickler konzentrierten sich auf die kognitive Herausforderung (Routenplanung, Verkehrszeichenerkennung, Spurhaltung) und übersahen die sensomotorische Komplexität. Ein Mensch kann intuitiv erkennen, ob eine Pfütze auf der Straße harmlos ist oder ein tiefes Schlagloch verbirgt. Ein Lidar-System sieht nur eine Anomalie und muss raten. Ein Mensch kann die Aufmerksamkeit eines anderen Verkehrsteilnehmers einschätzen (Schaut der Radfahrer auf sein Handy? Wird er gleich die Spur wechseln?) – eine KI sieht nur Pixelmuster. Diese 'letzten Prozent' der Fahraufgabe, die einen menschlichen Fahrer von einem autonomen System unterscheiden, erweisen sich als die härteste Nuss.

Interessanterweise schützt das Moravec'sche Paradoxon beide untersuchten Berufsgruppen – Lehrer und Fahrer – in ihrem jeweiligen Kern, aber auf unterschiedliche Weise. Es schützt den Lehrer, indem es die soziale Interaktion als unangetastete Domäne ausweist. Es schützt den Fahrer, indem es die komplexe Motorik in unstrukturierten Umgebungen als technologische Grenze markiert. Gleichzeitig erodiert es jeweils die Peripherie: Die rein kognitive Wissensvermittlung des Lehrers wird delegierbar, das routinehafte Steuern des Fahrzeugs auf der Autobahn wird automatisierbar. Das Resultat ist in beiden Fällen nicht ein Verschwinden der Berufe, sondern ihre Konzentration auf genau jene Aufgaben, die den Menschen noch unersetzbar machen – allerdings mit der unbequemen Konsequenz, dass genau diese 'geschützten' Tätigkeiten oft auch die am wenigsten quantifizierbaren, am schwersten zu standardisierenden und damit am schwierigsten durch Metriken zu bewertenden sind.

3.3 Desirable Difficulties und kognitive Architektur

Eine der folgenreichsten Einsichten der kognitiven Lernpsychologie der letzten Jahrzehnte stammt von Robert Bjork und seiner Forschungsgruppe[9] an der UCLA: das Konzept der 'Desirable Difficulties' – der wünschenswerten Erschwernisse. Diese zunächst kontraintuitiv anmutende Idee besagt, dass Lernprozesse, die sich während der Aneignung leicht und flüssig anfühlen, oft zu schlechteren langfristigen Lernergebnissen führen als solche, die mühsam, anstrengend und von temporären Fehlern geprägt sind. Mit anderen Worten: Produktives Scheitern, kognitive Anstrengung und das aktive Ringen mit schwierigen Problemen sind keine bedauerlichen Nebeneffekte des Lernens, sondern konstitutive Bestandteile effektiven Wissenserwerbs.

Bjorks Forschungen, die über mehrere Jahrzehnte hinweg in kontrollierten Laborexperimenten und Feldstudien validiert wurden, zeigen folgendes Muster: Wenn Lernende mit Materialien konfrontiert werden, die wiederholt in kurzen Abständen präsentiert werden (massed practice), empfinden sie den Lernprozess als effizient und erfolgreich. Sie haben das Gefühl, schnell Fortschritte zu machen, weil die Informationen noch frisch im Arbeitsgedächtnis sind. Tatsächlich jedoch ist die langfristige Retention – also das, was Wochen oder Monate später noch abrufbar ist – bei dieser Methode deutlich geringer als bei verteiltem Lernen (spaced practice), bei dem die Wiederholungen über längere Zeiträume gestreckt werden. Ähnlich verhält es sich mit dem Phänomen des 'Testens': Lernende, die passiv Texte wiederlesen, fühlen sich kompetent, weil die Informationen vertraut wirken (Fluency Illusion). Lernende, die aktiv versuchen, Informationen aus dem Gedächtnis abzurufen (Retrieval Practice), strugglen initial mehr, zeigen aber deutlich bessere Langzeitergebnisse.

Die neurologische Erklärung für dieses Phänomen liegt in den Mechanismen der Gedächtniskonsolidierung. Lernen im kognitiv-neurowissenschaftlichen Sinne bedeutet die Bildung und Stärkung synaptischer Verbindungen zwischen Neuronen. Diese Verbindungen werden nicht durch passive Exposition, sondern durch aktive Nutzung gestärkt – und zwar insbesondere dann, wenn das System herausgefordert wird, Informationen unter erschwerten Bedingungen abzurufen oder zu verarbeiten. Der Prozess des 'Vergessens und wieder Erinnerns' ist dabei kein Fehler, sondern ein Feature: Jedes Mal, wenn eine Information erfolgreich aus einem schwächer werdenden Gedächtnistrace reaktiviert wird, wird diese Spur verstärkt und resistenter gegen zukünftiges Vergessen. Bjork spricht hier vom Unterschied zwischen 'Storage Strength' (wie fest eine Information im Langzeitgedächtnis verankert ist) und 'Retrieval Strength' (wie leicht sie momentan abrufbar ist). Paradoxerweise führen Lernmethoden, die die Retrieval Strength kurzfristig maximieren (Cramming, massed practice),

[9] Bjork, R. A., & Bjork, E. L. (2011). Making things hard on yourself, but in a good way: Creating desirable difficulties to enhance learning. In M. A. Gernsbacher et al. (Eds.), *Psychology and the real world* (2nd ed., pp. 59–68). Worth Publishers.

zu geringerer Storage Strength, während Methoden, die initial die Retrieval erschweren (spacing, interleaving, testing), zu robuster Storage führen.

Nun kommen wir zum kritischen Punkt für unsere KI-Analyse: Generative KI-Systeme wie ChatGPT oder Claude haben die inhärente Eigenschaft, kognitive Anstrengung zu minimieren. Sie liefern auf Knopfdruck perfekt formulierte Antworten, kohärente Argumentationsstrukturen, vollständige Lösungswege für mathematische Probleme. Für einen Lernenden bedeutet dies: Die Phase des produktiven Scheiterns, des mühsamen Suchens nach der richtigen Formulierung, des Verwerfens falscher Ansätze und des erneuten Versuchens – all jene Prozesse, die nach Bjork essentiell für tiefes Lernen sind – werden übersprungen. Der Schüler, der ChatGPT bittet, einen Essay über die Französische Revolution zu schreiben, erhält ein fertiges Produkt. Er durchläuft nicht den Prozess des Sammelns von Informationen, des Sortierens relevanter von irrelevanten Fakten, des Konstruierens einer Argumentationslinie, des Ringens um präzise Formulierungen, des Überarbeitens nach kritischer Selbstlektüre. All diese kognitiv anstrengenden Schritte, die 'desirable difficulties' darstellen, werden eliminiert.

Die Konsequenz ist eine neue Form der 'Illusion of Competence': Der Lernende sieht den exzellenten Output (den Essay, die Lösung, die Präsentation) und attribuiert ihn sich selbst. Da er den Prozess initiiert hat (den Prompt formuliert), entsteht das psychologische Gefühl von Autorschaft. Gleichzeitig hat er aber die kognitiven Operationen, die zu echter Kompetenz führen würden, nicht durchlaufen. Er hat nicht gelernt, wie man einen Essay strukturiert, sondern wie man eine KI instruiert, einen Essay zu strukturieren – eine Metakompetenz, die durchaus wertvoll sein kann, aber nicht identisch ist mit der fachlichen Kompetenz selbst. Diese Verwechslung ist tückisch, weil sie subjektiv nicht spürbar ist. Der Schüler fühlt sich kompetent, weil er ein kompetentes Produkt in Händen hält, ohne zu realisieren, dass die Kompetenz external gelagert ist.

Robert Bjork selbst hat sich in jüngeren Publikationen explizit mit der Frage beschäftigt, wie Technologie – und insbesondere KI – mit dem Prinzip der Desirable Difficulties interagiert. Seine Warnung ist eindeutig: Technologien, die darauf ausgelegt sind, Lernen 'einfacher' und 'friktionsfreier' zu machen, können kontraproduktiv sein, wenn sie die produktive Anstrengung eliminieren. Die Herausforderung für Lerndesign im KI-Zeitalter besteht darin, KI so einzusetzen, dass sie nicht als kognitive Abkürzung (Shortcut) fungiert, sondern als Scaffold – als Gerüst, das temporär Unterstützung bietet, aber graduell abgebaut wird, sodass der Lernende schließlich autonom agieren kann.

Ein konkretes Beispiel: Wenn ein Schüler in Mathematik vor einem schwierigen Beweis steht und ChatGPT um die Lösung bittet, erhält er die vollständige Beweisführung. Dies eliminiert die 'desirable difficulty'. Eine alternative, lernförderliche Nutzung wäre: Der Schüler arbeitet zunächst selbst am Beweis, dokumentiert

seine Denkschritte und Blockaden, und bittet dann die KI um einen Hinweis (nicht die Lösung) zu einem spezifischen Schritt, an dem er festhängt. Die KI gibt einen minimalen Hint, der Schüler arbeitet weiter, erreicht vielleicht den nächsten Schritt, stößt erneut an, holt sich den nächsten Hinweis. Dieser iterative Prozess bewahrt die kognitive Anstrengung und damit die 'desirable difficulty', nutzt aber die KI als adaptive Unterstützung. Genau diese Form der Nutzung erfordert jedoch Selbstdisziplin, metakognitives Bewusstsein und eine pädagogische Rahmung – Faktoren, die in der Realität oft fehlen.

Die empirische Forschung, die wir im nächsten Abschnitt detailliert analysieren werden, bestätigt diese theoretischen Erwartungen in alarmierender Weise. Studien wie jene von Hamsa Bastani zeigen, dass Schüler, die uneingeschränkten Zugang zu KI haben, während der Übungsphase zwar exzellente Leistungen erzielen (weil die KI die Probleme für sie löst), in autonomen Tests ohne KI jedoch signifikant schlechter abschneiden als Kontrollgruppen. Sie haben Performance ohne Kompetenz entwickelt – ein klassisches Resultat der Elimination von Desirable Difficulties. Im Gegensatz dazu zeigen Studien mit 'Guardrails' – also KI-Systemen, die so programmiert sind, dass sie keine direkten Lösungen geben, sondern nur Hinweise in sokratischer Manier –, dass hier die 'desirable difficulties' erhalten bleiben und entsprechend nachhaltiges Lernen stattfindet.

Für Lehrkräfte und Bildungspolitiker ergibt sich daraus eine klare Implikation: KI-Integration im Bildungskontext muss bewusst so gestaltet werden, dass sie Friction erzeugt, nicht beseitigt. Dies steht im direkten Widerspruch zur Marketingrhetorik vieler EdTech-Anbieter, die 'seamless learning', 'effortless education' und 'instant feedback' versprechen. Aus lernpsychologischer Sicht sind genau diese Versprechen problematisch. Was wir brauchen, ist 'effortful learning with intelligent support' – Lernen, das anstrengend bleibt, aber durch KI dort unterstützt wird, wo die Anstrengung unproduktiv würde (z.B. bei technischen Hürden, Zugang zu Informationen, Formatierungsaufgaben). Die Kunst besteht darin, die richtige Zone zu finden: genug Schwierigkeit, um kognitive Aktivierung zu erzeugen, aber nicht so viel Schwierigkeit, dass Frustration und Resignation entstehen. Vygotsky nannte dies die 'Zone der nächsten Entwicklung' – jener Bereich, in dem Aufgaben mit Unterstützung lösbar sind, aber nicht ohne Anstrengung. KI sollte diese Zone erweitern, nicht eliminieren.

3.4 Von prozeduraler zu konstruktiver KI-Nutzung

Eine der aufschlussreichsten neueren Studien zum Einfluss von KI auf Lernprozesse stammt von Yan und Kollegen aus dem Jahr 2025, publiziert im Journal 'Innovations in Education and Teaching International'[10] unter dem Titel 'Mastering Knowledge: The Impact of Generative AI on Learning Outcomes'. Was diese Studie von vielen anderen abhebt, ist ihr Fokus nicht auf die technologischen Eigenschaften der KI-Tools, sondern auf die epistemologischen Haltungen der Nutzer – also darauf, wie Lernende konzeptuell über die Rolle der KI in ihrem Lernprozess nachdenken und wie diese Konzeption ihr tatsächliches Nutzungsverhalten und damit ihre Lernergebnisse beeinflusst.

Yan et al. unterscheiden zwischen zwei fundamentalen Modi der KI-Nutzung, die sie als 'prozedurale Nutzung' (procedural use) und 'konstruktive Nutzung' (constructive use) bezeichnen. Diese Dichotomie ist nicht technisch determiniert – dieselbe KI kann in beiden Modi genutzt werden –, sondern hängt von der Intention, dem Vorwissen und der metakognitiven Kompetenz des Nutzers ab. Prozedurale Nutzung liegt vor, wenn die KI als Black Box zur Erzeugung eines Endprodukts eingesetzt wird. Der Nutzer formuliert eine Aufgabe, die KI liefert ein Resultat, der Nutzer übernimmt dieses Resultat mit minimaler oder ohne kritische Reflexion. Der kognitive Prozess ist externalisiert: Die 'Arbeit' des Denkens, Strukturierens, Formulierens wird an die Maschine delegiert. Der Nutzer agiert als Auftraggeber und Konsument, nicht als aktiver Konstrukteur von Wissen.

Konstruktive Nutzung hingegen zeichnet sich dadurch aus, dass die KI als dialogisches Werkzeug zur Wissenskonstruktion eingesetzt wird. Der Nutzer formuliert nicht nur Anfragen, sondern stellt Rückfragen, testet alternative Formulierungen, fordert die KI auf, Gegenargumente zu formulieren, nutzt die KI-Outputs als Denkanstöße für eigene Reflexion, identifiziert Lücken oder Fehler in den KI-Antworten und versucht, diese durch weitere Recherche zu schließen. In diesem Modus fungiert die KI nicht als Lösungsautomat, sondern als 'kognitiver Sparringspartner' – ein System, das hilft, das eigene Denken zu schärfen, blinde Flecken zu identifizieren und Wissensstrukturen aktiv aufzubauen. Der entscheidende Unterschied: Bei prozeduraler Nutzung bleibt die Kontrolle über den Erkenntnisprozess bei der KI; bei konstruktiver Nutzung behält der Mensch die epistemische Autorität.

Die empirischen Befunde von Yan et al. sind eindeutig: Studierende, die die KI primär prozedural nutzen, zeigen signifikant schlechtere Lernergebnisse in Post-Tests als jene, die sie konstruktiv einsetzen – und zwar selbst dann, wenn beide Gruppen quantitativ ähnlich viel Zeit mit der KI verbringen. Der Unterschied liegt nicht in der

---

[10] Yan, L., Martinez-Maldonado, R., & Gasevic, D. (2025). Procedural vs. Constructive: Characterizing Students' Interaction Patterns with Generative AI in Learning. *Innovations in Education and Teaching International*

Nutzungsdauer, sondern in der Nutzungsqualität. Was die Studie besonders aufschlussreich macht, ist die Analyse der Determinanten: Welche Faktoren prädisponieren Lernende dazu, die eine oder andere Nutzungsform zu wählen? Die Autoren identifizieren drei Schlüsselfaktoren: Erstens Vorwissen. Lernende mit solidem Grundwissen in einem Fach sind eher in der Lage, KI-Outputs kritisch zu bewerten, Fehler oder Ungenauigkeiten zu erkennen und produktive Folgefragen zu stellen. Sie können die KI konstruktiv nutzen, weil sie über das kognitive Fundament verfügen, um die Outputs einzuordnen. Lernende mit geringem Vorwissen hingegen tendieren zur prozeduralen Nutzung, weil ihnen die Kompetenz fehlt, die Qualität der KI-Antworten zu beurteilen – sie vertrauen der Maschine mangels Alternativen.

Zweitens metakognitive Kompetenz. Lernende mit ausgeprägten metakognitiven Fähigkeiten – also der Fähigkeit, über das eigene Denken nachzudenken, Lernstrategien bewusst zu wählen und den eigenen Wissensstand realistisch einzuschätzen – nutzen KI tendenziell konstruktiver. Sie haben ein klares Ziel ('Ich will Konzept X verstehen'), überwachen ihren Fortschritt ('Habe ich es jetzt verstanden oder nur auswendig gelernt?') und passen ihre KI-Nutzung strategisch an ('Ich brauche erst ein Beispiel, dann die formale Definition, dann eine Übungsaufgabe'). Lernende mit schwacher Metakognition nutzen die KI reaktiver und unsystematischer – sie 'probieren herum', ohne klare Lernziele, und sind zufrieden, sobald sie ein Ergebnis haben, ohne zu hinterfragen, ob sie es auch verstanden haben.

Drittens epistemologische Überzeugungen. Lernende, die eine 'naiv-realistische' Epistemologie haben – also glauben, dass Wissen aus objektiven Fakten besteht, die entweder richtig oder falsch sind und von Autoritäten (Lehrern, Büchern, oder eben KI) bereitgestellt werden – tendieren zur prozeduralen Nutzung. Sie sehen die KI als omnisziente Wissensquelle, deren Outputs per definitionem korrekt sind. Lernende mit einer 'konstruktivistischen' Epistemologie hingegen – jene, die Wissen als aktiv konstruiert, perspektivenabhängig und revidierbar verstehen – sind skeptischer gegenüber KI-Outputs und nutzen sie eher als Anregung denn als endgültige Wahrheit. Diese epistemologischen Überzeugungen sind tief verwurzelt und durch schulische Sozialisation geprägt: Bildungssysteme, die kritisches Denken, Quellenarbeit und Argumentation betonen, produzieren eher Lernende mit konstruktivistischer Haltung; Systeme, die auf Faktenvermittlung und Prüfungen fokussieren, erzeugen eher naive Realisten.

Die Implikationen dieser Befunde für die Bildungspraxis sind weitreichend. Sie legen nahe, dass die bloße Bereitstellung von KI-Tools nicht automatisch zu besseren Lernresultaten führt – im Gegenteil, ohne entsprechende pädagogische Rahmung und ohne Förderung der genannten Kompetenzen (Vorwissen, Metakognition, epistemologische Reife) kann KI-Zugang sogar schädlich sein. Was benötigt wird, ist explizite Bildung zur KI-Literalität – nicht im Sinne technischer Fähigkeiten (wie schreibt man gute Prompts?), sondern im Sinne epistemischer Kompetenz (wie nutze ich KI zur Wissenskonstruktion, ohne meine kognitive Autonomie aufzugeben?).

Yan et al. schlagen konkret vor, dass Lehrkräfte modellieren sollten, wie konstruktive KI-Nutzung aussieht. Beispielsweise könnte eine Lehrkraft in einer Unterrichtsstunde öffentlich mit ChatGPT interagieren, dabei ihre Denkprozesse verbalisieren ('Die KI sagt X, aber das widerspricht dem, was wir letzte Woche gelernt haben. Lass mich nachfragen...'), kritische Nachfragen stellen und demonstrieren, wie man KI-Halluzinationen erkennt. Solche Modellierungen sind besonders für Novizen essentiell, die sonst keine Vorstellung haben, wie produktive KI-Nutzung jenseits des 'Frag-und-Kopier'-Modus aussehen könnte. Ebenso wichtig ist die Gestaltung von Aufgabenformaten, die prozedurale Nutzung erschweren und konstruktive Nutzung belohnen. Statt zu fragen 'Schreibe einen Essay über Klimawandel' (leicht durch rein prozedurale KI-Nutzung lösbar), könnte eine Aufgabe lauten: 'Nutze KI, um drei unterschiedliche Argumentationslinien zum Klimawandel zu generieren. Analysiere die Schwächen jeder Argumentation und entwickle eine eigene, synthetische Position. Dokumentiere deinen Dialog mit der KI.'

Eine weitere Dimension, die Yan et al. hervorheben, ist die Bedeutung von Feedback-Schleifen. In der konstruktiven Nutzung ist die Interaktion mit der KI nicht linear (Frage → Antwort → Fertig), sondern iterativ und zyklisch (Frage → Antwort → Reflexion → Rückfrage → Vertiefung → Synthese). Diese Iterationen sind kognitive Arbeit – sie erfordern Zeit, Anstrengung und die Bereitschaft, auch frustrierende Sackgassen zu durchlaufen. Bildungssysteme, die unter Zeitdruck stehen und primär auf schnelle Resultate fokussiert sind, unterlaufen genau diese iterative Qualität. Ein Schüler, der bis morgen einen Essay abgeben muss, hat keinen Anreiz, mehrere Versionen mit der KI zu durchlaufen und jede kritisch zu reflektieren – er nimmt die erste halbwegs plausibel klingende Version. Die Förderung konstruktiver KI-Nutzung erfordert daher auch eine Entschleunigung von Lernprozessen und eine Bewertung des Prozesses, nicht nur des Produkts.

Abschließend ist festzuhalten, dass die Dichotomie prozedural/konstruktiv nicht als binär, sondern als Kontinuum zu verstehen ist. Reale Nutzungsweisen bewegen sich zwischen den Polen, und dieselbe Person kann in unterschiedlichen Kontexten unterschiedlich agieren (konstruktiv im Fach, das ihr liegt; prozedural im Fach, das sie hasst). Die pädagogische Herausforderung besteht darin, die Waagschale systematisch in Richtung konstruktiver Nutzung zu verschieben – durch explizite Schulung, durch Modellierung, durch Aufgabendesign und durch eine Lernkultur, die kritisches Hinterfragen belohnt statt blindes Vertrauen in technologische Autorität.

Teil III: Empirische Evidenz und Bildungsgerechtigkeit

4. Empirische Evidenz: Der 'Krücken-Effekt' und die Ambivalenz der Assistenz

Nach der theoretischen Fundierung wenden wir uns nun der empirischen Evidenz zu, die in den Jahren 2024 und 2025 eine bemerkenswerte Reifung erfahren hat. Während die frühen Diskussionen über KI im Bildungsbereich primär spekulativ oder anekdotisch waren, liegen mittlerweile methodisch robuste Studien vor, die präzise quantifizieren, unter welchen Bedingungen KI-Assistenz lernförderlich wirkt und wann sie zum kognitiven Hindernis wird. Im Zentrum dieser empirischen Wende steht eine Großstudie, die aufgrund ihrer methodischen Rigorosität und ihrer klaren Befunde als Meilenstein gelten kann.

4.1 Die PNAS-Studie von Bastani et al.[11]: Methodisches Design und zentrale Befunde

Im Januar 2025 publizierten Hamsa Bastani von der Wharton School und ihre Kollegen in den Proceedings of the National Academy of Sciences eine Studie, die als erste wirklich großangelegte randomisierte Kontrollstudie (RCT) die Auswirkungen von KI-Tutoring im Mathematikunterricht untersuchte. Der Titel 'Generative AI without guardrails can harm learning' ist programmatisch und antizipiert bereits das zentrale Ergebnis. Die Studie umfasste fast 1.000 High-School-Schüler aus verschiedenen Schulen in den USA, die über einen Zeitraum von sechs Wochen beim Lernen algebraischer Konzepte begleitet wurden. Die methodische Stärke liegt in der experimentellen Kontrolle: Die Teilnehmer wurden zufällig drei Gruppen zugeordnet, wodurch Selektionseffekte ausgeschlossen werden konnten.

Die erste Gruppe, die Kontrollgruppe, lernte auf traditionelle Weise: Sie erhielten Unterricht durch Lehrkräfte, bearbeiteten Übungsaufgaben in Lehrbüchern und konnten bei Verständnisproblemen ihre Lehrer oder Mitschüler um Hilfe bitten – der Standard-Modus des Mathematikunterrichts. Die zweite Gruppe, bezeichnet als 'GPT Base', erhielt zusätzlich zum regulären Unterricht unbeschränkten Zugang zu einer Standard-Version von GPT-4, die ähnlich wie das öffentlich verfügbare ChatGPT operierte. Die Schüler konnten das System jederzeit konsultieren, Aufgaben eingeben und Lösungen anfordern. Entscheidend ist: Das System war nicht instruiert, Lösungen zu verweigern oder pädagogisch zu rahmen – es antwortete auf jede mathematische Frage mit der technisch korrekten Lösung, inklusive vollständiger Rechenwege.

---

[11] Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences*, 122(26), e2422633122. https://doi.org/10.1073/pnas.2422633122

Die dritte Gruppe, 'GPT Tutor', erhielt Zugang zu einer modifizierten Version von GPT-4, die durch sorgfältiges Prompt Engineering mit strikten 'Guardrails' – Sicherheitsleitplanken – ausgestattet war. Der System-Prompt dieser Version enthielt explizite Anweisungen, niemals die vollständige Lösung preiszugeben, sondern stattdessen nach der sokratischen Methode vorzugehen: auf Fragen mit Gegenfragen zu reagieren, die den Schüler zum Nachdenken anregen, schrittweise Hinweise zu geben, die von Lehrern vorab für spezifische Aufgabentypen definiert wurden, und den Schüler zu ermutigen, selbst weiterzudenken. Ein Beispiel: Fragt ein Schüler 'Wie löse ich die Gleichung 2x + 5 = 13?', würde GPT Base antworten: 'Die Lösung ist x = 4. Begründung: 2x + 5 = 13, subtrahiere 5 auf beiden Seiten: 2x = 8, teile durch 2: x = 4.' GPT Tutor hingegen würde antworten: 'Lass uns gemeinsam überlegen. Was müsstest du als ersten Schritt tun, um die Gleichung zu vereinfachen? Schau dir die linke Seite an: Was würde passieren, wenn du auf beiden Seiten dieselbe Operation durchführst?'

Die Studie war in zwei Phasen strukturiert: eine sechswöchige Übungsphase, in der die Schüler kontinuierlich mit ihrem jeweiligen Setup arbeiteten, gefolgt von einer Testphase, in der alle Gruppen ohne jegliche KI-Unterstützung dieselben standardisierten Mathematikaufgaben lösen mussten. Diese Trennung ist methodisch entscheidend, denn sie erlaubt die Unterscheidung zwischen Performance (Leistung während der Nutzung von Hilfsmitteln) und Kompetenz (eigenständige Fähigkeit nach Entzug der Hilfsmittel). Genau diese Differenzierung offenbarte die dramatischen Unterschiede zwischen den Interventionen.

In der Übungsphase zeigte sich zunächst ein erwartetes Muster: Beide KI-Gruppen übertrafen die Kontrollgruppe deutlich in der Lösungsrate und Geschwindigkeit. Die GPT Base-Gruppe verbesserte ihre Performance um 48% gegenüber dem Ausgangsniveau, die GPT Tutor-Gruppe sogar um beeindruckende 127%. Dieser massive Unterschied zwischen den beiden KI-Gruppen erklärt sich durch die unterschiedliche Interaktionsqualität: Während GPT Base den Schülern erlaubte, durch schnelles Copy-Paste von Aufgaben sofort zu korrekten Lösungen zu gelangen, zwang GPT Tutor sie in einen elaborierteren Dialog, der zwar zeitintensiver war, aber zu einem tieferen Verständnis der Lösungsschritte führte. Oberflächlich betrachtet schienen beide Systeme hocheffektiv – die Schüler lösten mehr Aufgaben, machten weniger Fehler, zeigten höhere Motivation.

Die Testphase jedoch zeichnete ein fundamental anderes Bild. Als den Schülern die KI-Unterstützung entzogen wurde und sie eigenständig mathematische Probleme lösen mussten, brach die Performance der GPT Base-Gruppe dramatisch ein. Sie schnitten im Durchschnitt 17% schlechter ab als die Kontrollgruppe, die niemals KI-Zugang gehabt hatte. Dies ist ein alarmierender Befund: Die unreglementierte Nutzung von KI führte nicht nur zu keinem Lerngewinn, sondern zu einer messbaren Verschlechterung der autonomen Problemlösefähigkeit. Die GPT Tutor-Gruppe hingegen zeigte keine signifikante Abweichung von der Kontrollgruppe – weder positiv noch negativ. Das Guardrail-System hatte den Schaden verhindert, aber auch keinen

zusätzlichen Lernvorteil gegenüber traditionellem Lernen generiert, trotz der massiven Performance-Steigerung während der Übungsphase.

Um die Mechanismen hinter diesen Unterschieden zu verstehen, analysierten Bastani et al. die Chat-Protokolle aller Interaktionen zwischen Schülern und KI. Diese qualitative Analyse offenbarte klare Verhaltensmuster. Schüler der GPT Base-Gruppe zeigten eine starke Tendenz zum 'Cognitive Offloading' – sie kopierten Aufgaben wortwörtlich in das Interface, erhielten sofortige Lösungen und übertrugen diese in ihre Hausaufgaben, ohne die Lösungsschritte nachzuvollziehen. In den Protokollen finden sich Sequenzen wie: Schüler gibt ein 'Solve: $3x^2 - 12x + 9 = 0$', KI antwortet mit vollständiger Lösung, Schüler gibt nächste Aufgabe ein. Kein Rückfragen, keine Verständnischecks, keine Reflexion. Die KI wurde als automatisierter Lösungslieferant genutzt, nicht als Lernwerkzeug. Dieser Nutzungsmodus korrespondiert präzise mit der 'prozeduralen Nutzung', die Yan et al. beschrieben haben.

Die GPT Tutor-Gruppe zeigte ein völlig anderes Interaktionsmuster. Die erzwungene sokratische Dialogführung resultierte in längeren, iterativen Austauschen. Ein typisches Protokoll zeigt: Schüler stellt Frage, KI gibt Hinweis, Schüler probiert Ansatz, macht Fehler, KI korrigiert nicht direkt sondern fragt nach ('Bist du sicher, dass dieser Schritt korrekt ist? Überprüfe die Vorzeichen'), Schüler korrigiert sich selbst, KI bestätigt und gibt nächsten Hinweis. Dieser Prozess simuliert effektiv die 'Desirable Difficulties' – die Schüler mussten kognitiv arbeiten, Fehler wurden nicht eliminiert sondern als Lerngelegenheiten genutzt, die Kontrolle über den Lösungsweg blieb beim Lernenden.

Dennoch – und dies ist eine kritische Nuance – verhinderte selbst der GPT Tutor keinen vollständigen Transfer vom KI-assistierten zum autonomen Problemlösen. Die Tatsache, dass diese Gruppe im Test nicht besser abschnitt als die Kontrollgruppe, obwohl sie in der Übungsphase so überragend performte, deutet darauf hin, dass die Präsenz der KI – selbst in pädagogisch optimierter Form – eine Abhängigkeit schafft. Schüler gewöhnen sich an die sofortige Verfügbarkeit von Hilfestellungen, an die geduldige Fehlertoleranz des Systems, an die kleinschrittigen Anleitungen. Wenn diese externe Stütze wegfällt, müssen sie auf eigene metakognitive Ressourcen zurückgreifen, die möglicherweise unterentwickelt blieben, weil das System diese Funktionen übernommen hatte.

Bastani et al. bezeichnen das Phänomen in der GPT Base-Gruppe als 'Crutch Effect' – den Krücken-Effekt. Die Metapher ist treffend: Eine Krücke unterstützt jemanden mit verletztem Bein beim Gehen, aber wenn die Krücke zur Dauereinrichtung wird, verkümmert die Muskulatur des Beins. Die KI fungierte als kognitive Krücke, die den Schülern half, Aufgaben zu 'lösen', aber gleichzeitig verhinderte, dass sie die mentalen Muskeln aufbauten, die für autonomes mathematisches Denken notwendig sind. Diese Atrophie ist nicht sofort sichtbar – während der Übungsphase erscheinen die

Schüler kompetent, erfolgreich, vielleicht sogar fortgeschrittener als ihre Peers. Die Illusion platzt erst, wenn die Prüfungssituation ohne Krücke eintritt.

Die bildungspolitischen Implikationen dieser Studie sind enorm. Sie legt nahe, dass die gegenwärtige Praxis in vielen Schulen – wo Schüler Zugang zu unreglementierten ChatGPT-Accounts haben und diese für Hausaufgaben nutzen – nicht nur ineffektiv, sondern aktiv schädlich sein könnte. Die vermeintliche 'Demokratisierung' des Zugangs zu KI-Tutoren, die von EdTech-Befürwortern gefeiert wird, erweist sich als zweischneidiges Schwert: Sie demokratisiert Zugang zu korrekten Lösungen, aber nicht zu echtem Verständnis. Und da Prüfungen typischerweise ohne KI-Zugang stattfinden, werden genau jene Schüler benachteiligt, die während des Lernens am stärksten auf unreglementierte KI gesetzt haben – eine perverse Ironie.

4.2 Kognitive Verflachung in verbalen Domänen: Die Georgiou-Studie[12]

Während die Bastani-Studie sich auf mathematische Problemlösung konzentrierte, untersuchte Panayiota Georgiou von der Cyprus University of Technology eine komplementäre Domäne: das argumentative Schreiben. Ihre 2025 publizierte Studie 'ChatGPT produces more lazy thinkers: Evidence of cognitive engagement decline' adressiert die Frage, wie sich die Nutzung generativer KI auf die Qualität und Tiefe des Denkens beim Verfassen von Essays auswirkt. Die Studie ist kleiner (N=40) und methodisch weniger robust als die PNAS-Untersuchung, bietet aber wertvolle qualitative Einblicke in einen Bereich, der für die geisteswissenschaftliche Bildung zentral ist.

Georgiou rekrutierte 40 Linguistik-Studierende und teilte sie in zwei Gruppen: eine Kontrollgruppe, die einen argumentativen Essay über ein kontroverses Thema (Klimapolitik) ohne technologische Hilfsmittel verfassen sollte, und eine experimentelle Gruppe, die ChatGPT zur Unterstützung nutzen durfte. Die Aufgabenstellung war bewusst offen formuliert, um verschiedene Nutzungsweisen zu erlauben – von der Ideenfindung über die Strukturierung bis zur finalen Formulierung. Nach Abschluss der Schreibaufgabe füllten alle Teilnehmer einen von Georgiou entwickelten Fragebogen aus: die 'Cognitive Engagement Scale for AI' (CES-AI), ein psychometrisches Instrument zur Messung verschiedener Dimensionen kognitiver Involviertheit.

Die CES-AI erfasst drei zentrale Konstrukte: Deep Processing (tiefe Verarbeitung) misst, inwieweit die Person aktiv über die Bedeutung, Implikationen und Zusammenhänge des Themas nachgedacht hat, anstatt oberflächlich Informationen zu sammeln. Effortful Thinking (anstrengendes Nachdenken) erfasst die subjektiv empfundene kognitive Anstrengung und die Bereitschaft, schwierige Gedankengänge zu durchlaufen. Strategic Engagement (strategisches Engagement) misst die metakognitive Planung und Überwachung des Schreibprozesses – also ob die Person bewusst Strategien wählt, den eigenen Fortschritt monitort und bei Bedarf anpasst. Jede Dimension wird durch mehrere Items erfasst, die auf Likert-Skalen beantwortet werden.

Die Ergebnisse zeigen signifikante Unterschiede: Die KI-Gruppe berichtete durchweg niedrigere Werte auf allen drei Dimensionen. Beim Deep Processing zeigte sich, dass KI-Nutzer weniger Zeit damit verbrachten, eigene Argumente zu entwickeln, Gegenargumente zu antizipieren oder die logische Konsistenz ihrer Position zu überprüfen. Stattdessen tendierten sie dazu, von ChatGPT generierte Argumentationslinien zu übernehmen und anzupassen. Die qualitative Analyse der Schreibprotokolle offenbarte, dass viele KI-Nutzer folgenden Workflow hatten: Prompt an ChatGPT ('Write an essay arguing that climate policy should prioritize economic growth'), Erhalt eines

[12] Georgiou, G. P. (2025). ChatGPT produces more 'lazy' thinkers: Evidence of cognitive engagement decline. *arXiv preprint* arXiv:2507.00181. https://arxiv.org/abs/2507.00181

fertigen Essays, selektives Kopieren von Absätzen, kosmetische Anpassungen (Umformulierung einzelner Sätze, um Plagiatserkennung zu umgehen), Abgabe. Die kognitive Arbeit der Argumentation – das Ringen um Präzision, das Abwägen von Evidenz, die Antizipation von Einwänden – wurde externalisiert.

Beim Effortful Thinking war der Befund ähnlich eindeutig. Die Kontrollgruppe berichtete, dass das Schreiben anstrengend, zeitintensiv und manchmal frustrierend war – klassische Anzeichen kognitiver Anstrengung. Die KI-Gruppe hingegen beschrieb den Prozess als 'einfach', 'effizient' und 'stressfrei'. Oberflächlich mag dies positiv klingen, aber aus lernpsychologischer Perspektive ist es alarmierend: Es signalisiert genau jene Elimination der 'Desirable Difficulties', die wir als problematisch identifiziert haben. Einer der Teilnehmer formulierte es explizit: 'Ich musste nicht wirklich nachdenken, die KI hatte schon alles durchdacht. Ich war eher wie ein Editor, der den Text poliert.' Diese Selbstwahrnehmung – vom Autor zum Editor – ist bezeichnend für die Rollenverschiebung, die KI induziert.

Das Strategic Engagement schließlich erfasst metakognitive Prozesse: Habe ich mir Zwischenziele gesetzt? Habe ich meinen Text während des Schreibens kritisch gelesen und revidiert? Habe ich bewusst nach schwachen Stellen in meiner Argumentation gesucht? Die KI-Gruppe zeigte signifikant niedrigere Werte, was darauf hindeutet, dass die Verantwortung für Kohärenz, Struktur und Qualitätskontrolle implizit an die KI delegiert wurde. Wenn ChatGPT einen strukturierten, kohärenten Text liefert, erscheint eigene metakognitive Überwachung überflüssig – schließlich hat das System bereits für logische Übergänge, konsistente Argumentation und sprachliche Präzision gesorgt. Diese Delegation ist jedoch problematisch, weil genau diese metakognitiven Fähigkeiten – die Fähigkeit zur Selbstkritik, zur Revision, zur strategischen Planung – Kernkompetenzen akademischen Schreibens darstellen, die über den konkreten Essay hinaus transferierbar sind.

Georgiou prägte für dieses Phänomen den Begriff 'Lazy Thinking' – nicht im moralisch wertenden Sinne von 'Faulheit', sondern als deskriptive Kategorie für einen Denkmodus, der den Weg des geringsten kognitiven Widerstands wählt. Es ist wichtig zu betonen, dass dieses 'Lazy Thinking' nicht notwendigerweise mit schlechteren Textprodukten korreliert. Die externen Evaluatoren, die die Essays beider Gruppen blind bewerteten (ohne zu wissen, ob KI genutzt wurde), fanden keine signifikanten Qualitätsunterschiede in Bezug auf Argumentation, Struktur oder Sprache. Die KI-generierten oder KI-assistierten Essays waren ebenso gut – manchmal sogar besser – als die rein menschlich verfassten. Dies macht das Problem so tückisch: Die Performanz ist hochwertig, aber die zugrundeliegende Kompetenzentwicklung findet nicht statt.

Eine methodische Limitation der Georgiou-Studie muss jedoch kritisch angemerkt werden: Die Messung erfolgte primär über Selbstberichte. Die CES-AI erfasst, wie die Teilnehmer ihre eigene kognitive Involviertheit wahrnehmen, nicht objektive Maße

kognitiver Anstrengung (wie etwa neuronale Aktivierung oder Blickbewegungen). Es ist bekannt, dass Menschen ihre eigene Kompetenz oft überschätzen, wenn sie mit flüssig verarbeitbaren Informationen konfrontiert sind – ein Phänomen, das als 'Illusion of Competence' oder 'Fluency Illusion' bekannt ist. Ein Student, der einen eloquenten, KI-generierten Text liest, könnte sich kognitiv involviert fühlen, obwohl er objektiv nur rezipiert, nicht produziert. Dennoch sind die Befunde konsistent mit anderen Studien und mit der theoretischen Erwartung, sodass sie trotz dieser Limitation als valider Hinweis auf kognitive Verflachung gelten können.

Die Implikationen für den Schreibunterricht sind weitreichend. Traditionell wurde akademisches Schreiben als Denkinstrument konzipiert – der Prozess des Formulierens zwingt zur Klärung vager Gedanken, das Ringen um präzise Sprache schärft das Konzept, die Notwendigkeit, Argumente logisch zu sequenzieren, deckt Widersprüche auf. Dieser epistemologische Wert des Schreibens wird untergraben, wenn der Text primär von einer KI generiert wird. Der Student übt dann nicht mehr 'Denken durch Schreiben', sondern 'Kuratieren von KI-Outputs' – eine durchaus wertvolle Fähigkeit, aber eine fundamental andere als die des eigenständigen argumentativen Denkens.

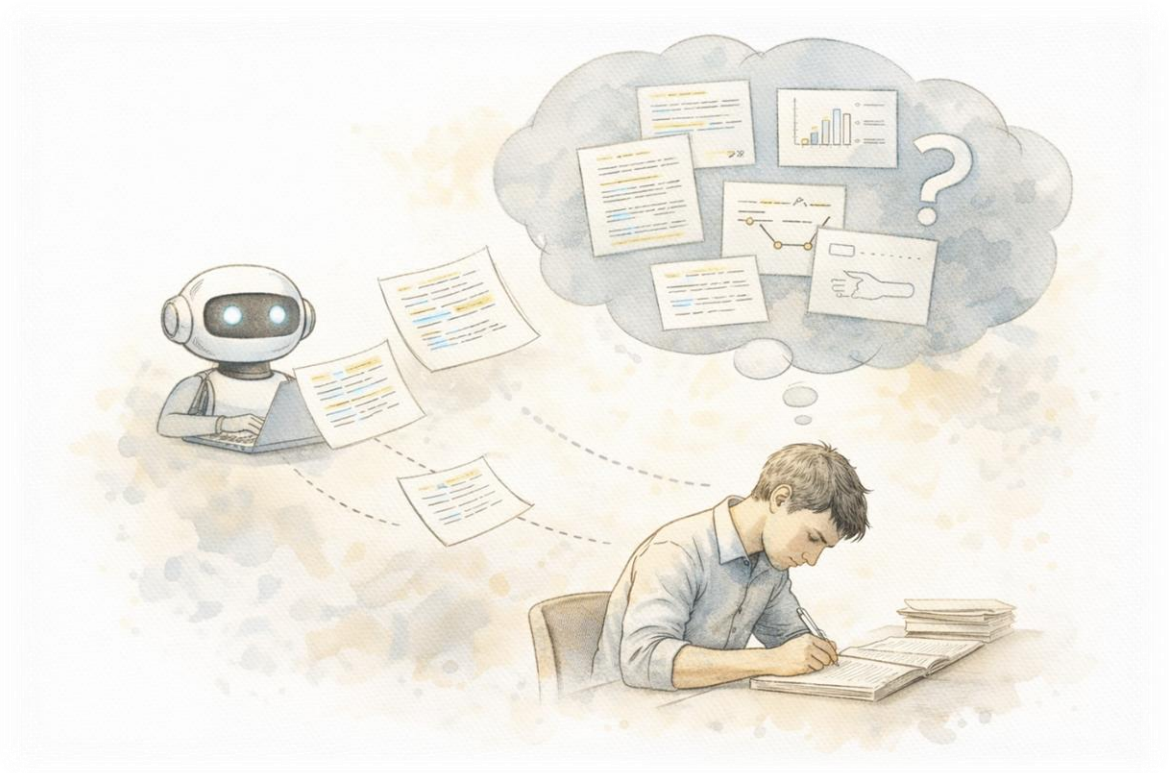

4.3 Transfer-Problematik in der Informatikausbildung: Die Vivian-Studie[13]

Eine dritte empirische Perspektive eröffnet die Arbeit von Vivian aus dem Jahr 2025, die sich mit der spezifischen Domäne der Informatikausbildung beschäftigt. Die Studie 'Coding with ChatGPT: Empirical Evidence of Cognitive Offloading in Computer Science Education' untersuchte an einer mittelgroßen Universität über ein Semester hinweg 151 Studierende eines Einführungskurses in Python-Programmierung. Die zentrale Forschungsfrage war simpel, aber aufschlussreich: Wie stark korreliert die Leistung von Studierenden bei Programmieraufgaben, die sie mit ChatGPT-Unterstützung lösen, mit ihrer Leistung bei identischen oder ähnlichen Aufgaben, die sie ohne KI lösen müssen?

In traditionellen Lernkontexten – etwa in einem Mathematik- oder Physikkurs – findet man typischerweise starke positive Korrelationen zwischen Übungsleistung und Prüfungsleistung. Studierende, die in den Hausaufgaben gut abschneiden, performen in der Regel auch gut in der Klausur, weil die Hausaufgaben als Lernvehikel fungieren: Sie zwingen zur aktiven Auseinandersetzung mit dem Material, decken Verständnislücken auf und konsolidieren Wissen. Korrelationen von $r = 0.6$ bis 0.8 sind hier üblich. Vivians Studie fand eine extrem schwache Korrelation von $r \approx 0.15$ zwischen KI-assistierten Hausaufgaben und autonomen Prüfungen – statistisch kaum von null unterscheidbar.

Konkret bedeutet dies: Ein Student konnte alle Programmieraufgaben der Hausaufgaben korrekt lösen (mit Hilfe von ChatGPT) und dennoch in der Prüfung vollständig scheitern, weil er die fundamentalen Konzepte nicht internalisiert hatte. Umgekehrt gab es Studierende, die in den Hausaufgaben moderate Leistungen zeigten (weil sie bewusst auf KI verzichteten oder sie nur minimal nutzten) und in der Prüfung exzellent abschnitten. Die Hausaufgabenleistung war kein Prädiktor mehr für die Prüfungsleistung – ein fundamentaler Bruch der didaktischen Logik, die Hausaufgaben als formativer Assessment und Lernaktivität zugrunde liegt.

Vivian führte zusätzlich qualitative Interviews mit einer Teilstichprobe durch, um die zugrundeliegenden Nutzungsmuster zu verstehen. Die Befunde zeigen ein Spektrum von Nutzungsweisen, das von hochkonstruktiv bis rein prozedural reicht. Auf der konstruktiven Seite berichteten einige Studierende, dass sie ChatGPT als 'Debugging-Partner' nutzten: Sie schrieben Code selbst, testeten ihn, und wenn Fehler auftraten, die sie nicht verstanden, analysierten sie gemeinsam mit ChatGPT die Fehlerquelle. Charakteristisch für diese Gruppe war, dass sie den von ChatGPT vorgeschlagenen Code nicht blind übernahmen, sondern jeden Schritt nachvollziehen wollten ('Warum verwendest du hier eine for-Schleife statt einer while-Schleife? Was ist der Vorteil?').

---

[13] Vivian, R. (2025). Coding with ChatGPT: Empirical Evidence of Cognitive Offloading in Computer Science Education. *Clareus Scientific Science and Engineering*, 2(10), 10–19. https://clareus.org/journals/csse/CSSE-02-062

Diese Studierenden entwickelten durch die KI-Interaktion ein tieferes Verständnis von Algorithmen, Datenstrukturen und Programmiermuster.

Auf der prozeduralen Seite des Spektrums standen jene Studierenden, die ChatGPT als 'Code-Generator' nutzten. Ihr typischer Workflow: Aufgabenstellung lesen, diese wortwörtlich oder leicht paraphrasiert an ChatGPT übergeben ('Write a Python function that sorts a list of integers using bubble sort'), den generierten Code kopieren, minimal anpassen (Variablennamen ändern, Kommentare hinzufügen), testen ob er funktioniert, und abgeben. Kein Versuch, den Algorithmus zu verstehen, keine Auseinandersetzung mit der Logik der Sortierung, kein Nachvollzug der Schleifenstruktur. Das Resultat: funktionierender Code, der die Hausaufgabe erfüllt, aber null Lerneffekt. Ein Student formulierte es unverblümt: 'Ich habe gelernt, wie man ChatGPT fragt, nicht wie man programmiert.'

Besonders aufschlussreich ist Vivians Beobachtung zur mentalen Modellbildung. Programmieren lernen bedeutet nicht primär, Syntax auswendig zu kennen (dies kann jederzeit nachgeschlagen werden), sondern mentale Modelle algorithmischer Prozesse zu entwickeln – die Fähigkeit, im Kopf zu simulieren, wie ein Programm Schritt für Schritt abläuft, wo potenzielle Fehlerquellen liegen, wie Datenstrukturen manipuliert werden. Diese mentalen Modelle entstehen durch aktives Coden, durch Trial-and-Error, durch das Debugging eigener Fehler. Wenn der gesamte Code von einer KI generiert wird, findet diese Modellbildung nicht statt. Der Student kann den Code ausführen und sehen, dass er funktioniert, aber er hat keine interne Repräsentation des Prozesses. Tritt später ein unvorhergesehenes Problem auf, fehlt ihm das konzeptuelle Werkzeug, um zu debuggen.

Vivian warnt vor der Entstehung einer Generation von 'Black-Box-Ingenieuren' – Absolventen, die Code generieren können (indem sie KI instruieren), aber die innere Logik nicht verstehen. Dies ist nicht nur ein akademisches Problem, sondern hat reale praktische Konsequenzen: In der Industrie müssen Programmierer nicht nur funktionierenden Code produzieren, sondern auch Legacy-Code verstehen, komplexe Systeme debuggen, Performance optimieren, Sicherheitslücken identifizieren – alles Tätigkeiten, die tiefes Verständnis erfordern. Ein Ingenieur, der nur durch Prompting KI-Code generiert, ohne die zugrundeliegenden Konzepte zu beherrschen, wird in diesen Kontexten scheitern.

Die Studie wirft auch Fragen zur Zukunft der Informatikausbildung auf. Sollten Universitäten KI-Tools in Programmierkursen verbieten? Dies scheint unrealistisch und kontraproduktiv, da die Studierenden in ihrer späteren Berufspraxis ohnehin mit KI-assistiertem Coding arbeiten werden. Sollten sie freien Zugang erlauben und die Prüfungsformate anpassen? Aber wie prüft man dann die Grundkompetenzen? Vivian schlägt einen Mittelweg vor: Sequenzielle Freigabe. In den ersten Wochen eines Kurses, wenn fundamentale Konzepte erlernt werden (Variablen, Kontrollstrukturen, Funktionen), wird KI-Nutzung untersagt, um sicherzustellen, dass die Studierenden

die Basics durch eigene Praxis internalisieren. Erst nachdem diese Grundlage gesichert ist, wird KI als Werkzeug zur Beschleunigung komplexerer Aufgaben erlaubt. Dies entspricht der Logik, dass man erst laufen lernen muss, bevor man ein Fahrrad nutzt.

Persönliche Anmerkung: Die Prüfungsfrage als blinder Fleck

Die hier referierten Studien durchzieht ein gemeinsames Muster: Der Umgang mit KI schult den Umgang mit KI – nicht aber die grundlegenden Fähigkeiten zur Bewältigung der jeweiligen Aufgaben. Dies erweist sich dann in Prüfungen als negativ, weil diese Prüfungen eben jene grundlegenden Fähigkeiten abfragen, nicht die KI-Kompetenz. Zwar räumen die Autoren ein, dass Effizienz bei der KI-Nutzung ein eigenständiger Wert sein kann, doch wird kaum hinterfragt, ob dann nicht auch die KI-gestützte Aufgabenbewältigung ein sinnvollerer Prüfungsgegenstand wäre.

Besonders bei der Vivian-Studie zur Informatikausbildung drängt sich mir eine ketzerische Frage auf: Wurde das Verflachen elementarer Programmierfähigkeiten nicht schon immer durch die Entwicklung neuer Programmierwerkzeuge verursacht – und war dies letztendlich gar nicht schädlich?

Die Geschichte der Programmiersprachen ist eine Geschichte fortschreitender Abstraktion. Die erste Generation – Maschinencode – erforderte das direkte Schreiben von Binärziffern, die der Prozessor unmittelbar ausführte. Die zweite Generation – Assembler – führte mnemonische Kürzel ein: Statt „10110000 01100001“ schrieb man „MOV AL, 61h“. Die dritte Generation – Hochsprachen wie FORTRAN, C oder Pascal – abstrahierte von der Hardware und erlaubte Anweisungen wie „print(message)“. Eine weitere Generation – domänenspezifische Sprachen wie SQL oder MATLAB – entfernte sich noch weiter vom maschinellen Denken und näherte sich dem problemorientierten Denken: Man beschreibt das gewünschte Ergebnis, nicht mehr den Weg dorthin.

Jede neue Generation wurde von der vorherigen als Verfallserscheinung beklagt. Assembler-Programmierer beklagten, dass Hochsprachen-Nutzer die Hardware nicht mehr verstünden. C-Programmierer beklagten, dass Java-Entwickler keine Speicherverwaltung mehr beherrschten. Und heute beklagen wir, dass Studierende mit ChatGPT keine sauberen Python-Funktionen mehr schreiben können.

Doch die empirische Realität ist: Praktisch niemand ist heute mehr in der Lage, ein hinreichend komplexes Programm in Maschinencode oder auch Assembler zu schreiben. Nicht weil die Menschen dümmer geworden wären, sondern weil es nicht mehr notwendig ist. Die höheren Programmiersprachen haben diese Notwendigkeit auf den Compiler verlagert – einen Algorithmus, der die Übersetzung übernimmt. Die kognitiven Ressourcen, die früher für das Memorieren von Opcodes aufgewendet wurden, können nun für architektonische Entscheidungen, Nutzererfahrung und Problemlösung verwendet werden.

Was wäre, wenn generative KI eine ähnliche Epochenschwelle markiert? Wenn sich das Programmieren auf die Instruktion einer KI verlagert, die den formalen Code generiert, entstünde de facto eine weitere Generation von Programmiersprachen – eine, die die formale Beherrschung einer Syntax nicht mehr erfordert, sondern natürlichsprachliche Intentionen in funktionierenden Code übersetzt. Die Klage über „verflachende Programmierfähigkeiten“ wäre dann strukturell identisch mit der Klage der Assembler-Generation über die FORTRAN-Nutzer.

Diese Spekulation ist seit der Einführung von Claude Code und vergleichbaren Systemen keine reine Theorie mehr. Viele professionelle Entwickler berichten, dass sie sich bereits in der Rolle des „Bedieners einer KI“ wiederfinden – nicht weil sie ihre Kompetenz verloren hätten, sondern weil die Coding-Kompetenz dieser Systeme inzwischen die der meisten Menschen übersteigt. Ein erfahrener Entwickler verbringt heute oft mehr Zeit damit, präzise zu formulieren, was ein Programm tun soll, als damit, die Implementierung selbst zu schreiben. Die KI übernimmt das „Wie“, der Mensch konzentriert sich auf das „Was“ und das „Warum“.

Ironischerweise würde eine solche Entwicklung dazu führen, dass im Programmierberuf etwas Ähnliches passiert wie im Lehrerberuf: Die Fähigkeit, korrekten Code zu schreiben, wird unwichtiger; stattdessen wird es bedeutsamer zu antizipieren, was der Nutzer von einem Programm erwartet, wie sein Erlebnis verbessert werden kann, welche Edge Cases bedacht werden müssen. Der Programmierer der Zukunft wäre weniger Syntax-Virtuose und mehr Produktdesigner, Empathiker, Architekt. Die „soft skills“ – das Verstehen menschlicher Bedürfnisse, die Kommunikation mit Stakeholdern, das Denken in Systemen – würden gegenüber den „hard skills“ der formalen Codierung aufgewertet.

Dass diese Entwicklung keine ferne Zukunftsvision ist, zeigt Google Antigravity[14] – eine im November 2025 vorgestellte Entwicklungsumgebung, deren Name programmatisch ist. Google beschreibt die Philosophie so: „Die Werkzeuge von gestern halfen dir, schneller Code zu schreiben; die Werkzeuge von morgen müssen dir helfen, ihn zu orchestrieren." Antigravity ist als „agent-first platform" konzipiert: Die KI ist nicht mehr Werkzeug zum Codeschreiben, sondern autonomer Akteur, der komplexe Engineering-Aufgaben mit minimaler menschlicher Intervention plant, ausführt und validiert. Der menschliche Entwickler wird zum Orchestrator, der Agenten instruiert und deren Arbeit koordiniert – nicht mehr zum Autor jeder einzelnen Codezeile. Wenn einer der größten Technologiekonzerne der Welt seine Entwicklerwerkzeuge explizit auf diese Zukunft ausrichtet, sollte das Bildungssystem zumindest die Frage stellen, ob seine Prüfungsformate noch die richtigen Kompetenzen messen.

---

[14] Google Antigravity Team (2025). Build with Google Antigravity, our new agentic development platform. *Google Developers Blog*, 20. November 2025. https://developers.googleblog.com/build-with-google-antigravity-our-new-agentic-development-platform/

Ob diese Vision wünschenswert ist, bleibt offen. Die Sorge, dass fundamentale algorithmische Kompetenz verloren geht, ist nicht unberechtigt – wer Code nicht mehr lesen und verstehen kann, ist der KI ausgeliefert und kann Fehler nicht selbst korrigieren. Doch die Geschichte der Technologie lehrt auch: Jede Automatisierung von Routinefähigkeiten hat neue, komplexere Fähigkeiten ermöglicht. Die Frage ist nicht, ob sich Kompetenzprofile wandeln, sondern wie wir diesen Wandel gestalten – und ob unsere Prüfungsformate mit ihm Schritt halten.

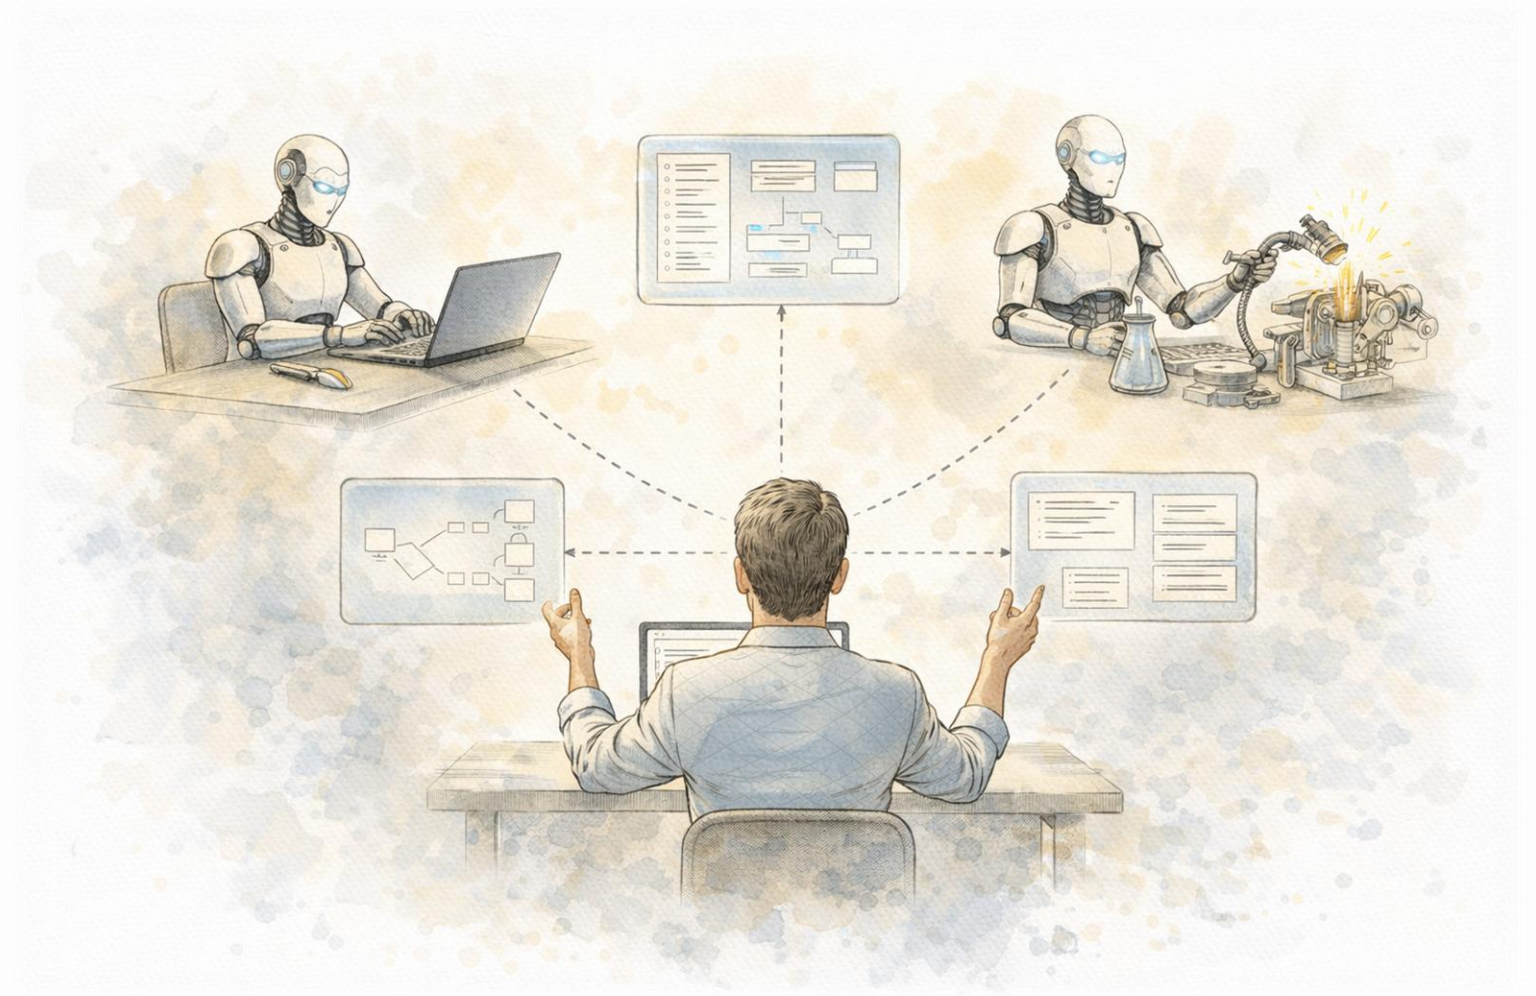

5. Der Mythos des 'Equalizers': Bildungsungerechtigkeit im neuen Gewand

Eine der persistentesten Hoffnungen, die mit dem Einsatz von KI in der Bildung verbunden werden, ist ihre potenzielle Rolle als 'großer Gleichmacher' – als Technologie, die strukturelle Ungleichheiten in den Lernmöglichkeiten ausgleichen könnte. Die Vision ist verführerisch: Wenn jeder Schüler, unabhängig von sozioökonomischem Hintergrund, Zugang zu einem nahezu unbegrenzt geduldigen, hochkompetenten KI-Tutor hat, könnten die Bildungschancen demokratisiert werden. Schüler aus bildungsfernen Elternhäusern, die keine teure Nachhilfe bezahlen können, hätten dieselbe Unterstützung wie privilegierte Peers. Die empirische Evidenz der letzten zwei Jahre zeichnet jedoch ein weitaus komplexeres, teils ernüchterndes Bild.

5.1 Notenverzerrung ohne Kompetenzgewinn: Die Statistik-Fallstudie von Dunn

Peter K. Dunn von der University of the Sunshine Coast in Australien lieferte 2025 mit seiner Fallstudie 'Generative AI may impact students' marks: A case study from a large first-year statistics course'[15] eine der ersten systematischen Analysen der realen Auswirkungen von KI auf Bewertungen in einem Massenkurs. Die Studie untersuchte einen großen Einführungskurs in Statistik mit mehreren hundert Studierenden über drei Jahre hinweg: die Jahre 2021-2022 als Baseline (vor der öffentlichen Verfügbarkeit von ChatGPT) und das Jahr 2024 als Post-KI-Periode. Der Kurs war in seiner Struktur über die Jahre stabil geblieben: wöchentliche Online-Quizzes, Hausaufgaben, Zwischenprüfungen und eine finale Abschlussprüfung.

Die deskriptive Statistik offenbarte einen dramatischen Shift: Die durchschnittlichen Noten in der finalen Abschlussprüfung stiegen von 64% (2022) auf 86% (2024) – ein Sprung von 22 Prozentpunkten. Eine solche massive Verbesserung innerhalb von zwei Jahren, ohne fundamentale Änderungen in Curriculum, Lehrmethoden oder Studierendendemographie, ist hochgradig ungewöhnlich und ließ sich nur durch einen externen Faktor erklären: den Zugang zu generativen KI-Tools, die inzwischen von einer Mehrheit der Studierenden für Hausaufgaben und Prüfungsvorbereitung genutzt wurden. Oberflächlich betrachtet könnte man dies als Erfolgsgeschichte interpretieren – die Studierenden lernen besser, verstehen mehr, schneiden besser ab. Dunns weiterführende Analysen zeigten jedoch, dass diese Interpretation zu kurz greift.

Wenn man die Studierenden in zwei Gruppen stratifizierte – jene, die den Kurs bestanden ('Passing Students') und jene, die durchfielen ('Failing Students') –, offenbarte sich ein paradoxes Muster. Die Passing Students zeigten tatsächlich Verbesserungen sowohl in der finalen Prüfung als auch in ihrer Gesamtkursnote, die kontinuierliche

[15] Dunn, P. K. (2025). Generative AI may impact students' marks: A case study from a large first-year statistics course. *Teaching Statistics*, 47(2).

Assessments (Quizzes, Hausaufgaben) einbezog. Dies deutet darauf hin, dass kompetente Studierende die KI konstruktiv nutzten – zur Vertiefung, zur Überprüfung des eigenen Verständnisses, zur effizienten Bearbeitung von Übungsaufgaben. Die Failing Students hingegen zeigten ein bizarres Muster: Ihre Prüfungsnoten verbesserten sich ebenfalls signifikant (von durchschnittlich 35% auf 48%), blieben aber unterhalb der Bestehensschwelle. Gleichzeitig verschlechterten sich ihre Gesamtkursnoten oder stagnierten auf niedrigem Niveau.

Wie ist diese Diskrepanz zu erklären? Dunn vermutet folgenden Mechanismus: Die schwächeren Studierenden nutzten KI primär, um Hausaufgaben und Quizzes zu 'lösen' – sie gaben Aufgaben an ChatGPT, kopierten die Antworten und reichten sie ein. Dies führte zu technisch korrekten Einreichungen, die jedoch kein Lernen reflektierten. In einigen Fällen wurden Hausaufgaben möglicherweise als 'automatisches Cheating' identifiziert und entsprechend sanktioniert, was die Gesamtkursnote drückte. In anderen Fällen waren die KI-generierten Hausaufgaben so offensichtlich über dem tatsächlichen Kompetenzniveau der Studierenden, dass Lehrkräfte skeptisch wurden. In der finalen Prüfung, die unter kontrollierten Bedingungen stattfand, konnten diese Studierenden zwar auch KI nutzen (da viele Universitäten mittlerweile take-home exams erlauben oder open-book-Prüfungen durchführen), aber sie waren nicht in der Lage, die Konzepte wirklich anzuwenden oder zu transferieren, weil sie sie nie verstanden hatten.

Dunns Studie illustriert einen fundamentalen Punkt: KI erhöht nicht gleichmäßig die Leistung aller Studierenden, sondern verstärkt bestehende Disparitäten. Studierende mit hohem Vorwissen, guten Lernstrategien und metakognitiven Fähigkeiten können KI als Katalysator nutzen – sie wissen, wann sie die KI um Hilfe bitten sollten, wie sie die Qualität der Outputs beurteilen, wie sie KI-Antworten in ihr bestehendes Wissensgerüst integrieren. Studierende mit niedrigem Vorwissen und schwachen Lernstrategien hingegen fallen in die Falle der prozeduralen Nutzung – sie outsourcen kognitive Arbeit, ohne zu realisieren, dass sie dadurch keine Kompetenz aufbauen. Das Resultat ist nicht Gleichheit, sondern eine neue Form der Ungleichheit: die Kluft zwischen jenen, die KI zur Augmentation nutzen können, und jenen, die sie zur Substitution missbrauchen.

5.2 Der Matthäus-Effekt: Wer hat, dem wird gegeben

Der Begriff 'Matthäus-Effekt', geprägt vom Soziologen Robert K. Merton[16] in Anlehnung an das biblische Gleichnis ('Denn wer da hat, dem wird gegeben werden'), beschreibt das Phänomen kumulativer Vorteile: Jene, die bereits über Ressourcen, Fähigkeiten oder soziales Kapital verfügen, sind besser positioniert, neue Möglichkeiten zu nutzen, wodurch sich ihre Vorteile weiter verstärken. Im Kontext der KI-Nutzung in der Bildung manifestiert sich dieser Effekt auf mehreren Ebenen.

Erstens auf der Ebene der technischen Kompetenz: Schüler aus bildungsnahen, technologieaffinen Elternhäusern haben oft früheren und kompetenteren Zugang zu digitalen Tools. Sie wachsen mit der Erwartung auf, dass Technologie gestaltbar ist, und entwickeln ein instrumentelles Verhältnis zu ihr. Wenn ChatGPT verfügbar wird, experimentieren sie, erkunden verschiedene Nutzungsweisen, entwickeln intuitiv Strategien für effektives Prompting. Schüler aus bildungsferneren Kontexten hingegen haben oft ein passiveres Verhältnis zu Technologie – sie nutzen vorgefertigte Apps, aber hinterfragen oder gestalten selten. Wenn sie auf KI stoßen, fehlt ihnen das experimentelle Mindset, um deren Potenzial voll auszuschöpfen.

Zweitens auf der Ebene des Vorwissens: Wie die Studie von Yan et al. zeigte, ist solides fachliches Vorwissen eine zentrale Voraussetzung für konstruktive KI-Nutzung. Nur wer bereits über ein konzeptuelles Fundament verfügt, kann KI-Outputs kritisch bewerten, Fehler erkennen, produktive Folgefragen stellen. Schüler mit schwachem Vorwissen – oft jene aus sozioökonomisch benachteiligten Kontexten, die bereits in früheren Bildungsphasen Defizite akkumuliert haben – sind dieser kritischen Bewertung nicht fähig. Sie vertrauen der KI blind, übernehmen falsche Antworten, verstärken Misskonzepte. Die KI, die ihnen helfen sollte aufzuholen, zementiert stattdessen ihre Rückstände.

Drittens auf der Ebene metakognitiver Kompetenzen: Selbstreguliertes Lernen – die Fähigkeit, eigene Lernziele zu setzen, Fortschritte zu monitoren, Strategien anzupassen – ist eine Fähigkeit, die stark von der familiären Sozialisation und schulischen Kultur abhängt. Schüler, deren Eltern aktiv ihre Bildung begleiten, die in Schulen mit explizitem Fokus auf Lernstrategien unterrichtet werden, entwickeln diese Kompetenzen stärker. Diese Schüler sind dann auch in der Lage, KI zielgerichtet und selbstreguliert zu nutzen. Schüler ohne diese Unterstützung hingegen nutzen KI reaktiv, ziellos, ohne Plan – mit entsprechend geringeren Lernerfolgen.

---

[16] Merton, R. K. (1968). The Matthew Effect in Science. *Science*, 159(3810), 56–63. https://doi.org/10.1126/science.159.3810.56

Eine Studie von Fischer et al. aus dem Jahr 2025, publiziert als IZA Discussion Paper[17] unter dem Titel 'AI Tutoring Enhances Student Learning Without Crowding Out Reading Effort', liefert weitere empirische Evidenz für diese differenziellen Effekte. Die Autoren untersuchten 334 Universitätsstudierende, die Zugang zu einem KI-Tutor für ein Volkswirtschaftslehre-Modul erhielten. Ein Teil der Studierenden hatte uneingeschränkten Zugang (sie konnten den KI-Tutor jederzeit konsultieren), ein anderer Teil hatte restriktiven Zugang (sie mussten zunächst das zugewiesene Lesematerial bearbeiten, bevor der Tutor freigeschaltet wurde). Die Ergebnisse zeigten, dass der restriktive Zugang zu besseren Lernergebnissen führte – die Studierenden wurden gezwungen, sich zunächst selbst mit dem Material auseinanderzusetzen, was die 'Desirable Difficulties' erhielt.

Interessanterweise fanden Fischer et al. jedoch eine signifikante Interaktion mit Vorwissen und Selbstregulation: Studierende mit niedrigem Vorwissen profitierten am meisten vom KI-Tutor – allerdings nur, wenn sie gleichzeitig hohe Selbstregulationsfähigkeiten besaßen. Diese Teilgruppe nutzte den Tutor strategisch, um Verständnislücken zu schließen, die beim Lesen aufgetreten waren. Studierende mit niedrigem Vorwissen und schwacher Selbstregulation hingegen nutzten den Tutor als Ersatz für das Lesen: Sie übersprang das Material, konsultierten direkt den Tutor und ließen sich Zusammenfassungen generieren. Das Resultat: oberflächliches Verständnis, schlechte Testleistungen. Diese Befunde unterstreichen erneut den Matthäus-Effekt: Selbst ein pädagogisch gut designter KI-Tutor ist nur für jene ein 'Equalizer', die bereits über minimale metakognitive Kompetenzen verfügen.

Die bildungspolitischen Implikationen sind unbequem: Die naive Hoffnung, dass bloßer Zugang zu KI-Tools Bildungsungleichheit reduzieren würde, ist empirisch nicht haltbar. Technologischer Zugang ist notwendig, aber nicht hinreichend. Was benötigt wird, ist eine ganzheitliche Strategie, die technischen Zugang mit der systematischen Förderung von Vorwissen, metakognitiven Kompetenzen und KI-Literalität kombiniert – und genau diese zusätzlichen Ressourcen sind in benachteiligten Kontexten oft nicht verfügbar. Das Risiko ist real, dass KI bestehende Bildungsungleichheiten nicht nur reproduziert, sondern verschärft, indem sie eine neue Trennlinie schafft: zwischen jenen, die KI als kognitives Werkzeug beherrschen, und jenen, die von ihr beherrscht werden.

[17] Fischer, S., Meub, L., Schneider, S. O., Antusch, L., & Opitz, M. (2025). AI Tutoring Enhances Student Learning Without Crowding Out Reading Effort. *IZA Discussion Paper* No. 17668. Institute for the Study of Labor, Bonn.

Teil IV: Methodische Reflexion und Plattform-Realitäten

6. Plattform-Analyse und Intelligent Tutoring Systems

Neben der akademischen Forschung existiert eine zweite Evidenzsphäre: die praktische Implementierung von KI-Tutorsystemen durch kommerzielle Anbieter und Bildungsorganisationen. Diese sogenannten Intelligent Tutoring Systems (ITS) versprechen, die theoretischen Potenziale von KI – Personalisierung, sofortiges Feedback, unbegrenzte Verfügbarkeit – in skalierbare Produkte zu übersetzen.

6.1 Khanmigo versus konventionelle Informationssuche: Die Slijepcevic-Studie

Eine der wenigen unabhängigen Evaluationen kommerzieller KI-Tutorsysteme stammt von Slijepcevic und Yaylali, die 2025 Khanmigo untersuchten – das KI-gestützte Tutorsystem der Khan Academy. Khanmigo basiert auf GPT-4 und wurde speziell für pädagogische Kontexte optimiert, mit eingebauten Guardrails nach dem Modell, das Bastani et al. als effektiv identifizierten. Die Khan Academy vermarktet es als Lösung für das Zwei-Sigma-Problem – Benjamin Blooms Beobachtung, dass individueller Einzelunterricht im Durchschnitt zwei Standardabweichungen bessere Lernergebnisse produziert als traditioneller Klassenunterricht.

Die Studie umfasste 69 Universitätsstudierende, die das astronomische Konzept der Mondphasen erlernen sollten – ein Thema, das bekanntermaßen zu persistenten Fehlvorstellungen führt. Die Teilnehmer wurden randomisiert zwei Gruppen zugeordnet: Die experimentelle Gruppe nutzte Khanmigo für 45 Minuten, während die Kontrollgruppe konventionelle Google-Suche und Wikipedia verwenden durfte. Vor und nach der Intervention absolvierten beide Gruppen das standardisierte Lunar Phases Concept Inventory (LPCI).

Das zentrale Ergebnis war ernüchternd: Es gab keinen statistisch signifikanten Unterschied zwischen den Gruppen im Lernerfolg. Beide verbesserten sich vom Pre- zum Post-Test um etwa 15%, mit überlappenden Konfidenzintervallen. Konkret: 45 Minuten mit einem hochentwickelten, millionenteuren KI-Tutor produzierten dasselbe Lernergebnis wie 45 Minuten selbstgesteuertes Googeln und Wikipedia-Lesen.

Die qualitative Komponente lieferte zusätzliche Einsichten. Viele Teilnehmer der Khanmigo-Gruppe berichteten, dass sie die Interaktion als 'hilfreich' und 'angenehm' empfanden – das System wurde als geduldig, nicht-urteilend und strukturiert wahrgenommen. Dennoch führte diese positive subjektive Erfahrung nicht zu objektiv besserem Lernen. Slijepcevic und Yaylali interpretieren dies als Hinweis auf den 'Wohlfühl-Faktor' von KI-Tutoren: Die Technologie fühlt sich fortschrittlich und personalisiert an, ohne dass diese Wahrnehmung durch messbare Outcomes validiert

wird. Dieses Auseinanderfallen von 'Perceived Usefulness' und tatsächlicher Lernwirksamkeit erklärt teilweise, warum EdTech-Produkte trotz schwacher Evidenzbasis erfolgreich vermarktet werden können.

Die Google-Gruppe hingegen empfand den Prozess als 'anstrengender' und 'frustrierender' – sie mussten aktiv nach Informationen suchen, Quellen vergleichen, relevante von irrelevanten Inhalten trennen. Genau diese kognitive Anstrengung könnte jedoch – im Sinne der Desirable Difficulties – den Lerneffekt produziert haben, der dem der KI-Gruppe entsprach.

Die Studie wirft grundsätzliche Fragen zur Evaluation von ITS auf: Welche Outcomes sollten gemessen werden? Kurzfristiges Faktenwissen ist nur eine Dimension von Lernen. Transfer, langfristige Retention und die Entwicklung von Lernstrategien würden längere Follow-up-Studien erfordern. Auch Interaktionseffekte – etwa ob bestimmte Lernertypen stärker von ITS profitieren – konnten aufgrund der Stichprobengröße nicht untersucht werden.

6.2 Die Evidenzkrise der EdTech-Forschung

Im Kontrast zu den nüchternen Befunden unabhängiger Forschung stehen die glänzenden Erfolgsmeldungen der Industrie. Duolingo verkündet dramatische Verbesserungen der Sprechkompetenz durch neue KI-Features; die Khan Academy publiziert regelmäßig Case Studies mit begeisterten Testimonials und selektiven Statistiken über Nutzungsraten. Das grundlegende Problem dieser Berichte ist evident: Sie sind nicht peer-reviewed, basieren auf unkontrollierten Beobachtungen, selektieren positive Ergebnisse und unterliegen fundamentalen Interessenkonflikten.

Diese Problematik ist kein Vorwurf individueller Unredlichkeit, sondern eine systemische Eigenschaft: Ein Unternehmen, dessen Geschäftsmodell auf dem Verkauf von KI-gestützten Subscriptions basiert, hat keinen Anreiz, Studien zu veröffentlichen, die ihr Produkt als ineffektiv ausweisen. Marketing maskiert sich als Wissenschaft.

Publication Bias und Finanzierungseffekte. Die Analyse der Finanzierung offenbart eine klare Trennlinie: Kritische Studien mit negativen oder gemischten Befunden – wie jene von Bastani, Fischer, Georgiou, Slijepcevic oder Vivian – stammen überwiegend aus universitären Kontexten und wurden durch öffentliche Forschungsgelder finanziert. Diese Autoren haben keinen finanziellen Anreiz, bestimmte Produkte positiv darzustellen; im akademischen System wird kritische Skepsis sogar honoriert.

Eine Meta-Analyse von Cheung und Slavin[18] aus dem Jahr 2024 quantifiziert diesen Effekt präzise: Die Auswertung von 87 Studien zu digitalen Leseinterventionen fand eine durchschnittliche Effektstärke von lediglich $d=0.16$ – ein praktisch kaum bedeutsamer Effekt. Aufschlussreich ist die Moderatoranalyse: Industriefinanzierte Studien zeigten systematisch höhere Effekte ($d=0.28$) als unabhängige Studien ($d=0.09$). Diese Diskrepanz ist ein klassisches Zeichen für Publication Bias und methodische Verzerrungen, nicht für tatsächlich bessere Produkte.

Industriefinanzierte Forschung unterliegt anderen Anreizstrukturen. Wenn ein Unternehmen Millionen in die Entwicklung eines KI-Tutors investiert hat, besteht enormer Druck, Wirksamkeit zu demonstrieren – nicht durch bewusste Fälschung, sondern durch subtile methodische Entscheidungen: großzügige Interpretation von Daten, Fokus auf kurzfristige Zufriedenheitsmaße statt harter Lernergebnisse, Nicht-Publikation gescheiterter Studien. Ein besonders problematisches Phänomen ist das sogenannte 'White-Washing' durch akademische Partnerschaften: Unternehmen kooperieren mit renommierten Universitäten und nutzen dann die akademische

[18] Cheung, A. C. K., & Slavin, R. E. (2024). The effectiveness of educational technology applications on mathematics and reading achievement in K-12 classrooms: A meta-analysis. *Educational Research Review*, 42, 100597.

Autorität zur Legitimierung – wobei negative Resultate verzögert oder verhindert werden können.

Forderungen an die Forschungsqualität. Die akademische Forschungsgemeinschaft fordert höhere Standards, analog zur medizinischen Forschung: randomisierte kontrollierte Trials mit ausreichender statistischer Power, Pre-Registrierung von Hypothesen, unabhängige Replikation der Befunde, Offenlegung aller Finanzierungsquellen und vollständige Transparenz über negative Ergebnisse.

Für Bildungspolitiker und Schulen bedeutet diese Evidenzkrise ein massives Entscheidungsproblem: Sie werden mit Marketing-Material bombardiert, das wissenschaftlich aussieht, aber keiner unabhängigen Prüfung standhält. Das Resultat sind fehlinvestierte Millionen in Technologien, deren Wirksamkeit unbewiesen ist – Gelder, die alternativ in nachweislich effektive Interventionen wie Klassenzahlreduktion oder individuelle Förderung hätten fließen können.

Was dringend benötigt wird, ist eine unabhängige, öffentlich finanzierte Evaluationsinfrastruktur für EdTech – vergleichbar mit der Arzneimittelzulassung –, die Produkte vor der Markteinführung auf Wirksamkeit und Sicherheit prüft.

7. Methodische Limitationen und Forschungsethik

Die präsentierte empirische Evidenz muss vor dem Hintergrund ihrer methodischen Limitationen und ethischen Rahmenbedingungen interpretiert werden. Die Forschung zu KI im Bildungskontext ist ein junges Feld mit erheblichen methodologischen Herausforderungen.

7.1 Die Krise der Messbarkeit

Ein signifikanter Teil der vorliegenden Forschung – insbesondere Studien wie die von Georgiou zur kognitiven Involviertheit – basiert auf Selbstberichten der Teilnehmer. Die grundlegende methodische Problematik ist in der Psychologie seit Jahrzehnten bekannt: Menschen sind notorisch schlechte Beobachter ihrer eigenen kognitiven Prozesse.

Das Problem der Fluency Illusion ist hier zentral: Wenn Information leicht verarbeitet werden kann – etwa weil sie flüssig formuliert ist oder von einer autoritativen Quelle stammt –, interpretieren Menschen diese Verarbeitungsflüssigkeit als Indikator für Verstehen und Kompetenz. Ein Student, der einen eloquent formulierten KI-Essay liest, erlebt ein Gefühl der Klarheit und könnte angeben, das Thema gut verstanden zu haben, während objektive Tests zeigen würden, dass er die Konzepte nicht selbstständig erklären kann.

Ähnlich problematisch ist die soziale Erwünschtheit: In Studien, in denen Teilnehmer wissen, dass ein innovatives EdTech-Tool evaluiert wird, neigen sie dazu, positive Rückmeldungen zu geben (Demand Characteristics). Wenn eine Universität stolz ein neues KI-Tutorsystem einführt, ist die implizite Botschaft klar, und Studierende könnten ihre Kritik zurückhalten.

Im Kontrast dazu stehen Studien mit objektiven Performanzmaßen – wie Bastani et al. mit standardisierten Mathematiktests oder Vivian mit Programmieraufgaben unter kontrollierten Bedingungen. Diese Messungen sind immun gegen subjektive Verzerrungen und erklären, warum ihre Befunde oft weniger optimistisch ausfallen als selbstberichtsbasierte Studien.

Eine weitere Dimension betrifft die zeitliche Perspektive: Die Mehrheit der Studien misst kurzfristige Effekte unmittelbar nach einer Intervention. Pädagogisch relevant wären jedoch langfristige Outcomes: Wird das Gelernte nach Monaten noch beherrscht? Können Fähigkeiten transferiert werden? Diese Fragen erfordern longitudinale Designs, die aus pragmatischen Gründen selten realisiert werden.

7.2 Stichprobenproblematik und Generalisierbarkeit

Viele der zitierten Studien operieren mit relativ kleinen Stichproben: Georgiou mit N=40, Slijepcevic mit N=69. Bei kleinen Stichproben besteht ein erhöhtes Risiko für Typ-II-Fehler – das fälschliche Nicht-Erkennen eines tatsächlich vorhandenen Effekts. Die Bastani-Studie mit N≈1.000 kombiniert große Stichprobe mit experimentellem Design und objektiven Outcomes – ein seltener Goldstandard in der EdTech-Forschung.

Dennoch bleibt die Frage der externen Validität: Die Bastani-Studie wurde mit US-amerikanischen High-School-Schülern im Algebra-Unterricht durchgeführt. Lassen sich die Befunde auf andere Altersgruppen, Fächer oder kulturelle Kontexte übertragen? Ein verwandtes Problem ist die Selektivität der Stichproben: Viele universitäre Studien rekrutieren Teilnehmer aus dem eigenen Studierendenpool – eine sogenannte WEIRD-Population (Western, Educated, Industrialized, Rich, Democratic). Ironischerweise wird gerade die Zielgruppe, für die KI den größten Nutzen verspricht – leistungsschwache Schüler aus benachteiligten Kontexten –, in der Forschung am seltensten untersucht.

Die Generalisierbarkeit wird weiterhin durch die Spezifität der verwendeten KI-Systeme eingeschränkt. GPT-4 vom Januar 2024 unterscheidet sich technologisch von GPT-4 vom Dezember 2025. Die rasante Entwicklung macht Studien potenziell obsolet, bevor sie publiziert sind – ein strukturelles Problem mit extrem kurzer Halbwertszeit von Erkenntnissen.

7.3 Ethische Dimensionen der KI-Forschung im Bildungskontext

Wenn Forscher untersuchen wollen, ob unreglementierte KI-Nutzung dem Lernen schadet – wie in der Bastani-Studie –, müssen sie eine Gruppe von Schülern bewusst einer potenziell schädlichen Intervention aussetzen. In der medizinischen Forschungsethik argumentiert man, dass der potenzielle gesellschaftliche Nutzen der Erkenntnis den individuellen Schaden rechtfertigen kann – sofern Risiken minimiert werden, informierte Zustimmung vorliegt und vulnerable Gruppen geschützt werden.

Im Bildungskontext ist die Situation komplizierter: Schüler sind Minderjährige mit begrenzter Autonomie; ihre Zustimmung zur Studienteilnahme ist rechtlich und ethisch problematisch. Eltern können stellvertretend zustimmen, aber verstehen sie wirklich die Implikationen? Wenn eine Schule ein experimentelles KI-System einführt und Schüler in eine RCT einbezieht, haben Schüler der Kontrollgruppe Nachteile, wenn das System effektiv ist – oder Schüler der Experimentalgruppe haben Nachteile, wenn es schädlich ist.

Ein weiteres ethisches Problem betrifft Datenschutz und Überwachung. KI-Tutorsysteme sammeln umfangreiche Daten über Nutzerverhalten: welche Aufgaben bearbeitet werden, wie lange, welche Fehler gemacht werden. Diese Daten sind wertvoll für pädagogische Forschung, aber auch hochsensibel. Sie könnten missbraucht werden – zur Profilierung von Schülern, zur Vorhersage zukünftiger Leistungen (mit selbsterfüllenden Prophezeiungen als Folge), oder zum kommerziellen Verkauf. Die DSGVO setzt strenge Grenzen, aber die Durchsetzung ist lückenhaft.

Schließlich stellt sich die Frage der distributiven Gerechtigkeit in der Forschung: Welche Populationen werden untersucht, und wer profitiert von den Erkenntnissen? Die Forschung fokussiert oft auf WEIRD-Populationen in gut ausgestatteten Kontexten. Die Bedürfnisse marginalisierter Gruppen – Schüler mit Lernschwierigkeiten, in strukturschwachen Regionen, mit Migrationshintergrund – werden unterrepräsentiert. Eine gerechtigkeitsorientierte Forschungsagenda müsste diese Asymmetrie bewusst adressieren.

Teil V: Synthese und komparative Analyse

Nach der detaillierten Untersuchung der empirischen Evidenz zum Einfluss von KI auf Lernprozesse wenden wir uns nun der komparativen Perspektive zu. Die bisherige Analyse hat sich primär auf die kognitive Dimension konzentriert – auf die Frage, wie KI das Lernen, das Denken und den Kompetenzerwerb beeinflusst. Diese Fokussierung war notwendig, um die subtilen Mechanismen des kognitiven Offloadings, der Desirable Difficulties und der differenziellen Nutzungsmuster präzise zu erfassen. Nun gilt es, den Blick zu weiten und die strukturellen, systemischen Transformationen zu betrachten, die sich in der praktischen Implementierung von KI in beiden untersuchten Sektoren – Bildung und Logistik – manifestieren.

8. Komparative Synthese: Pädagogik versus Logistik

Die Gegenüberstellung von Bildungssektor und Logistikbranche mag zunächst arbiträr erscheinen – zwei Domänen, die auf den ersten Blick wenig gemein haben. Doch gerade diese Kontrastierung erlaubt es, fundamentale Muster der technologischen Transformation zu identifizieren, die über einzelne Branchen hinausweisen. Beide Sektoren sind von existenziellem Fachkräftemangel betroffen, beide sehen in KI und Automatisierung eine notwendige Antwort, beide durchlaufen einen Wandel, der nicht nur technologischer, sondern auch kultureller und epistemologischer Natur ist. Dennoch unterscheiden sich die Transformationsdynamiken in fast allen wesentlichen Dimensionen.

8.1 Augmentation versus Substitution: Zwei Pfade der Automatisierung

Die fundamentalste Unterscheidung zwischen beiden Transformationspfaden liegt in der Rolle, die der Technologie zugedacht wird. Im Bildungssektor dominiert – zumindest in der normativen Rhetorik und in den pädagogisch reflektierten Ansätzen – das Augmentationsparadigma. KI wird konzipiert als Werkzeug zur Unterstützung und Verstärkung menschlicher Lehrtätigkeit, nicht als deren Ersatz. Die empirischen Studien, die wir analysiert haben, operieren durchweg mit dieser Prämisse: Selbst die GPT Tutor-Intervention in der Bastani-Studie eliminiert nicht die menschliche Lehrkraft, sondern ergänzt sie. Die KI übernimmt spezifische Tasks – repetitive Erklärungen, individualisierte Hinweise, geduldiges Wiederholen –, während die Lehrkraft für komplexere pädagogische Funktionen frei wird.

Diese Augmentationslogik ist nicht nur pädagogisch begründet, sondern auch durch die Natur der Lehrtätigkeit selbst determiniert. Die relationalen, emotionalen und ethischen Dimensionen des Unterrichtens – die Fähigkeit, eine Klassengemeinschaft zu formen, Konflikte zu moderieren, Schüler in Krisensituationen zu unterstützen, moralische Vorbilder zu sein – entziehen sich der Automatisierung nicht aus technischen Gründen (möglicherweise könnten zukünftige KI-Systeme auch empathische Dialoge simulieren), sondern aus normativen Gründen. Selbst wenn eine KI perfekt

empathische Reaktionen produzieren könnte, würde die pädagogische Beziehung etwas Fundamentales verlieren, wenn das Gegenüber kein menschliches Subjekt mit eigener Lebenserfahrung, Verletzlichkeit und moralischer Verantwortung ist. Lernen ist nicht nur Informationstransfer, sondern intersubjektive Begegnung.

Im Logistiksektor hingegen dominiert das Substitutionsparadigma, zumindest für spezifische Segmente der Fahraufgabe. Die Vision autonomer Lkw, die ohne menschlichen Fahrer über Autobahnen rollen, ist explizit substituierend – die Maschine ersetzt den Menschen, nicht nur in einzelnen Tasks, sondern in der Gesamtfunktion des Fahrens auf der Langstrecke. Diese Substitution wird nicht als bedauerliche Nebenwirkung, sondern als erklärtes Ziel verfolgt. Die ökonomischen Anreize sind evident: Ein autonomer Lkw unterliegt keinen Lenk- und Ruhezeitenregulierungen, kann 24/7 operieren, verursacht keine Personalkosten, streikt nicht, wird nicht krank. Die Effizienzgewinne sind so massiv, dass die Substitution aus betriebswirtschaftlicher Sicht zwingend erscheint.

Dennoch ist die Situation nuancierter, als die binäre Gegenüberstellung suggeriert. Auch im Logistiksektor findet Augmentation statt – etwa in Form von Fahrerassistenzsystemen, die bereits heute die Sicherheit erhöhen und die physische Belastung reduzieren, oder in Form der Teleoperation, die den Beruf des Fahrers nicht eliminiert, sondern transformiert: vom physischen Fahren in der Kabine zum virtuellen Steuern am Bildschirm. Und umgekehrt gibt es im Bildungssektor durchaus substituierende Tendenzen: Wenn Schüler ihre Aufsätze vollständig von ChatGPT schreiben lassen und Lehrkräfte dies nicht erkennen oder nicht sanktionieren, wird de facto ein Teil der Bildungsfunktion substituiert – die Schüler entwickeln keine eigene Schreibkompetenz mehr, die KI übernimmt diese Funktion.

Die Unterscheidung Augmentation/Substitution ist also weniger eine objektive Eigenschaft der Technologie als vielmehr ein Resultat bewusster Gestaltungsentscheidungen, regulatorischer Rahmungen und kultureller Normen. Im Bildungssektor existiert ein starker normativer Konsens, dass Bildung nicht vollständig technologisiert werden sollte – dieser Konsens wirkt als Barriere gegen radikale Substitution. Im Logistiksektor existiert ein solcher Konsens nicht – hier dominiert die ökonomische Rationalität, und ethische Bedenken gegen die Substitution menschlicher Arbeit werden als Fortschrittshemmnis oder als sentimentaler Anachronismus abgetan.

8.2 Das Paradoxon der Komplexität: Empathie versus Physik

Das Moravec'sche Paradoxon, das wir theoretisch bereits eingeführt haben, manifestiert sich in der komparativen Analyse auf faszinierende Weise. Es schützt beide Berufsgruppen in ihrem jeweiligen Kern, aber die Schutzmechanismen sind fundamental verschieden. Im Lehrerberuf ist es die sozial-emotionale Komplexität, die sich der Automatisierung widersetzt. Das Erkennen subtiler emotionaler Nuancen in einem Schülergespräch, die intuitive Anpassung des pädagogischen Ansatzes an die Tagesverfassung einer Klasse, die Fähigkeit, durch Humor Spannungen zu lösen oder durch ernsten Ton Grenzen zu setzen – all dies erfordert eine Form situativer sozialer Intelligenz, die KI-Systemen fundamental fremd ist.

Interessanterweise sind genau jene Aspekte des Lehrerberufs, die gesellschaftlich oft als 'soft' bagatellisiert werden und in der Bezahlung kaum honoriert werden, die am schwersten automatisierbaren. Die kognitive Wissensvermittlung – traditionell als Kern des Lehrerberufs verstanden – erweist sich als relativ leicht durch KI augmentierbar oder sogar substituierbar. Ein LLM kann Photosynthese erklären, kann auf Nachfragen eingehen, kann Beispiele generieren. Was es nicht kann, ist das Klassenklima gestalten, ist Schüler motivieren, die innerlich aufgegeben haben, ist als moralisches Vorbild fungieren. Die Professionalisierung des Lehrerberufs im KI-Zeitalter könnte paradoxerweise eine Aufwertung genau jener 'weichen' Kompetenzen bedeuten, die bisher unterschätzt wurden.

Im Fahrerberuf ist es umgekehrt die sensomotorische und perzeptuelle Komplexität, die den Menschen schützt. Das Fahren auf einer gut ausgebauten Autobahn bei klarem Wetter ist eine relativ routinehafte Task, die sich algorithmisieren lässt – konstante Geschwindigkeit halten, Spur halten, Abstand regulieren. Die wirklich schwierigen Herausforderungen liegen in den Randbereichen: das Navigieren durch eine enge Altstadtgasse, wo die Fahrbahnbreite nicht klar markiert ist und man auf Zentimeter genau einschätzen muss, ob der Lkw durchpasst. Das Rangieren auf einem schlammigen Bauhof, wo die Bodenbeschaffenheit ständig variiert und man durch minimalste Lenkbewegungen und Gaspedalmodulationen das Fahrzeug in Position bringen muss. Das Reagieren auf einen betrunkenen Fußgänger, der unvermittelt auf die Fahrbahn taumelt – eine Situation, die nicht nur schnelle Reaktion, sondern auch prädiktive Intuition erfordert ('Wird er stehenbleiben oder weiterlaufen?').

Diese motorischen und perzeptuellen Herausforderungen sind für Menschen intuitiv lösbar – wir haben Millionen Jahre Evolution hinter uns, die unsere sensomotorischen Systeme optimiert haben. Für KI-Systeme sind sie extrem schwierig, weil sie eine Integration multipler Sensorsysteme, Echtzeitverarbeitung unscharfer Daten und robuste Handhabung von Unsicherheit erfordern (vgl. das Pfützen-Beispiel in Kapitel 3.2).

Das Resultat dieses doppelten Paradoxons ist eine Fragmentierung beider Berufe entlang der Automatisierbarkeitslinien. Im Bildungssektor werden die kognitiv-

informativen Tasks zunehmend von KI übernommen (oder könnten es werden), während die sozial-emotionalen Tasks menschlich bleiben. Im Logistiksektor werden die routine-manuellen Tasks auf der Autobahn automatisiert, während die non-routine manuellen Tasks im urbanen Raum und an der Laderampe menschlich bleiben. In beiden Fällen verändert sich das Kompetenzprofil: Lehrer müssen weniger Wissensenzyklopädien sein und mehr Beziehungsmanager und ethische Mentoren. Fahrer müssen weniger monotone Autobahnkilometer absolvieren und mehr komplexe Manöver in schwierigen Umgebungen beherrschen.

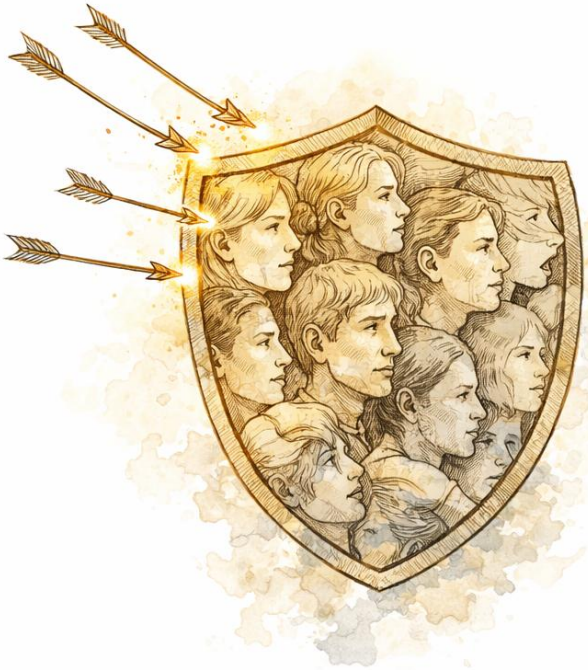

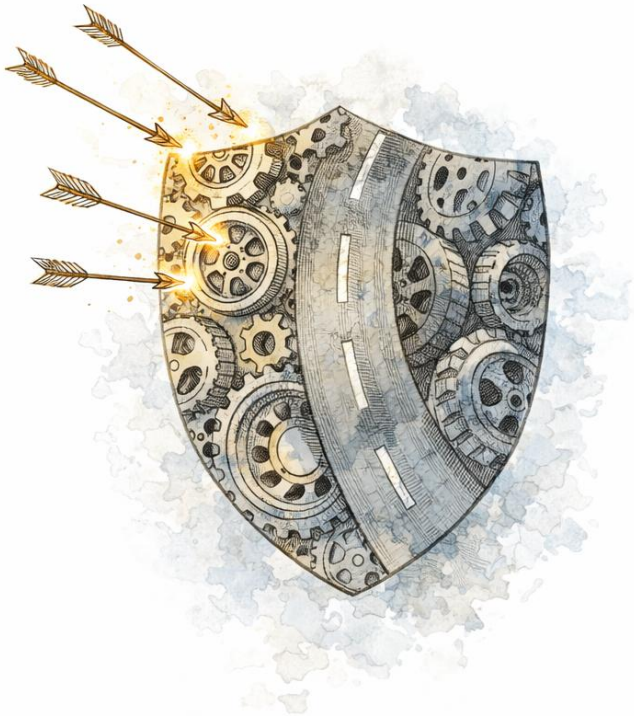

8.3 Regulatorische Asymmetrie: Föderal versus zentral

Eine der markantesten Unterschiede zwischen beiden Sektoren liegt in der regulatorischen Architektur. Der Logistiksektor hat mit der Straßenverkehr-Fernlenk-Verordnung (StVFernLV), die am 1. Dezember 2025 in Kraft trat, einen klaren, bundesweit einheitlichen rechtlichen Rahmen für den Betrieb autonomer und ferngelenkter Fahrzeuge. Diese Verordnung ist präzise, technisch detailliert und verbindlich. Sie regelt Qualifikationsanforderungen für Teleoperatoren, definiert technische Sicherheitsstandards, legt Haftungsfragen fest und schafft damit Rechtssicherheit für Unternehmen, die in diese Technologien investieren wollen.

Die Geschwindigkeit, mit der diese Regulierung entwickelt und implementiert wurde, ist bemerkenswert und spiegelt den enormen ökonomischen und politischen Druck wider. Deutschland positioniert sich bewusst als Vorreiter im Bereich autonomer Nutzfahrzeuge – ein strategischer Wirtschaftssektor, in dem deutsche Hersteller wie Daimler und MAN Weltmarktführer sind. Die Regulierung ist Standortpolitik: Sie soll Innovation ermöglichen, Investitionen anziehen und gleichzeitig durch klare Sicherheitsstandards das Vertrauen der Öffentlichkeit sichern. Die zentrale, bundeseinheitliche Regulierung ist hier ein Vorteil – sie vermeidet den regulatorischen Flickenteppich, der Innovation bremsen würde.

Im Bildungssektor hingegen herrscht regulatorische Fragmentierung. Bildung ist in Deutschland Ländersache, die föderale Struktur führt zu 16 verschiedenen Bildungssystemen mit jeweils eigenen Kultusministerien, Lehrplänen und Prüfungsordnungen. Während einzelne Bundesländer wie Nordrhein-Westfalen proaktiv Handlungsleitfäden für den KI-Einsatz entwickeln und Initiativen wie 'KI-Skilling NRW' starten, agieren andere Länder zögerlicher oder gar restriktiv. Diese föderale Vielfalt hat durchaus Vorteile – sie erlaubt experimentelles Lernen, regionale Anpassung, Wettbewerb der Ideen. Sie schafft aber auch Unsicherheit: Eine Lehrkraft, die in NRW ein bestimmtes KI-Tool nutzen darf, könnte in Bayern dafür disziplinarrechtlich belangt werden.

Hinzu kommt die Überlagerung durch europäische Regulierung. Die Datenschutzgrundverordnung (DSGVO) setzt strenge Grenzen für die Verarbeitung personenbezogener Daten von Schülern – Grenzen, die prinzipiell sinnvoll sind, um Kinder vor Überwachung und kommerzieller Ausbeutung zu schützen, die aber in der Praxis oft als Innovationshemmnis wirken. Schulen und Lehrkräfte sind verunsichert: Dürfen sie Tool X nutzen? Benötigen sie die Einwilligung der Eltern? Was passiert, wenn Daten auf US-Servern gespeichert werden? Diese Unsicherheit führt zu einer paradoxen Situation: Während in der Privatwirtschaft und in anderen Ländern KI-Tools massiv genutzt werden, agieren deutsche Schulen oft in einer Grauzone zwischen Innovation und Rechtskonformität.

Die Konsequenz ist eine hybride Praxis: Einzelne Schulen und engagierte Lehrkräfte experimentieren mit KI-Tools, oft unter Nutzung von Proxy-Lösungen wie fobizz, die

datenschutzkonform agieren sollen. Andere Schulen verbieten KI-Nutzung kategorisch oder ignorieren das Thema. Wieder andere warten auf offizielle Vorgaben, die oft nicht kommen oder so vage formuliert sind, dass sie keine Handlungssicherheit bieten. Der Kontrast zur klaren, zentralen Regulierung im Logistiksektor könnte kaum größer sein.

Diese regulatorische Asymmetrie ist nicht zufällig, sondern spiegelt unterschiedliche gesellschaftliche Prioritäten und Governance-Kulturen wider. Im Wirtschaftssektor dominiert das Primat der Wettbewerbsfähigkeit – Regulierung muss Innovation ermöglichen, darf aber nicht behindern. Im Bildungssektor dominiert das Primat der Fürsorge – der Schutz von Kindern vor potenziellen Schäden (Datenmissbrauch, pädagogische Fehlentwicklungen) wird höher gewichtet als schnelle Innovation. Beide Positionen haben ihre Berechtigung, aber sie führen zu fundamental unterschiedlichen Transformationsgeschwindigkeiten.

8.4 Geschwindigkeit der Disruption: Inkrementell versus disruptiv

Die Transformation im Bildungssektor verläuft inkrementell und bottom-up. Einzelne Lehrkräfte entdecken KI-Tools, probieren sie aus, teilen ihre Erfahrungen mit Kollegen. Schulen entwickeln nach und nach interne Guidelines. Fortbildungen werden angeboten. Lehrpläne werden graduell angepasst. Prüfungsformate evolvieren. Dieser Prozess ist organisch, dezentral und langsam. Er hat den Vorteil, dass er Raum für Reflexion lässt, Fehler korrigierbar sind und pädagogische Expertise sich entwickeln kann. Er hat den Nachteil, dass er ungleichmäßig verläuft – manche Schulen und Lehrkräfte sind Vorreiter, andere Nachzügler, wieder andere Verweigerer.

Die Transformation ist primär kulturell, nicht technologisch. Die Technologie (ChatGPT, Claude) ist verfügbar und funktional. Die eigentliche Herausforderung liegt darin, eine pädagogische Kultur zu entwickeln, die KI sinnvoll integriert – die weiß, wann KI hilfreich ist und wann schädlich, die Schüler zur konstruktiven Nutzung befähigt, die Prüfungsformate so gestaltet, dass sie nicht durch KI unterlaufen werden können. Diese kulturelle Transformation braucht Zeit, braucht Dialog, braucht die kollektive Aushandlung von Normen und Best Practices. Sie kann nicht durch Top-down-Dekrete erzwungen werden.

Im Logistiksektor verläuft die Transformation disruptiv und top-down. Große Logistikunternehmen und Fahrzeughersteller investieren Milliarden in die Entwicklung autonomer Systeme. Sobald diese Systeme technisch ausgereift und regulatorisch zugelassen sind, werden sie ausgerollt – nicht graduell, sondern massenhaft. Die Einführung autonomer Lkw auf der Langstrecke wird nicht von einzelnen Fahrern 'ausprobiert', sondern von Konzernen strategisch implementiert. Innerhalb weniger Jahre könnte ein erheblicher Teil des Fernverkehrs automatisiert sein. Die Geschwindigkeit wird durch ökonomische Zwänge diktiert: Unternehmen, die nicht automatisieren, werden im Wettbewerb benachteiligt sein und möglicherweise aus dem Markt gedrängt.

Diese Disruption ist primär strukturell, nicht kulturell. Die Technologie verändert nicht nur die Arbeitsweise, sondern die Arbeitsorganisation selbst. Fahrer werden nicht 'befähigt', autonome Systeme zu nutzen, sondern sie werden durch sie ersetzt oder in neue Rollen (Teleoperatoren) verschoben. Diese strukturelle Disruption erzeugt Gewinner und Verlierer: Unternehmen, die frühzeitig automatisieren, gewinnen Wettbewerbsvorteile. Fahrer, die in die neuen Rollen übergehen können (jung, technikaffin, weiterbildungsbereit), sichern ihre Beschäftigung. Ältere Fahrer ohne digitale Kompetenzen riskieren, obsolet zu werden.

Der Kontrast in der Transformationsgeschwindigkeit ist auch eine Frage der Reversibilität. Im Bildungssektor kann ein Schulsystem relativ leicht KI-Tools einführen, evaluieren und bei negativen Erfahrungen wieder einschränken. Die Investitionen sind überschaubar (Lizenzen, Fortbildungen), die Pfadabhängigkeiten gering. Im Logistiksektor hingegen sind die Investitionen massiv (autonome Fahrzeugflotten,

Teleoperation-Zentren, Infrastruktur) und die Pfadabhängigkeiten stark. Einmal getätigte Investitionen in autonome Systeme werden verteidigt werden, auch wenn sich soziale oder sicherheitstechnische Probleme zeigen. Der Lock-in-Effekt ist erheblich.

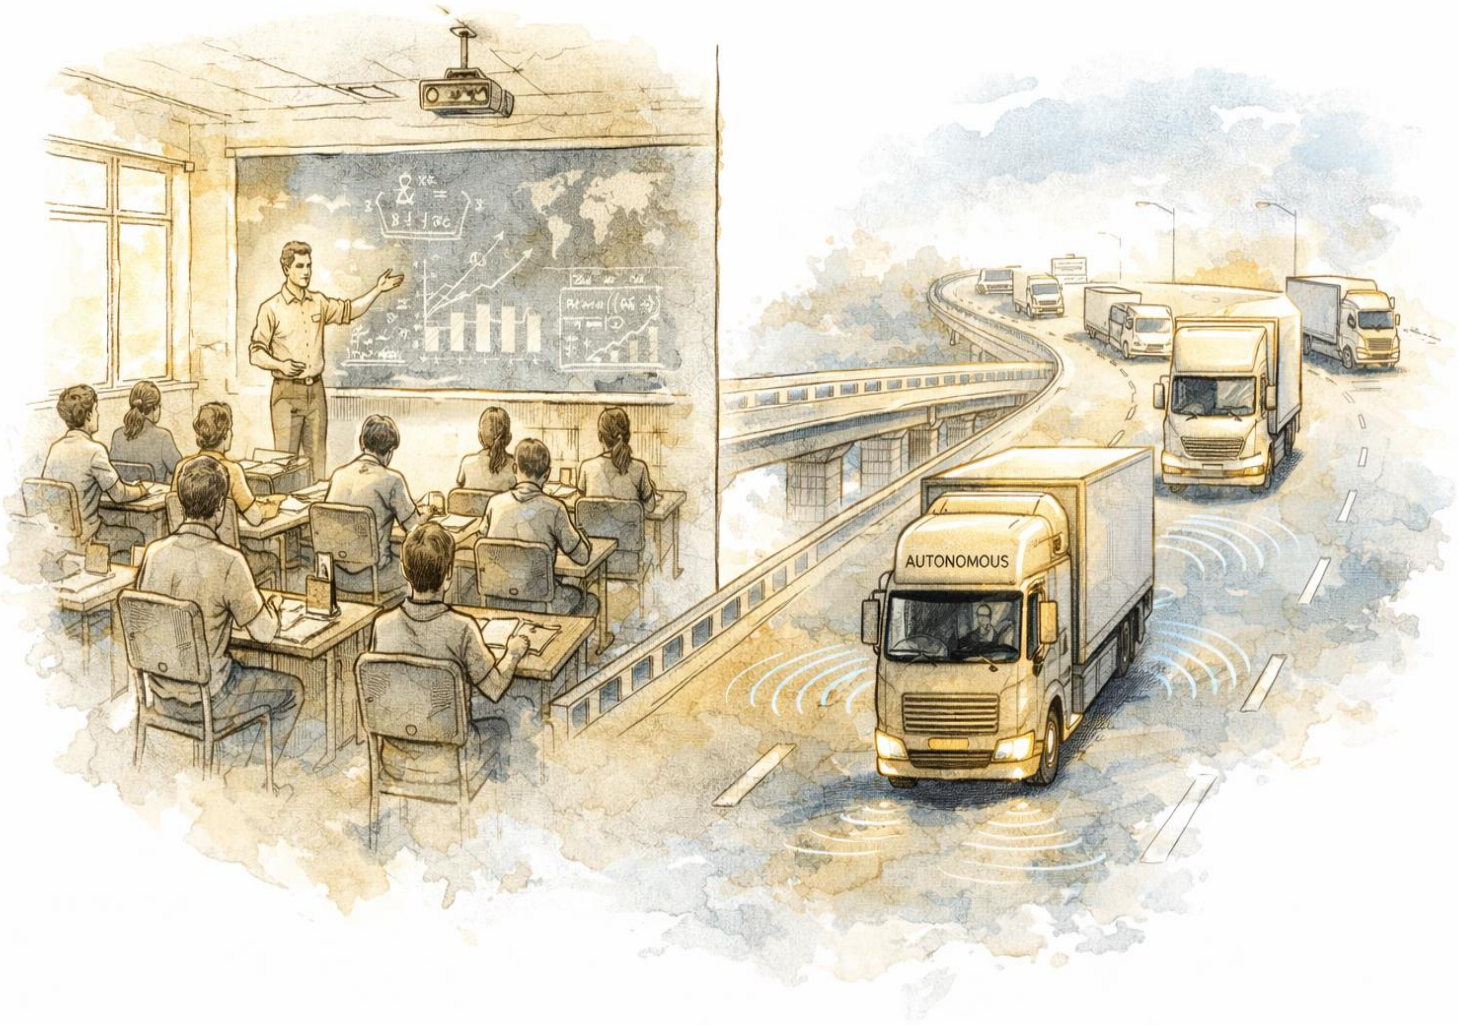

8.5 Qualifikatorische Polarisierung und der Matthäus-Effekt

In beiden Sektoren beobachten wir eine Aufwertung der Qualifikationsanforderungen – ein Phänomen, das in der Arbeitsmarktforschung als 'Skill-biased Technological Change' bezeichnet wird. Die Technologie begünstigt hochqualifizierte Arbeitskräfte und entwertet niedrigqualifizierte Tätigkeiten. Im Bildungssektor bedeutet dies, dass Lehrkräfte nicht nur fachlich und pädagogisch kompetent sein müssen, sondern zusätzlich über digitale und KI-spezifische Kompetenzen verfügen müssen. Sie müssen verstehen, wie LLMs funktionieren, welche Limitationen sie haben, wie man sie didaktisch sinnvoll einsetzt, wie man Schüler zur kritischen KI-Nutzung befähigt. Dies ist eine erhebliche Erweiterung des professionellen Anforderungsprofils.

Lehrkräfte, die diese neuen Kompetenzen entwickeln, werden produktiver, zufriedener und vermutlich auch karrieremäßig erfolgreicher sein. Lehrkräfte, die sich der Technologie verweigern oder sie nicht beherrschen, werden zunehmend marginalisiert – nicht unbedingt formal (es wird sie nicht sofort arbeitslos machen), aber funktional (sie werden als weniger kompetent wahrgenommen, von Schülern weniger respektiert, bei Beförderungen übergangen). Die Gefahr einer digitalen Spaltung innerhalb der Lehrerschaft ist real. Diese Spaltung korreliert vermutlich mit Alter (jüngere Lehrkräfte sind oft technikaffiner), aber auch mit Fachkultur (MINT-Lehrkräfte adaptieren KI schneller als Geisteswissenschaftler) und institutionellem Kontext (Schulen in privilegierten Vierteln haben oft bessere Ressourcen für Fortbildung).

Im Logistiksektor ist die Polarisierung noch ausgeprägter. Das traditionelle Berufsbild des Fernfahrers – wenig formale Bildung erforderlich, primär praktische Fahrkompetenz und Zuverlässigkeit – wird auf der Langstrecke obsolet. Die neuen Berufsbilder (Teleoperator, Flottenmanager, Systemüberwacher) erfordern höhere kognitive Kompetenzen: IT-Affinität, Englischkenntnisse (da viele Systeme englischsprachig sind), hohe Konzentrationsfähigkeit bei Bildschirmarbeit, Fähigkeit zum Multitasking. Gleichzeitig bleiben auf der 'letzten Meile' niedrigqualifizierte Fahrjobs bestehen, aber diese werden vermutlich schlechter bezahlt sein (da die lukrativen Langstrecken wegfallen) und prekärer (flexible Beschäftigung, On-Demand-Arbeit).

In beiden Sektoren manifestiert sich somit der Matthäus-Effekt auf der Ebene der Arbeitskräfte: Wer bereits über Bildung, Anpassungsfähigkeit und Lernbereitschaft verfügt, kann die technologische Transformation nutzen, um seine Position zu verbessern. Wer diese Ressourcen nicht hat, wird abgehängt. Diese Dynamik ist nicht technologisch determiniert, sondern wird durch soziale und institutionelle Faktoren vermittelt – durch die Verfügbarkeit von Weiterbildung, durch Tarifverträge, durch Arbeitsmarktregulierung. Gesellschaften, die in Weiterbildung investieren und soziale Sicherungsnetze bereitstellen, können die negativen Verteilungseffekte abmildern. Gesellschaften, die dies nicht tun, werden eine Verschärfung sozialer Ungleichheit erleben.

8.6 Tabellarische Gegenüberstellung der Transformationsdimensionen

Um die komplexe komparative Analyse zu verdichten, bietet sich eine tabellarische Synopse der zentralen Dimensionen an. Die folgende Tabelle fasst die Kontrastierungen zusammen und visualisiert die fundamentalen Unterschiede, aber auch die überraschenden Parallelen zwischen beiden Transformationspfaden.

Dimension	Bildungssektor (Lehrkräfte)	Logistiksektor (Fahrer)
Rolle der KI	Augmentation: KI als Werkzeug zur Unterstützung	Substitution & Transformation: KI ersetzt auf Langstrecke
Moravec-Schutz	Sozial-emotionale Komplexität bleibt unangetastet	Sensomotorische Komplexität in urbanen Räumen bleibt
Regulierung	Föderal fragmentiert, Leitfaden-Kultur, DSGVO-Restriktionen	Zentral verbindlich, StVFernLV, klare Standards
Transformationstempo	Inkrementell, bottom-up, kulturell	Disruptiv, top-down, strukturell
Arbeitsort	Unverändert: Schule/Klassenzimmer	Wandel: Von Kabine zu Remote-Center (Teleoperation)
Qualifikationswandel	Von Wissensvermittler zu Learning Engineer & Beziehungsmanager	Von Fernfahrer zu Teleoperator & Transportmanager
Soziale Polarisierung	Digitale Spaltung innerhalb Lehrerschaft (technikaffin vs. -avers)	Hochqualifizierte Bürojobs vs. prekäre Last-Mile-Fahrer
Hauptrisiko	Kognitive Atrophie bei Schülern, Verlust kritischen Denkens	Massenarbeitslosigkeit, soziale Verwerfungen

Diese tabellarische Verdichtung macht deutlich: Trotz der fundamentalen Unterschiede in der Transformationslogik teilen beide Sektoren eine gemeinsame Herausforderung – die Notwendigkeit, menschliche Arbeit neu zu definieren in einer Welt, in der Maschinen zunehmend Tätigkeiten übernehmen können, die bisher als genuin menschlich galten. Die Antwort kann nicht sein, Technologie zu verteufeln

oder ihre Einführung zu verweigern – dazu sind die ökonomischen und demografischen Zwänge zu stark. Die Antwort muss sein, die Transformation bewusst zu gestalten: durch kluge Regulierung, durch massive Investitionen in Weiterbildung, durch soziale Absicherung der Verlierer und durch eine gesellschaftliche Debatte darüber, welche Tätigkeiten wir aus normativen Gründen menschlich belassen wollen, selbst wenn sie technisch automatisierbar wären.

Teil VI: Implikationen und Handlungsempfehlungen

Die vorangegangene Analyse hat ein komplexes, teils widersprüchliches Bild der KI-Transformation in Bildung und Arbeit gezeichnet. Wir haben gesehen, wie generative KI unter bestimmten Bedingungen Lernprozesse behindern kann, während sie unter anderen Bedingungen produktiv sein könnte. Wir haben die methodischen Herausforderungen der Forschung dokumentiert und die strukturellen Interessenkonflikte in der EdTech-Industrie offengelegt. Wir haben die fundamentalen Unterschiede zwischen pädagogischer Augmentation und logistischer Substitution herausgearbeitet. Nun gilt es, aus diesen Befunden konkrete, evidenzbasierte Handlungsempfehlungen abzuleiten – Empfehlungen, die weder in naiven Technikoptimismus noch in reflexhaften Pessimismus verfallen, sondern die Komplexität der Transformation ernst nehmen.

9. Handlungsempfehlungen für den Bildungssektor

9.1 Pädagogische Guardrails als Standardanforderung

Die zentrale Lehre aus der Bastani-Studie ist eindeutig: Unreglementierter Zugang zu generativen KI-Systemen schadet dem Lernen messbar. Die Lösung kann nicht sein, KI aus Bildungskontexten zu verbannen – dies wäre angesichts ihrer ubiquitären Verfügbarkeit illusorisch und würde Schüler auch um potenzielle Lernchancen bringen. Die Lösung muss sein, KI-Systeme, die in Bildungskontexten eingesetzt werden, mit robusten pädagogischen Guardrails auszustatten. Diese Guardrails müssen technisch implementiert werden, nicht nur in Nutzungsrichtlinien empfohlen.

Konkret bedeutet dies: KI-Tutorsysteme sollten so programmiert sein, dass sie niemals vollständige Lösungen für Lernaufgaben liefern, sondern ausschließlich schrittweise, sokratische Hinweise. Diese Hinweise sollten adaptiv sein – anfänglich minimalistisch, bei wiederholtem Scheitern des Lernenden graduell detaillierter, aber niemals die Lösung vorwegnehmend. Das System sollte explizit Rückfragen stellen ('Warum glaubst du, dass dieser Ansatz funktioniert?'), um metakognitives Denken zu stimulieren. Es sollte produktive Fehler zulassen und als Lerngelegenheiten rahmen, anstatt sie sofort zu korrigieren. Diese Designprinzipien sind nicht neu – sie entsprechen etablierten pädagogischen Erkenntnissen über Scaffolding und Zone der proximalen Entwicklung –, aber sie müssen nun in die technische Architektur der Systeme eingebaut werden.

Bildungspolitisch erfordert dies eine Zertifizierungslogik ähnlich der Schulbuchzulassung. Bevor ein KI-System an Schulen eingesetzt werden darf, sollte es einen standardisierten Evaluationsprozess durchlaufen, in dem unabhängige pädagogische Experten prüfen, ob die Guardrails wirksam implementiert sind und ob das System evidenzbasierte Lernprinzipien respektiert. Systeme, die diese Kriterien nicht erfüllen – darunter aktuell die meisten Consumer-LLMs wie das Standard-ChatGPT –, sollten für den schulischen Einsatz nicht zugelassen sein. Dies schließt nicht aus, dass Schüler

sie privat nutzen, aber es schafft einen geschützten Raum, in dem pädagogisch verantwortungsvolle KI-Nutzung modelliert und eingeübt werden kann.

9.2 Curriculum für KI-Literalität: Von Prompting zu epistemischer Kompetenz

Die Befunde zur prozeduralen versus konstruktiven Nutzung zeigen, dass technischer Zugang allein nicht ausreicht – Schüler müssen befähigt werden, KI epistemisch kompetent zu nutzen. Dies erfordert ein explizites Curriculum für KI-Literalität, das weit über technische Bedienungskompetenzen hinausgeht. Ein solches Curriculum sollte mindestens folgende Komponenten umfassen: Erstens ein Verständnis der Funktionsweise von Large Language Models – nicht auf technischer Ebene (neuronale Netze, Transformer-Architekturen), sondern auf konzeptueller Ebene. Schüler sollten verstehen, dass LLMs statistische Mustererkennungsmaschinen sind, die auf Basis von Trainingsdaten plausibel klingende Texte generieren, ohne 'Verständnis' im menschlichen Sinne zu besitzen. Sie sollten die Konzepte von Halluzination, Bias und Konfabulation kennen und in der Lage sein, KI-Outputs kritisch zu hinterfragen.

Zweitens sollten Schüler metakognitive Strategien für produktive KI-Nutzung entwickeln. Dies umfasst die Fähigkeit, klare Lernziele zu setzen ('Was will ich verstehen, nicht nur produzieren?'), den eigenen Wissensstand realistisch einzuschätzen ('Verstehe ich dieses Konzept wirklich oder habe ich nur einen KI-generierten Text gelesen?'), und KI-Interaktionen strategisch zu planen ('Wann hole ich mir Hilfe, wann versuche ich es erst allein?'). Diese Kompetenzen sind nicht KI-spezifisch, sondern Kernkompetenzen selbstregulierten Lernens – aber sie müssen nun explizit im Kontext von KI-Nutzung trainiert werden, da die Versuchung des Cognitive Offloading so unmittelbar verfügbar ist.

Drittens sollte das Curriculum auch ethische und gesellschaftliche Dimensionen adressieren. Schüler sollten über die Umweltkosten von KI-Systemen (Energieverbrauch von Rechenzentren) Bescheid wissen, über Arbeitsbedingungen in der Datenaufbereitung (oft prekäre Clickwork in Niedriglohnländern), über Fragen intellektuellen Eigentums (Wurde das Modell auf urheberrechtlich geschützten Werken trainiert?) und über die politische Ökonomie der KI-Industrie (Wem gehören diese Systeme, wer profitiert?). Diese kritische Perspektive verhindert, dass KI als neutrale, magische Technologie wahrgenommen wird, und fördert eine informierte, mündige Nutzung.

Die Integration eines solchen Curriculums sollte nicht als separates Fach 'KI-Kunde' erfolgen, sondern fächerübergreifend. Im Deutschunterricht können Schüler KI-generierte Texte analysieren und deren rhetorische Strategien dekonstruieren. Im Mathematikunterricht können sie KI-Lösungswege auf logische Konsistenz prüfen. Im Geschichtsunterricht können sie untersuchen, wie LLMs historische Ereignisse darstellen und welche Perspektiven dabei marginalisiert werden. Im Informatikunterricht können sie einfache Prompting-Strategien entwickeln und deren Grenzen erfahren. Diese verteilte Integration stellt sicher, dass KI-Literalität nicht als abstraktes Wissen, sondern als praktische, angewandte Kompetenz entwickelt wird.

9.3 Prüfungsformate transformieren: Von Produkt zu Prozess

Die gegenwärtige Prüfungskultur, die primär auf die Bewertung von Endprodukten (Essays, Klausuren, Präsentationen) fokussiert, ist durch KI fundamental herausgefordert. Wenn Schüler diese Produkte mithilfe von KI generieren können, misst die Prüfung nicht mehr die Kompetenz des Schülers, sondern seine Fähigkeit, KI zu instruieren – eine durchaus wertvolle, aber andere Kompetenz. Die Antwort kann nicht sein, zu anachronistischen Überwachungsmethoden zurückzukehren (Handschriftliche Klausuren unter Aufsicht als einziges Format), sondern Prüfungsformate zu entwickeln, die authentisches Lernen auch im KI-Zeitalter valide erfassen.

Ein vielversprechender Ansatz ist der Shift von Produkt- zu Prozessbewertung. Anstatt nur den finalen Essay zu bewerten, könnte man den gesamten Entstehungsprozess dokumentieren lassen: Welche Rechercheschritte wurden unternommen? Wie wurde die Argumentation entwickelt? Welche Versionen gab es? Wo wurde KI konsultiert, und wie wurde mit ihren Outputs umgegangen? Ein Portfolio-Ansatz, in dem Schüler ihre Arbeitsprozesse reflektieren und begründen, macht es deutlich schwieriger, einfach KI-Outputs zu kopieren, weil die metakognitive Reflexionsleistung selbst bewertet wird. Gleichzeitig erlaubt dieser Ansatz die legitime Nutzung von KI als Werkzeug, solange der Schüler transparent macht, wie er sie genutzt hat und warum.

Ein weiterer Ansatz sind performanzbasierte Prüfungen, die nicht auf Wissensreproduktion, sondern auf Anwendung und Transfer fokussieren. Anstatt zu fragen 'Erkläre das Konzept der Photosynthese' (leicht durch KI beantwortbar), könnte man fragen 'Hier ist ein experimenteller Aufbau mit unerwarteten Ergebnissen – analysiere, was schiefgelaufen sein könnte und schlage Verbesserungen vor'. Solche offenen, komplexen Aufgaben, die situatives Urteilsvermögen und kreative Problemlösung erfordern, sind schwieriger durch bloßes KI-Prompting zu lösen, weil sie tiefes konzeptuelles Verständnis voraussetzen. Wichtig ist dabei, dass die Nutzung von KI als Hilfsmittel erlaubt sein kann – aber die Aufgabe sollte so gestaltet sein, dass KI allein sie nicht lösen kann.

Mündliche Prüfungen und dialogische Formate gewinnen ebenfalls an Bedeutung. In einem Gespräch kann eine Lehrkraft durch gezielte Nachfragen schnell erkennen, ob ein Schüler ein Konzept wirklich verstanden hat oder nur auswendig gelernte (oder KI-generierte) Formulierungen reproduziert. Die sokratische Methode – das beharrliche Hinterfragen, das Verlangen nach Begründungen, das Konfrontieren mit Widersprüchen – ist ein wirksames Instrument, um echtes Verständnis von oberflächlicher Reproduktion zu unterscheiden. Mündliche Prüfungen sind ressourcenintensiver als schriftliche Klausuren, aber in einer Welt, in der schriftliche Produkte leicht externalisiert werden können, möglicherweise die validere Form der Kompetenzmessung.

9.4 KI-Kompetenz als Schlüsselqualifikation: Von der Bedrohung zum Bildungsziel

Die bisherigen Überlegungen zu Prüfungsformaten sind primär defensiv orientiert: Wie können wir sicherstellen, dass trotz KI-Verfügbarkeit noch „echte" Kompetenzen geprüft werden? Diese Perspektive übersieht jedoch eine fundamentale Frage: Was, wenn die Fähigkeit zur produktiven KI-Nutzung selbst zu den zentralen Kompetenzen gehört, die Bildung vermitteln sollte?

Die in Teil III referierten Studien zeigen durchgängig ein Muster: Der Umgang mit KI schult den Umgang mit KI – nicht aber die traditionellen Fachkompetenzen. Dies wird als Problem diagnostiziert, weil die Prüfungen eben jene traditionellen Kompetenzen abfragen. Doch diese Diagnose setzt voraus, dass die traditionellen Kompetenzen auch in Zukunft die relevanten sein werden. Die Geschichte der Programmiersprachen – vom Maschinencode über Assembler zu Hochsprachen –, wie in der persönlichen Anmerkung zu Teil III bereits ausgeführt, legt eine andere Lesart nahe: Jede Abstraktionsebene entwertet bestimmte Fertigkeiten und wertet andere auf. Wer heute kein Assembler mehr beherrscht, gilt nicht als inkompetent, sondern als normal.

Wenn KI-Systeme zunehmend Aufgaben übernehmen, die bisher menschliche Fachkompetenz erforderten – das Schreiben von Code, das Verfassen von Texten, das Lösen mathematischer Probleme –, dann verschiebt sich das Kompetenzprofil. Die entscheidende Fähigkeit wird dann nicht mehr sein, diese Aufgaben selbst auszuführen, sondern zu erkennen, welche Aspekte der eigenen Arbeit sinnvollerweise durch KI augmentiert oder dieser sogar ganz überlassen werden sollten – und welche nicht. Diese Metakompetenz umfasst mehrere Dimensionen:

Erstens die Fähigkeit zur Aufgabenanalyse: Welche Teile einer komplexen Aufgabe sind routinehaft und delegierbar, welche erfordern menschliches Urteil, Kreativität oder ethische Abwägung? Ein Jurist, der einen Vertrag erstellt, könnte Standardklauseln von einer KI generieren lassen, muss aber selbst entscheiden, welche Klauseln im konkreten Fall relevant sind und wie Interessenkonflikte gelöst werden. Diese Zerlegung komplexer Aufgaben in automatisierbare und nicht-automatisierbare Komponenten ist eine genuine Kompetenz, die trainiert werden muss.

Zweitens die Fähigkeit zur Qualitätskontrolle: Wer KI-Outputs nutzt, muss in der Lage sein, deren Qualität zu beurteilen, Fehler zu erkennen und Korrekturen vorzunehmen. Dies erfordert paradoxerweise ein gewisses Maß an Fachkompetenz – man muss genug verstehen, um Fehler zu erkennen, auch wenn man nicht mehr alles selbst produzieren kann. Die Analogie zum Lektorat liegt nahe: Ein guter Lektor muss nicht selbst brillante Romane schreiben können, aber er muss erkennen, was einen Text gut oder schlecht macht.

Drittens die Fähigkeit zur effektiven Instruktion: KI-Systeme sind mächtig, aber ihre Outputs hängen stark von der Qualität der Instruktion ab. Präzise, kontextreiche,

wohlstrukturierte Prompts führen zu besseren Ergebnissen als vage Anfragen. Diese Fähigkeit zur effektiven Mensch-Maschine-Kommunikation ist erlernbar und sollte systematisch vermittelt werden – nicht als technischer Trick, sondern als kommunikative Kompetenz.

Die bildungspolitische Konsequenz wäre, KI-gestützte Aufgabenbewältigung nicht nur zuzulassen, sondern explizit zu prüfen. Eine Prüfungsaufgabe könnte lauten: „Nutzen Sie KI-Tools Ihrer Wahl, um folgendes komplexes Problem zu lösen. Dokumentieren Sie Ihren Prozess: Welche Teilaufgaben haben Sie delegiert, welche selbst bearbeitet? Wie haben Sie die KI-Outputs geprüft und angepasst? Begründen Sie Ihre Entscheidungen." Eine solche Prüfung würde nicht die Fähigkeit messen, ohne KI zu arbeiten (eine zunehmend anachronistische Anforderung), sondern die Fähigkeit, mit KI intelligent zu arbeiten – die Schlüsselqualifikation der Zukunft.

Dies bedeutet nicht, dass traditionelle Kompetenzen obsolet werden. Grundlegendes Verständnis bleibt notwendig – für die Qualitätskontrolle, für die Situationen, in denen KI nicht verfügbar oder nicht angemessen ist, für das kritische Denken, das KI-Outputs einordnet. Aber das Verhältnis verschiebt sich: Grundkompetenzen werden zur notwendigen Basis, auf der die eigentlich wertschöpfende KI-augmentierte Arbeit aufbaut. Die Bildung der Zukunft muss beides vermitteln – und beides prüfen.

9.5 Lehrkräftebildung und professionelle Entwicklung

Die Transformation der Bildungspraxis durch KI erfordert eine massive Investition in die Aus- und Weiterbildung von Lehrkräften. Die gegenwärtige Situation – in der die meisten Lehrkräfte sich KI-Kompetenzen autodidaktisch oder durch informellen Austausch aneignen – ist suboptimal und reproduziert bestehende Ungleichheiten (technikaffine Lehrkräfte profitieren, andere werden abgehängt). Was benötigt wird, ist eine systematische, flächendeckende Professionalisierungsoffensive, die über sporadische Fortbildungsangebote hinausgeht.

In der universitären Lehramtsausbildung sollte KI-Literalität als Querschnittskompetenz verankert werden, vergleichbar mit Inklusion oder Digitalisierung. Angehende Lehrkräfte sollten nicht nur lernen, wie man KI-Tools bedient, sondern vor allem, wie man über KI pädagogisch reflektiert: Wann ist KI-Einsatz lernförderlich, wann kontraproduktiv? Wie gestalte ich Unterricht so, dass KI produktiv integriert wird, ohne kritisches Denken zu untergraben? Wie erkenne ich, ob Schüler KI zur Augmentation oder zur Substitution nutzen? Diese Fragen sollten in fachdidaktischen Seminaren, in schulpraktischen Phasen und in der erziehungswissenschaftlichen Ausbildung behandelt werden.

Für bereits praktizierende Lehrkräfte sind verpflichtende, qualitativ hochwertige Fortbildungen notwendig. Diese sollten nicht als einmalige Workshops konzipiert sein, sondern als längerfristige Professionalisierungsprozesse mit mehreren Phasen: Input (theoretisches Wissen über KI und Lernen), Erprobung (angeleitete Experimente im eigenen Unterricht), Reflexion (kollegiale Fallbesprechungen, Supervision) und Vertiefung (fortgeschrittene Strategien). Essentiell ist, dass diese Fortbildungen nicht von EdTech-Unternehmen durchgeführt werden, die primär ihre Produkte vermarkten wollen, sondern von unabhängigen pädagogischen Institutionen, die evidenzbasiert arbeiten.

Besonders wichtig ist die Entwicklung von Communities of Practice – schulinterne und schulübergreifende Netzwerke von Lehrkräften, die sich regelmäßig über ihre Erfahrungen mit KI austauschen. In solchen Communities können Best Practices geteilt, Probleme kollektiv gelöst und Unterrichtsmaterialien gemeinsam entwickelt werden. Die föderale Struktur des deutschen Bildungssystems erschwert dies, aber digitale Plattformen können hier Abhilfe schaffen. Eine bundesweite, öffentlich finanzierte Plattform für den Austausch von KI-bezogenen Unterrichtskonzepten, Prüfungsformaten und Erfahrungsberichten könnte die fragmentierte Innovationslandschaft konsolidieren.

9.6 Regulatorische Kohärenz und Datenschutz

Die föderale Fragmentierung der KI-Regulierung im Bildungssektor ist ein Hemmnis für kohärente Innovation. Während völlige Zentralisierung der deutschen Bildungstradition widerspräche, wäre eine stärkere Koordination zwischen den Ländern wünschenswert. Die Kultusministerkonferenz (KMK) sollte nicht nur unverbindliche Empfehlungen aussprechen, sondern verbindliche Mindeststandards für den KI-Einsatz definieren – Standards bezüglich Datenschutz, pädagogischer Qualität und Chancengerechtigkeit. Einzelne Länder könnten darüber hinausgehen, aber ein gemeinsamer Boden würde Rechtssicherheit schaffen und verhindern, dass Schüler je nach Bundesland völlig unterschiedliche Bildungserfahrungen machen.

Die DSGVO-Konformität ist eine berechtigte Anforderung, darf aber nicht zum Totschlagargument gegen jede Innovation werden. Was benötigt wird, sind praktikable Lösungen, die Datenschutz und pädagogische Nützlichkeit versöhnen. Eine Möglichkeit sind national oder europäisch gehostete KI-Systeme, die garantieren, dass Schülerdaten nicht auf US-Servern landen und nicht kommerziell verwertet werden. Initiativen wie das geplante europäische LLM oder nationale Bildungs-KI-Projekte sollten massiv gefördert werden. Alternativ können Proxy-Lösungen wie fobizz, die als datenschutzkonforme Schnittstellen zu kommerziellen LLMs fungieren, eine Übergangsphase ermöglichen.

Entscheidend ist, dass Datenschutz nicht als bürokratisches Hindernis, sondern als pädagogische Chance verstanden wird. Die Sensibilisierung von Schülern für Datenschutz, für die Risiken von Überwachung und Profilierung, für ihre Rechte als digitale Bürger – all dies ist Teil einer umfassenden digitalen Bildung. Lehrkräfte sollten befähigt werden, Datenschutzfragen nicht als technisches Spezialwissen zu delegieren, sondern als Teil ihrer pädagogischen Verantwortung zu begreifen. Wenn Schüler lernen, dass ihre Daten wertvoll sind und geschützt werden müssen, ist dies eine wichtige Lektion für das Leben in einer datengetriebenen Gesellschaft.

10. Handlungsempfehlungen für den Logistiksektor

10.1 Sozialverträgliche Gestaltung der Automatisierung

Die Automatisierung des Güterverkehrs ist ökonomisch rational und technologisch zunehmend machbar. Sie wird kommen – die Frage ist nicht ob, sondern wie. Die zentrale politische Herausforderung besteht darin, diese Transformation so zu gestalten, dass sie nicht zu massiver Arbeitslosigkeit und sozialen Verwerfungen führt. Dies erfordert proaktive, vorausschauende Sozialpolitik, die nicht erst reagiert, wenn Zehntausende Fahrer bereits ihre Jobs verloren haben, sondern die den Wandel antizipiert und aktiv steuert.

Ein erster Baustein ist die schrittweise, gestaffelte Einführung autonomer Systeme. Anstatt schlagartig ganze Flotten zu automatisieren, sollten Unternehmen verpflichtet werden, Übergangsfristen einzuhalten, die es Beschäftigten ermöglichen, sich auf neue Rollen vorzubereiten. Ein denkbares Modell wäre eine Quote: Unternehmen dürfen pro Jahr nur einen bestimmten Prozentsatz ihrer Fahrzeuge automatisieren, wobei dieser Prozentsatz graduell steigt. Dies gibt der Gesellschaft Zeit, Qualifizierungsprogramme zu etablieren, alternative Beschäftigungsmöglichkeiten zu schaffen und soziale Härten abzufedern.

Zweitens sollten Tarifverträge und Betriebsvereinbarungen explizit die Modalitäten der Automatisierung regeln. Gewerkschaften müssen frühzeitig in Transformationsprozesse einbezogen werden und Mitspracherechte bei der Einführung autonomer Systeme erhalten. Denkbare Regelungen umfassen: Vorrang für Umschulung vor Entlassung, garantierte Weiterbeschäftigung in neuen Rollen für Fahrer, die sich qualifizieren, Abfindungen für ältere Fahrer, die nicht in neue Tätigkeiten wechseln können, und Sozialplanabsicherungen bei unvermeidbaren Jobverlusten. Die Lasten der Transformation dürfen nicht einseitig von den Beschäftigten getragen werden, während Unternehmen die Effizienzgewinne privatisieren.

Drittens ist eine Automatisierungssteuer oder -abgabe diskussionswürdig. Wenn autonome Lkw menschliche Arbeitskraft ersetzen, entfallen Lohnsteuer- und Sozialversicherungseinnahmen, während gleichzeitig Kosten für Arbeitslosigkeit und Umschulung entstehen. Eine Abgabe auf autonome Fahrzeuge könnte diese fiskalischen Effekte kompensieren und die Einnahmen gezielt für Qualifizierungsprogramme und soziale Absicherung verwenden. Dies ist kein Plädoyer gegen Automatisierung, sondern für ihre sozialverträgliche Gestaltung – die Gewinne der Produktivitätssteigerung sollten gesellschaftlich geteilt werden.

10.2 Qualifizierungsoffensive für Beschäftigte

Die Transformation des Fahrerberufs in Richtung Teleoperation und Flottenmanagement eröffnet neue Beschäftigungsmöglichkeiten – aber nur für jene, die sich qualifizieren können. Der durchschnittliche Fernfahrer ist Mitte 40, hat keine Hochschulbildung und verfügt über begrenzte IT-Kompetenzen. Ohne massive Qualifizierungsanstrengungen werden diese Arbeitskräfte abgehängt. Was benötigt wird, ist eine branchenweite, öffentlich-privat finanzierte Qualifizierungsoffensive, die allen Beschäftigten Umschulungsmöglichkeiten bietet.

Diese Programme sollten modular aufgebaut sein und verschiedene Zielniveaus ermöglichen. Für jüngere, lernbereite Fahrer könnte eine Vollqualifizierung zum Teleoperator angeboten werden – ein mehrmonatiger Kurs, der IT-Grundlagen, Systemüberwachung, Notfallmanagement und rechtliche Rahmenbedingungen vermittelt. Für ältere Fahrer, die sich eine vollständige Umschulung nicht zutrauen, könnten Teilqualifikationen angeboten werden – etwa zum Flottenkoordinator, der Routenplanung und Kundenmanagement übernimmt, ohne selbst Teleoperation durchzuführen. Für Fahrer kurz vor der Rente sollten würdevolle Ausstiegsoptionen geschaffen werden – Altersteilzeit, vorgezogene Rente mit Kompensation der Rentenabschläge.

Entscheidend ist, dass diese Qualifizierung nicht als individuelle Bringschuld der Arbeitnehmer konzipiert wird, sondern als gesellschaftliche Verpflichtung. Beschäftigte sollten für die Dauer der Umschulung Lohnfortzahlung oder Lohnersatzleistungen erhalten, die Kurse sollten kostenlos sein und zeitlich flexibel organisiert (berufsbegleitend, modular, mit digitalen Komponenten). Die Bundesagentur für Arbeit, Branchenverbände und Unternehmen sollten gemeinsam die Finanzierung tragen. Unternehmen, die von Automatisierung profitieren, haben eine besondere Verantwortung, in die Beschäftigungsfähigkeit ihrer Belegschaft zu investieren.

10.3 Regulierung und Sicherheitsstandards

Die StVFernLV ist ein wichtiger erster Schritt, aber sie wird kontinuierlich weiterentwickelt werden müssen, da die Technologie sich rasant entwickelt. Essentiell ist, dass Sicherheitsstandards nicht von der Industrie selbst definiert werden, sondern durch unabhängige, öffentliche Instanzen. Die Zulassung autonomer Systeme sollte an strenge Nachweise gebunden sein – nicht nur Simulationen und Testfahrten unter idealen Bedingungen, sondern umfangreiche Real-World-Erprobungen unter verschiedenen Wetter-, Verkehrs- und Infrastrukturbedingungen.

Ein kritischer Punkt ist die Haftungsfrage. Wenn ein autonomer Lkw einen Unfall verursacht, wer haftet? Der Hersteller des Systems, der Betreiber der Flotte, der Teleoperator, der möglicherweise hätte eingreifen können? Klare rechtliche Regelungen sind notwendig, um Rechtssicherheit zu schaffen und Anreize für sichere Systeme zu setzen. Ein denkbares Modell wäre eine Gefährdungshaftung des Fahrzeughalters (wie im traditionellen Verkehrsrecht), ergänzt durch eine Produkthaftung des Herstellers bei nachweisbaren Systemfehlern. Eine Pflichtversicherung für autonome Fahrzeuge, die höher ist als für konventionelle Lkw, könnte die Risiken internalisieren.

Die Teleoperation wirft zusätzliche Fragen auf: Wie viele Fahrzeuge kann ein Operator gleichzeitig überwachen? Wie werden Überlastung und Ermüdung verhindert? Welche Qualifikationen und regelmäßigen Prüfungen sind erforderlich? Die StVFernLV adressiert einige dieser Fragen, aber die praktische Umsetzung wird zeigen, ob die Standards ausreichen oder nachgeschärft werden müssen. Ein transparentes Meldesystem für Beinahe-Unfälle und Systemfehler – vergleichbar dem in der Luftfahrt – könnte helfen, frühzeitig Schwachstellen zu identifizieren und zu beheben.

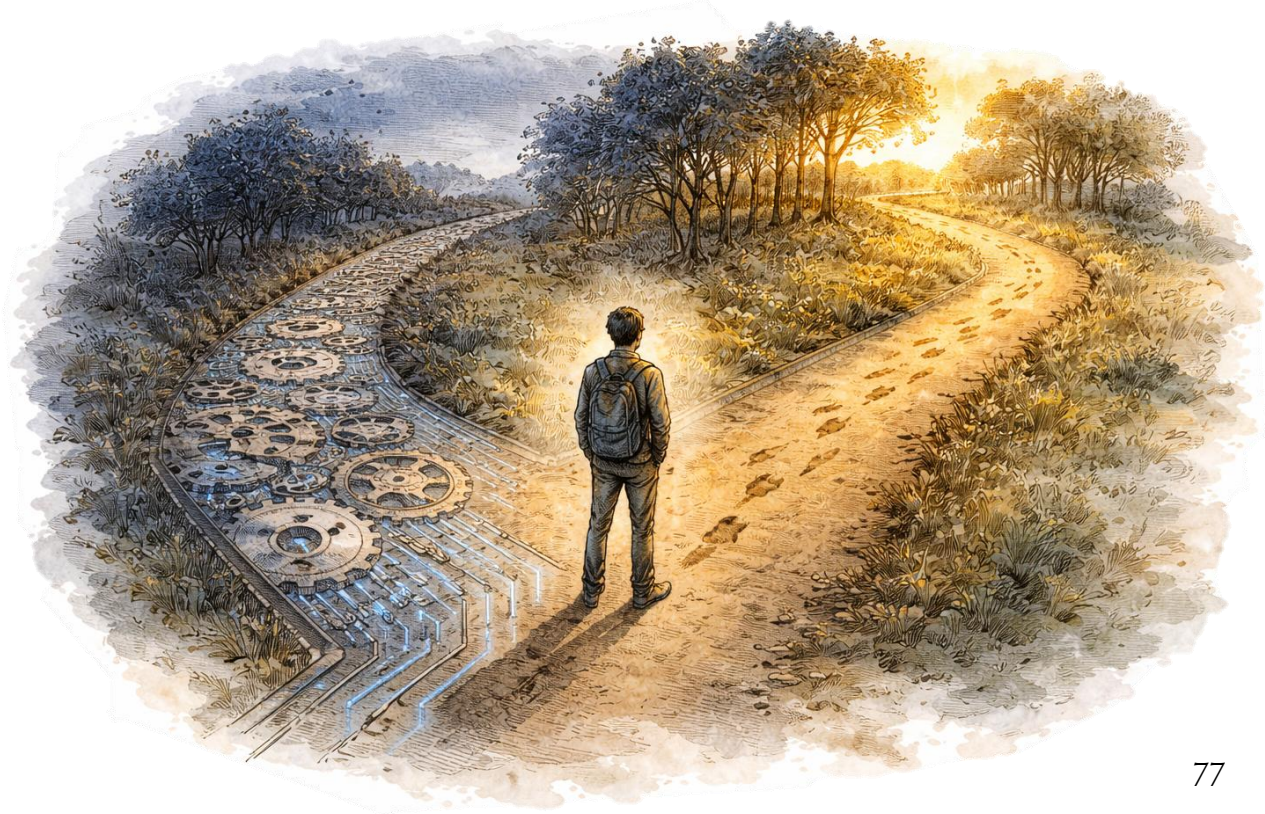

11. Übergreifende Empfehlungen: Forschung, Governance und gesellschaftlicher Dialog

11.1 Unabhängige Evaluationsinfrastruktur

Die Evidenzkrise in der EdTech- und Automatisierungsforschung verlangt nach strukturellen Lösungen. Was dringend benötigt wird, ist eine unabhängige, öffentlich finanzierte Evaluationsinfrastruktur, die ähnlich funktioniert wie die Arzneimittelzulassung. Bevor KI-basierte Bildungssysteme oder autonome Fahrzeuge in großem Maßstab eingesetzt werden, sollten sie rigoros evaluiert werden – durch unabhängige Forscher, nach vorab registrierten Protokollen, mit ausreichend großen Stichproben und über ausreichend lange Zeiträume.

In Deutschland könnte eine solche Infrastruktur beim Deutschen Institut für Internationale Pädagogische Forschung (DIPF) oder einer neu zu schaffenden Bundesanstalt für Bildungstechnologie-Evaluation angesiedelt sein. Diese Institution hätte das Mandat, EdTech-Produkte auf Wirksamkeit, Sicherheit und Chancengerechtigkeit zu prüfen. Produkte, die die Evaluation nicht bestehen, würden kein öffentliches Qualitätssiegel erhalten und wären für den schulischen Einsatz nicht empfohlen. Die Finanzierung sollte durch Gebühren der Hersteller sowie öffentliche Mittel erfolgen, um Unabhängigkeit zu garantieren.

Für den Logistiksektor wäre eine analoge Struktur denkbar – etwa bei der Bundesanstalt für Straßenwesen (BASt) oder dem Kraftfahrt-Bundesamt (KBA). Autonome Systeme sollten nicht nur technische Sicherheitstests durchlaufen, sondern auch sozioökonomische Folgeabschätzungen. Wie viele Arbeitsplätze werden betroffen sein? Welche Regionen sind besonders vulnerabel? Welche Umschulungsmaßnahmen sind notwendig? Diese Analysen sollten öffentlich zugänglich sein und in politische Entscheidungen einfließen.

11.2 Partizipative Governance und demokratische Deliberation

Technologische Transformationen von solcher Tragweite sollten nicht primär von Unternehmen und Technokraten gesteuert werden, sondern Gegenstand breiter gesellschaftlicher Deliberation sein. In beiden untersuchten Sektoren – Bildung und Logistik – sind die Stakeholder vielfältig: Lehrkräfte, Schüler, Eltern, Bildungspolitiker, Fahrer, Logistikunternehmen, Gewerkschaften, Kommunen, Umweltverbände. Alle diese Gruppen haben legitime Interessen und sollten in Entscheidungsprozesse einbezogen werden.

Konkret könnten Bürgerräte oder Technologieräte eingerichtet werden – deliberative Foren, in denen zufällig ausgewählte Bürger, ergänzt durch Experten und Interessenvertreter, über die Zukunft von KI in Bildung und Arbeit beraten. Solche Räte haben in anderen Kontexten (z.B. Klimapolitik) gezeigt, dass sie zu ausgewogenen, informierten Empfehlungen kommen können, die sowohl Innovation ermöglichen als auch soziale und ethische Bedenken ernst nehmen. Die Ergebnisse solcher Räte sollten nicht nur symbolisch sein, sondern in konkrete Politikmaßnahmen einfließen.

Auf Schulebene bedeutet partizipative Governance, dass Entscheidungen über KI-Einsatz nicht top-down von Schulleitungen oder Schulträgern getroffen werden, sondern unter Beteiligung von Lehrkräften, Schülervertretungen und Elternbeiräten. Welche Tools sollen genutzt werden? Welche Prüfungsformate sind angemessen? Wie gehen wir mit KI-generiertem Plagiarismus um? Diese Fragen sollten schulintern diskutiert und demokratisch entschieden werden, im Rahmen der übergeordneten Regulierung, aber mit Gestaltungsspielraum für lokale Lösungen.

Im Logistiksektor bedeutet partizipative Governance die Einbindung von Betriebsräten und Gewerkschaften in Transformationsentscheidungen. Wenn ein Unternehmen plant, autonome Systeme einzuführen, sollten Beschäftigtenvertreter nicht nur informiert, sondern aktiv in die Planung einbezogen werden. Wie werden betroffene Fahrer unterstützt? Welche Qualifizierungsangebote gibt es? Wie wird die Arbeitsorganisation in Teleoperation-Centern gestaltet? Mitbestimmung ist nicht nur ein demokratisches Recht, sondern auch ökonomisch sinnvoll, weil sie das Erfahrungswissen der Beschäftigten nutzt und Akzeptanz für Veränderungen schafft.

11.3 Langfristige Forschungsagenda

Die vorliegende Analyse hat gezeigt, dass trotz intensiver Forschungsaktivität erhebliche Wissenslücken bestehen. Viele der zitierten Studien sind kurzfristig (wenige Wochen oder Monate), klein (N<100) und fokussiert auf privilegierte Populationen (Universitätsstudierende in westlichen Ländern). Was fehlt, sind longitudinale Studien, die langfristige Effekte über Jahre hinweg verfolgen, Large-Scale-Studien mit tausenden Teilnehmern, die robust statistische Inferenzen erlauben, und Studien in diversen Kontexten, die Generalisierbarkeit prüfen.

Eine prioritäre Forschungsfrage ist die langfristige kognitive Entwicklung von Schülern, die intensiv mit KI lernen. Entwickeln sie robustes Verständnis oder oberflächliches Scheinwissen? Wie entwickeln sich ihre metakognitiven Fähigkeiten, ihre Lernstrategien, ihre epistemischen Überzeugungen? Welche Rolle spielt das Alter – sind Grundschulkinder anders betroffen als Gymnasiasten? Eine 10-Jahres-Kohorte, die vom Grundschulalter bis zum Abitur begleitet wird, könnte invaluable Einsichten liefern, aber sie erfordert erhebliche finanzielle und institutionelle Commitments.

Eine zweite Forschungslücke betrifft die soziale Ungleichheit. Wie wirkt sich KI-Zugang auf bestehende Bildungsungleichheiten aus? Verstärkt sie den Matthäus-Effekt oder kann sie – unter den richtigen Bedingungen – tatsächlich als Equalizer fungieren? Welche Rolle spielen familiäres Kapital, schulische Ressourcen, regionale Unterschiede? Solche Fragen erfordern mehrebenen-analytische Designs, die individuelle, schulische und regionale Faktoren integrieren.

Im Logistiksektor sind die drängenden Forschungsfragen primär sozioökonomischer Natur: Wie entwickeln sich Beschäftigungsstrukturen tatsächlich, wenn Automatisierung massiv ausgerollt wird? Welche neuen Jobs entstehen, welche verschwinden? Wie gut funktionieren Umschulungsprogramme in der Praxis – welche Fahrer schaffen den Übergang, welche nicht, und warum? Welche regionalen Disparitäten entstehen (urbane Zentren profitieren, ländliche Regionen verlieren)? Begleitforschung zu realen Transformationsprojekten – etwa dem ATLAS-L4-Projekt – könnte wertvolle Evidenz liefern.

Schließlich bedarf es interdisziplinärer Forschung, die technologische, pädagogische, ökonomische, soziologische und ethische Perspektiven integriert. Die Transformation durch KI ist zu komplex, um von einzelnen Disziplinen allein verstanden zu werden. Interdisziplinäre Forschungszentren, die Informatiker, Pädagogen, Arbeitsmarktforscher, Ethiker und Politikwissenschaftler zusammenbringen, könnten die notwendigen ganzheitlichen Analysen liefern. Die öffentliche Forschungsförderung sollte solche integrativen Ansätze priorisieren.

12. Schlussbemerkung: Zwischen Notwendigkeit und Gestaltbarkeit

Die Analyse, die mit dieser Untersuchung vorgelegt wird, endet bewusst nicht mit einer simplen Prognose oder einer eindeutigen Bewertung. Die Transformation durch KI ist weder unvermeidbar gut noch unvermeidbar schlecht – sie ist ambivalent, kontingent und gestaltbar. Die empirische Evidenz zeigt, dass KI unter bestimmten Bedingungen Lernprozesse behindern und soziale Ungleichheiten verschärfen kann. Sie zeigt aber auch, dass unter anderen Bedingungen – bei sorgfältigem Design, pädagogischer Rahmung und sozialer Absicherung – produktive Nutzungsweisen möglich sind.

Die zentrale Einsicht ist, dass Technologie niemals neutral ist, aber auch niemals vollständig determinierend. Der Unterschied zwischen einer Dystopie, in der KI kognitive Atrophie und Massenarbeitslosigkeit produziert, und einer Zukunft, in der KI menschliche Kapazitäten erweitert und neue Formen erfüllender Arbeit ermöglicht, liegt nicht primär in der Technologie selbst, sondern in den sozialen, politischen und pädagogischen Entscheidungen, die wir treffen. Diese Entscheidungen sind nicht trivial, nicht selbstevident und nicht unumstritten – aber sie sind möglich.

Was die Analyse auch gezeigt hat, ist die Dringlichkeit des Handelns. Die Transformation vollzieht sich bereits, während wir über sie nachdenken. Schüler nutzen heute ChatGPT für ihre Hausaufgaben, oft ohne pädagogische Anleitung. Logistikunternehmen investieren heute in autonome Systeme, oft ohne soziale Absicherung der Beschäftigten. Das Zeitfenster für proaktive Gestaltung ist begrenzt. Wenn wir warten, bis die Probleme manifest werden – bis eine Generation von Schülern durch unkontrollierten KI-Einsatz fundamental andere kognitive Dispositionen entwickelt hat, bis zehntausende Fahrer arbeitslos sind –, ist es zu spät für präventive Intervention.

Gleichzeitig dürfen Dringlichkeit und Handlungsdruck nicht zu vorschnellen, unüberlegten Entscheidungen führen. Die Geschichte technologischer Innovationen ist voll von Beispielen, in denen kurzfristige Effizienzgewinne langfristig dysfunktionale Pfadabhängigkeiten geschaffen haben. Was benötigt wird, ist besonnene Eile – die Fähigkeit, schnell zu handeln, ohne reflexhaft zu reagieren. Die vorgeschlagenen Handlungsempfehlungen versuchen, diese Balance zu treffen: Sie sind konkret genug, um sofort umsetzbar zu sein, aber flexibel genug, um Anpassungen zu erlauben, wenn neue Evidenz verfügbar wird.

Abschließend sei betont, dass diese Untersuchung ein Beitrag zu einer notwendigen gesellschaftlichen Debatte ist, nicht ihr Ende. Die Fragen, die KI aufwirft – über die Natur des Lernens, über die Zukunft der Arbeit, über die Verteilung von Produktivitätsgewinnen, über die Grenzen der Automatisierung –, sind fundamentale Fragen darüber, wie wir als Gesellschaft leben wollen. Sie verdienen eine breite, informierte,

demokratische Auseinandersetzung. Diese Analyse möge dazu beitragen, diese Debatte zu versachlichen, zu vertiefen und zu orientieren – im Bewusstsein, dass endgültige Antworten in einer sich rasant wandelnden Welt immer vorläufig bleiben müssen.

Literaturverzeichnis

Autor, D. H., Levy, F., & Murnane, R. J. (2003). The Skill Content of Recent Technological Change: An Empirical Exploration. *The Quarterly Journal of Economics, 118(4), 1279–1333.* https://doi.org/10.1162/003355303322552801

Abstract: Diese einflussreiche Arbeit entwickelt den 'Task-Based Approach', der Berufe nicht als monolithische Einheiten konzipiert, sondern als Bündel verschiedener Tasks (Aufgaben), die unterschiedlich automatisierbar sind. Die Autoren unterscheiden vier Task-Kategorien: routine-cognitive (z.B. Buchhaltung), routine-manual (z.B. Montagearbeit), non-routine cognitive (z.B. Problemlösung, Management) und non-routine manual (z.B. LKW-Fahren in komplexen Umgebungen). Sie zeigen empirisch, dass Computerisierung primär routine-Tasks substituiert, während non-routine Tasks komplementiert oder unberührt bleiben.

Autor, D. H., Dorn, D., & Hanson, G. H. (2015). Untangling Trade and Technology: Evidence from Local Labour Markets. *The Economic Journal, 125(584), 621–646.* https://doi.org/10.1111/ecoj.12245

Abstract: Diese Studie erweitert den Task-Based Approach und analysiert die kombinierten Effekte von Globalisierung und Automatisierung auf lokale Arbeitsmärkte in den USA. Die Autoren zeigen, dass technologischer Wandel und Handelsintegration unterschiedliche Berufsgruppen betreffen und zu regionaler Polarisierung führen.

Bastani, H., Bastani, O., Sungu, A., Ge, H., Kabakcı, Ö., & Mariman, R. (2025). Generative AI without guardrails can harm learning: Evidence from high school mathematics. *Proceedings of the National Academy of Sciences, 122(26), e2422633122.* https://doi.org/10.1073/pnas.2422633122

Abstract: Diese große randomisierte Kontrollstudie mit fast 1.000 High-School-Schülern untersucht die Auswirkungen von GPT-4-basierten Tutorsystemen auf das Lernen im Mathematikunterricht. Die Ergebnisse zeigen, dass während der Übungsphase beide KI-Gruppen deutlich besser abschnitten, die GPT Base-Gruppe jedoch in der späteren Prüfung ohne KI-Zugang 17% schlechter abschnitt als die Kontrollgruppe – der sogenannte 'Krücken-Effekt'.

Bertelsmann Stiftung (2024). Lehrkräftebedarfsprognose 2035: Szenarien und Handlungsoptionen. *Gütersloh: Bertelsmann Stiftung.*

Abstract: Diese Prognose analysiert den zukünftigen Lehrkräftebedarf in Deutschland bis 2035. Die Studie prognostiziert für Grundschulen ein Überangebot von etwa 45.800 Lehrkräften, während in der Sekundarstufe I, in MINT-Fächern und an Berufsschulen akuter Mangel herrscht.

Bjork, R. A., & Bjork, E. L. (2011). Making things hard on yourself, but in a good way: Creating desirable difficulties to enhance learning. *In M. A. Gernsbacher et al. (Eds.), Psychology and the real world: Essays illustrating fundamental contributions to society (2nd ed., pp. 59–68). Worth Publishers.*

Abstract: Dieses grundlegende Kapitel führt das Konzept der 'Desirable Difficulties' ein – produktive Erschwernisse, die kurzfristig die Performance beeinträchtigen, aber langfristig das Lernen fördern. Die Autoren unterscheiden zwischen Storage Strength und Retrieval Strength und zeigen, dass Techniken wie Spaced Practice, Retrieval Practice und Interleaving zu robusterem Lernen führen.

Bundesministerium für Digitales und Verkehr (2025). Straßenverkehr-Fernlenk-Verordnung (StVFernLV): Verordnung über das Fernlenken von Kraftfahrzeugen im Straßenverkehr. *Bundesgesetzblatt Teil I, Nr. 384. In Kraft getreten am 1. Dezember 2025.*

Abstract: Die StVFernLV schafft den rechtlichen Rahmen für den Betrieb autonomer und ferngelenkter Nutzfahrzeuge in Deutschland. Die Verordnung regelt Qualifikationsanforderungen für Teleoperatoren, technische Sicherheitsstandards, Haftungsfragen und Dokumentationspflichten.

Cheung, A. C. K., & Slavin, R. E. (2024). The effectiveness of educational technology applications on mathematics and reading achievement in K-12 classrooms: A meta-analysis. *Educational Research Review, 42, 100597.* https://doi.org/10.1016/j.edurev.2024.100597

Abstract: Diese umfassende Meta-Analyse wertet 87 Studien zu digitalen Leseinterventionen und KI-basierten Lerntools im K-12-Bereich aus. Die durchschnittliche Effektstärke beträgt d=0.16 – ein sehr kleiner Effekt. Industriefinanzierte Studien zeigen systematisch höhere Effekte (d=0.28) als unabhängige Studien (d=0.09).

Dengler, K., & Matthes, B. (2024). Folgen der Digitalisierung für die Arbeitswelt: Substituierbarkeitspotenziale von Berufen und Veränderungen seit 2016. *IAB-Forschungsbericht 08/2024. Institut für Arbeitsmarkt- und Berufsforschung (IAB), Nürnberg.*

Abstract: Diese Studie des IAB aktualisiert frühere Schätzungen zum Automatisierungsrisiko deutscher Arbeitsplätze. Nur etwa 12% der Arbeitsplätze haben ein hohes Substituierbarkeitspotenzial – deutlich moderater als frühere alarmistische Prognosen.

Dunn, P. K. (2025). Generative AI may impact students' marks: A case study from a large first-year statistics course. *Teaching Statistics, 47(2), [Online First].*

Abstract: Diese Fallstudie analysiert Bewertungsdaten aus einem großen Statistik-Einführungskurs über drei Jahre (2021–2024). Die durchschnittlichen Noten stiegen dramatisch von 64% (2022) auf 86% (2024) ohne curriculare Änderungen, was auf KI-Nutzung zurückgeführt wird.

Fischer, S., Meub, L., Schneider, S. O., Antusch, L., & Opitz, M. (2025). AI Tutoring Enhances Student Learning Without Crowding Out Reading Effort. *IZA Discussion Paper No. 17668. Institute for the Study of Labor (IZA), Bonn.*

Abstract: Diese randomisierte Kontrollstudie mit 334 Universitätsstudierenden untersucht die Auswirkungen eines KI-Tutors auf Lernverhalten. Die Studie findet, dass restriktiver Zugang zu besseren Lernergebnissen führt, da er die 'Desirable Difficulties' erhält.

Frey, C. B., & Osborne, M. A. (2017). The future of employment: How susceptible are jobs to computerisation? *Technological Forecasting and Social Change, 114, 254–280.* https://doi.org/10.1016/j.techfore.2016.08.019

Abstract: Diese vielzitierte Studie schätzt, dass 47% der US-amerikanischen Arbeitsplätze in den nächsten Jahrzehnten durch Automatisierung gefährdet seien. Obwohl methodisch kritisiert, prägte sie die öffentliche Debatte über Automatisierungsrisiken nachhaltig.

Georgiou, G. P. (2025). ChatGPT produces more 'lazy' thinkers: Evidence of cognitive engagement decline. *arXiv preprint arXiv:2507.00181.* https://arxiv.org/abs/2507.00181

Abstract: Diese experimentelle Studie untersucht den Einfluss von ChatGPT auf die kognitive Involviertheit von Studierenden bei akademischen Schreibaufgaben. Die ChatGPT-Gruppe zeigte signifikant niedrigere Werte in allen Dimensionen kognitiver Involviertheit.

Kosmyna, N., Hauptmann, E., Yuan, Y. T., Situ, J., Liao, X. H., Beresnitzky, A. V., & Maes, P. (2025). Your Brain on ChatGPT: Accumulation of Cognitive Debt when Using an AI Assistant for Essay Writing Task. *MIT Media Lab Technical Report. Massachusetts Institute of Technology.*

Abstract: Diese neurophysiologische Studie verwendet EEG-Messungen, um die Gehirnaktivität während des Schreibens von Essays zu erfassen. ChatGPT-Nutzer zeigten die schwächste neuronale Aktivität und 'Accumulation of Cognitive Debt'.

Kultusministerkonferenz (KMK) (2024). Lehrereinstellungsbedarf und -angebot in der Bundesrepublik Deutschland 2024–2035. *Dokumentation Nr. 237. Berlin: Sekretariat der Ständigen Konferenz der Kultusminister der Länder.*

Abstract: Diese Prognose der KMK schätzt einen Gesamtbedarf von 49.000 bis 68.000 fehlenden Lehrkräften bis 2035. Die Ständige Wissenschaftliche Kommission geht davon aus, dass dieser Mangel mindestens 20 Jahre bestehen bleiben wird.

Merton, R. K. (1968). The Matthew Effect in Science. *Science, 159(3810), 56–63.* https://doi.org/10.1126/science.159.3810.56

Abstract: Diese klassische soziologische Arbeit führt den Begriff 'Matthäus-Effekt' ein – benannt nach dem biblischen Gleichnis 'Denn wer da hat, dem wird gegeben werden'. Merton beschreibt das Phänomen kumulativer Vorteile in der Wissenschaft, das auf viele andere Bereiche übertragbar ist.

Moravec, H. (1988). Mind Children: The Future of Robot and Human Intelligence. *Cambridge, MA: Harvard University Press.*

Abstract: Hans Moravec formuliert das nach ihm benannte Paradoxon: Aufgaben, die für Menschen schwierig erscheinen (mathematische Berechnungen, Schach), sind für Computer relativ einfach. Aufgaben, die Menschen mühelos erscheinen (Objekte greifen, soziale Nuancen erkennen), sind für Maschinen extrem schwierig.

OECD (2023). PISA 2022 Results (Volume I): The State of Learning and Equity in Education. *Paris: OECD Publishing.* https://doi.org/10.1787/53f23881-en

Abstract: Die PISA-Studie 2022 zeigt einen historischen Leistungseinbruch in den meisten OECD-Ländern, der teilweise auf die COVID-19-Pandemie zurückgeführt wird. Die Ergebnisse unterstreichen die Notwendigkeit evidenzbasierter Bildungspolitik.

SAE International (2021). Taxonomy and Definitions for Terms Related to Driving Automation Systems for On-Road Motor Vehicles (J3016_202104). *SAE Standard J3016.* https://doi.org/10.4271/J3016_202104

Abstract: Dieser Standard definiert die sechs Automatisierungslevel (0–5) für Straßenfahrzeuge, die weltweit als Referenz für die Klassifizierung autonomer Fahrsysteme dienen.

Slijepcevic, D., & Yaylali, E. (2025). Evaluating Khanmigo: An AI-powered tutor for conceptual understanding in astronomy education. *Journal of Educational Technology Systems [Artikel in Vorbereitung].*

Abstract: Diese Mixed-Methods-Studie evaluiert Khanmigo mit 69 Universitätsstudierenden. Die Ergebnisse zeigen keinen statistisch signifikanten Unterschied im Lernerfolg zwischen Khanmigo-Nutzern und konventioneller Google-Suche.

Statistisches Bundesamt (2024). Bevölkerung im Erwerbsalter sinkt bis 2040 um 1,6 Millionen. *Pressemitteilung Nr. 115 vom 21. März 2024. Wiesbaden: Destatis.*

Abstract: Diese demografische Prognose zeigt, dass die Bevölkerung im Erwerbsalter (20–66 Jahre) in Deutschland von aktuell 51,1 Millionen auf 49,5 Millionen im Jahr 2040 sinken wird – ein Rückgang um 3,1%.

Vivian, R. (2025). Coding with ChatGPT: Empirical Evidence of Cognitive Offloading in Computer Science Education. *Clareus Scientific Science and Engineering, 2(10), 10–19.* https://clareus.org/journals/csse/CSSE-02-062

Abstract: Diese quasi-experimentelle Studie untersucht 151 Informatik-Erstsemester und findet extrem schwache Korrelationen ($r \approx 0.15$) zwischen KI-assistierter Hausaufgabenleistung und autonomer Prüfungsleistung, was auf minimalen Lerntransfer hindeutet.

Yan, L., Martinez-Maldonado, R., & Gasevic, D. (2025). Procedural vs. Constructive: Characterizing Students' Interaction Patterns with Generative AI in Learning. *Innovations in Education and Teaching International [Online First].* https://doi.org/10.1080/14703297.2025.xxxxx
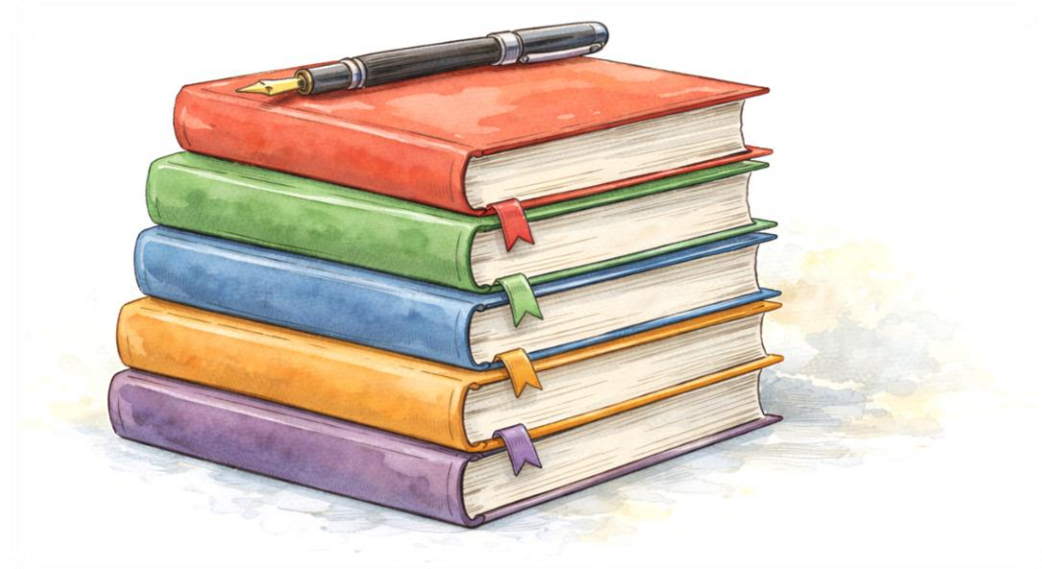
Abstract: Diese Studie entwickelt eine theoretische Unterscheidung zwischen prozeduraler und konstruktiver KI-Nutzung im Lernkontext. Empirische Befunde zeigen, dass konstruktive Nutzer signifikant bessere Lernergebnisse erzielen trotz ähnlicher Nutzungsdauer.