

Die Einrichtung einer souveränen, lokalen KI-Infrastruktur

Von der Hardware-Vorbereitung bis zum ersten privaten Chat
macOS & Windows

Leitfaden für Einsteiger und Fortgeschrittene
Stand: März 2026

1. Die wichtigste Regel: Die KI als Co-Pilot nutzen

Bevor man die erste Zeile Code tippt oder einen Installer lädt, steht die wichtigste Empfehlung dieses gesamten Leitfadens an erster Stelle: Gehen Sie diesen Weg nicht allein. Die Installation von lokaler KI-Software kann aufgrund technischer Hürden, ungewohnter Begriffe und unübersichtlicher Benutzeroberflächen einschüchternd wirken. Es ist daher absolut ratsam, sich von einer bereits verfügbaren, etablierten KI assistieren zu lassen – sei es Gemini, ChatGPT, Claude oder ein anderer Assistent Ihrer Wahl.

Der Screenshot-Trick

Das mächtigste Werkzeug für eine reibungslose Installation ist die visuelle Kommunikation mit Ihrer Begleit-KI. Wann immer ein Menü unübersichtlich erscheint, eine kryptische Fehlermeldung auftaucht oder Sie schlicht nicht wissen, wo Sie klicken sollen: Machen Sie einen Screenshot und zeigen Sie ihn Ihrer KI.

Was bringt das konkret?

- **Blindes Klicken verhindern:** Die KI erkennt sofort, welcher Button oder welches Eingabefeld gemeint ist, und kann präzise Anweisungen geben.
- **Fehlermeldungen übersetzen:** Kryptische Fehlermeldungen werden in Sekunden in verständliche Sprache übersetzt, inklusive Lösungsvorschlag.
- **Versteckte Felder finden:** Die KI zeigt exakt, in welches unscheinbare Feld ein Modellname oder eine URL eingetragen werden muss.



Praxistipp

Nutzen Sie die Bildschirmfoto-Funktion Ihres Betriebssystems (macOS: Cmd+Shift+4, Windows: Win+Shift+S) und fügen Sie den Screenshot direkt in den Chat mit Ihrer Begleit-KI ein. So wird aus einem frustrierenden Prozess eine geführte Entdeckungsreise.

Dieser Ansatz macht Sie nicht abhängig – im Gegenteil: Sie lernen mit jedem Schritt, wie die Technologie funktioniert, und bauen gleichzeitig Kompetenz auf. Die KI fungiert dabei als geduldiger Tutor, der niemals genervt reagiert.

2. Das Fundament: Ollama (Das Backend)

Ollama bildet das technische Rückgrat Ihrer lokalen KI-Infrastruktur. Es ist die Software, die die eigentlichen KI-Modelle verwaltet, auf die Hardware lädt und die Berechnungen durchführt. Man kann sich Ollama als das „Gehirn-Gehäuse“ vorstellen: Es stellt sicher, dass die Rechenleistung Ihres Computers optimal genutzt wird, damit die KI möglichst schnelle Antworten liefert.

Warum Ollama?

Ollama ist ein technisches Wunderwerk an Effizienz. Die Software erkennt automatisch, ob Ihr Rechner über einen leistungsfähigen Grafikchip (GPU) verfügt, und verteilt die Rechenlast intelligent zwischen Prozessor und Grafikkarte. Auf einem Mac mit Apple Silicon (M1, M2, M3 oder neuer) nutzt Ollama den sogenannten Unified Memory – den gemeinsamen Speicher von CPU und GPU – besonders effizient. Auf Windows-Rechnern mit NVIDIA-Grafikkarten kommt die CUDA-Beschleunigung zum Einsatz.

Die wichtigsten Vorzüge auf einen Blick:

- **Automatische Hardware-Erkennung:** Ollama wählt selbständig die optimale Berechnungsmethode.
- **Einfache Modellverwaltung:** Modelle werden mit einem einzigen Befehl heruntergeladen und gestartet.
- **Leichtgewichtig:** Ollama selbst benötigt kaum Systemressourcen und läuft unauffällig im Hintergrund.

Installation – Schritt für Schritt

Die Installation erfolgt über die offizielle Webseite **ollama.com**. Je nach Betriebssystem unterscheidet sich der Ablauf leicht:

Schritt	macOS	Windows
Download	Die .zip-Datei von ollama.com herunterladen.	Die OllamaSetup.exe von ollama.com herunterladen.
Installation	Die entpackte App in den Programme-Ordner ziehen.	Den Installer starten und den Anweisungen folgen.
Sichtbarkeit	Ein kleines Lama-Symbol erscheint oben in der Menüleiste.	Ein Lama-Symbol erscheint unten rechts im System-Tray.
Hardware	Nutzt Apple Silicon (M1/M2/M3) Unified Memory optimal.	Nutzt bevorzugt NVIDIA-Grafikkarten via CUDA-Beschleunigung.

⚠ Wichtiger Hinweis

Ollama läuft nach der Installation als Hintergrunddienst. Das Lama-Symbol in der Menüleiste (macOS) oder im System-Tray (Windows) zeigt an, dass der Dienst aktiv ist. Ollama muss laufen, bevor Sie später die Weboberfläche starten.

3. Die Isolationsschicht: Docker Desktop

Bevor wir die eigentliche Benutzeroberfläche installieren, benötigen wir eine zusätzliche Softwareschicht: Docker Desktop. Docker ist eine Technologie, die Anwendungen in sogenannten Containern isoliert. Ein Container ist eine Art abgeschlossene Blase, in der eine Software mit allem, was sie braucht, lebt – ohne das restliche System zu beeinflussen.

Warum ist Docker sinnvoll?

Man könnte Open WebUI theoretisch auch direkt installieren, aber Docker bietet drei entscheidende Vorteile:

- **Sauberes System:** Die gesamte Software für die Weboberfläche lebt in einer abgeschlossenen Umgebung. Sie verändert keine Systemeinstellungen an Ihrem Mac oder PC und kollidiert nicht mit anderer Software.
- **Sicherheit:** Falls in der Weboberfläche eine Sicherheitslücke auftreten würde, bliebe diese im Container gefangen und könnte nicht auf Ihre privaten Dateien oder das Betriebssystem zugreifen.
- **Einfaches Löschen:** Gefällt Ihnen das System nicht mehr? Löschen Sie einfach den Container, und Ihr Rechner ist sofort wieder im Originalzustand – ohne Datenmüll oder Rückstände.

Installation

macOS: Laden Sie „Docker Desktop for Mac“ von der offiziellen Webseite docker.com herunter. *Achten Sie dabei unbedingt auf die richtige Variante:* Es gibt separate Downloads für Macs mit Intel-Prozessor und für Macs mit Apple Silicon (M1/M2/M3). Die falsche Version führt zu erheblichen Leistungseinbußen.

Windows: Laden Sie „Docker Desktop for Windows“ herunter. Während der Installation werden Sie gefragt, ob das WSL2-Backend (Windows Subsystem for Linux) aktiviert werden soll – **bestätigen Sie dies unbedingt**. WSL2 sorgt dafür, dass Docker unter Windows flüssig und performant läuft. Ohne WSL2 müsste Docker auf eine ältere, deutlich langsamere Virtualisierungstechnik zurückgreifen.

Was ist WSL2?

WSL2 (Windows Subsystem for Linux 2) ist eine von Microsoft entwickelte Technologie, die es ermöglicht, eine vollständige Linux-Umgebung direkt innerhalb von Windows auszuführen. Docker nutzt diese Umgebung, um Container effizient zu betreiben. Die Aktivierung ist ein einmaliger Schritt und hat keine negativen Auswirkungen auf Ihr Windows-System.

4. Die Schaltzentrale: Open WebUI

Open WebUI ist das „Gesicht“ Ihrer lokalen KI. Es handelt sich um eine elegante Weboberfläche, die über Docker gestartet wird und anschließend bequem im Browser bedient werden kann. Die Oberfläche ähnelt dabei bewusst bekannten KI-Chatdiensten wie ChatGPT oder Claude – mit dem entscheidenden Unterschied, dass sämtliche Daten lokal auf Ihrem Rechner verbleiben.

Der Installations-Befehl

Stellen Sie sicher, dass sowohl Ollama als auch Docker Desktop gestartet sind. Öffnen Sie dann das Terminal (macOS) oder die PowerShell (Windows) und führen Sie folgenden Befehl aus:

```
docker run -d -p 3000:8080 \ --add-host=host.docker.internal:host-gateway \ -v  
open-webui:/app/backend/data \ --name open-webui \ ghcr.io/open-webui/open-  
webui:main
```

Dieser Befehl sieht auf den ersten Blick komplex aus, lässt sich aber in seine Bestandteile zerlegen:

Die Bedeutung der Parameter

-d (Detached Mode)

Der Container läuft im Hintergrund. Sie können das Terminal nach dem Start schließen, ohne dass die Anwendung stoppt.

-p 3000:8080 (Port-Mapping)

Die Software im Container denkt, sie läuft auf Port 8080. Durch dieses Mapping erreichen Sie sie bequem unter localhost:3000 in Ihrem Browser.

--add-host=host.docker.internal:host-gateway

Dies ist die lebenswichtige Brücke zwischen der Weboberfläche (im Container) und dem installierten Ollama (auf Ihrem Rechner). Ohne diesen Parameter kann Open WebUI die KI-Modelle nicht finden.

-v open-webui:/app/backend/data (Volume)

Dies ist der „Safe“ Ihrer Daten. Alle Chatverläufe und Einstellungen werden in diesem Volume gespeichert. Selbst wenn Sie den Container löschen und neu erstellen, bleiben Ihre Daten erhalten.

--name open-webui

Gibt dem Container einen sprechenden Namen, damit Sie ihn später leicht in Docker Desktop wiederfinden.

5. Erste Schritte in Open WebUI

Nach erfolgreicher Installation öffnen Sie Ihren Browser und navigieren zu:

`http://localhost:3000`

Beim ersten Aufruf müssen Sie ein lokales Benutzerkonto erstellen. Dieses Konto existiert ausschließlich auf Ihrem Rechner – es werden keine Daten an einen externen Server übermittelt. Der erste registrierte Benutzer erhält automatisch Administratorrechte.

Die größten Hürden und wie man sie meistert

Hürde 1: Die leere Oberfläche. Nach dem Login stehen Sie zunächst vor einer leeren Chat-Oberfläche. Das System hat noch kein „Wissen“ – es wurde noch kein KI-Modell heruntergeladen. Das ist normal und kein Fehler.

Hürde 2: Den Admin-Bereich finden. Die Modellverwaltung ist oft hinter dem Profilbild oder einem kleinen Zahnrad-Symbol verborgen, häufig in der unteren linken Ecke der Oberfläche. Suchen Sie nach „Admin Panel“ oder „Settings“.

Hürde 3: Versteckte Eingabefelder. Die Eingabefelder für den Modell-Download sind oft sehr dezent gestaltet – hellgrau auf weißem Hintergrund. Hier ist der Screenshot-Trick aus Abschnitt 1 besonders wertvoll.

Ein KI-Modell herunterladen

Um das erste Modell zu laden, navigieren Sie in den Admin-Bereich und suchen das Eingabefeld für den Modell-Download. Geben Sie den Namen des gewünschten Modells ein, zum Beispiel:

`qwen3:8b`

Klicken Sie anschließend auf das Download-Symbol. Das Modell wird nun aus dem Internet heruntergeladen und lokal gespeichert. Je nach Modellgröße und Internetverbindung kann dieser Vorgang einige Minuten dauern.

Empfehlenswerte Einstiegsmodelle:

Modell	Größe	Beschreibung
qwen3:8b	~5 GB	Hervorragendes Allround-Modell für vielfältige Aufgaben
llama3.1:8b	~5 GB	Starkes Open-Source-Modell von Meta
gemma3:4b	~3 GB	Kompaktes Modell von Google, gut für ältere Hardware
mistral:7b	~4 GB	Effizientes französisches Modell mit guter Mehrsprachigkeit



Zur Modellgröße

Die angegebene Größe bezieht sich auf den Download. Im Arbeitsspeicher (RAM) benötigen die Modelle etwa die gleiche Menge. Für ein 8B-Modell sollten Sie mindestens 8 GB freien RAM einplanen. Rechner mit 16 GB RAM oder mehr sind ideal.

6. Fazit: Ein System, das mitwächst

Der Weg über Ollama, Docker und Open WebUI ist am Anfang etwas steiniger als die Registrierung bei einem Cloud-Dienst. Doch der Aufwand lohnt sich, denn Sie erhalten ein System mit drei entscheidenden Eigenschaften:

- **Privat:** Kein Wort, das Sie eingeben, verlässt Ihren Rechner. Sämtliche Daten bleiben lokal – keine Cloud, kein Tracking, kein Datenschutzrisiko.
- **Modular:** Sie können heute ein Modell für allgemeine Aufgaben laden, morgen eines, das auf Medizin spezialisiert ist, übermorgen eines für Programmierung – und alle koexistieren friedlich auf Ihrem System.
- **Zukunftssicher:** Dank Docker lässt sich Open WebUI mit einem einzigen Befehl auf die neueste Version aktualisieren, ohne dass Ihre Einstellungen oder Chatverläufe verloren gehen.

✨ Zusammenfassung

Mit einer Begleit-KI an der Hand, die via Screenshots „mitschaut“, verliert selbst die komplizierteste Installation ihren Schrecken. Der Dreiklang aus Ollama (Backend), Docker (Isolation) und Open WebUI (Oberfläche) bildet ein professionelles, erweiterbares Fundament für Ihre ganz persönliche, souveräne KI-Infrastruktur.

A. Anhang: Kurzreferenz der wichtigsten Befehle

Die folgenden Terminalbefehle helfen Ihnen bei der täglichen Arbeit mit Ihrer lokalen KI-Infrastruktur:

Ollama – Modelle verwalten

```
ollama pull qwen3:8b          # Modell herunterladen
```

```
ollama list                   # Installierte Modelle anzeigen
```

```
ollama run qwen3:8b           # Modell im Terminal starten
```

```
ollama rm modellname         # Modell löschen
```

Docker – Container verwalten

```
docker start open-webui      # Container starten
```

```
docker stop open-webui       # Container stoppen
```

```
docker ps                    # Laufende Container anzeigen
```

Open WebUI – Aktualisieren

```
docker pull ghcr.io/open-webui/open-webui:main docker stop open-webui docker rm  
open-webui docker run -d -p 3000:8080 \    --add-host=host.docker.internal:host-  
gateway \    -v open-webui:/app/backend/data \    --name open-webui \  
ghcr.io/open-webui/open-webui:main
```

Durch das Volume (-v) bleiben alle Ihre Chatverläufe und Einstellungen beim Update erhalten.