Wie denkt
die Maschine ?

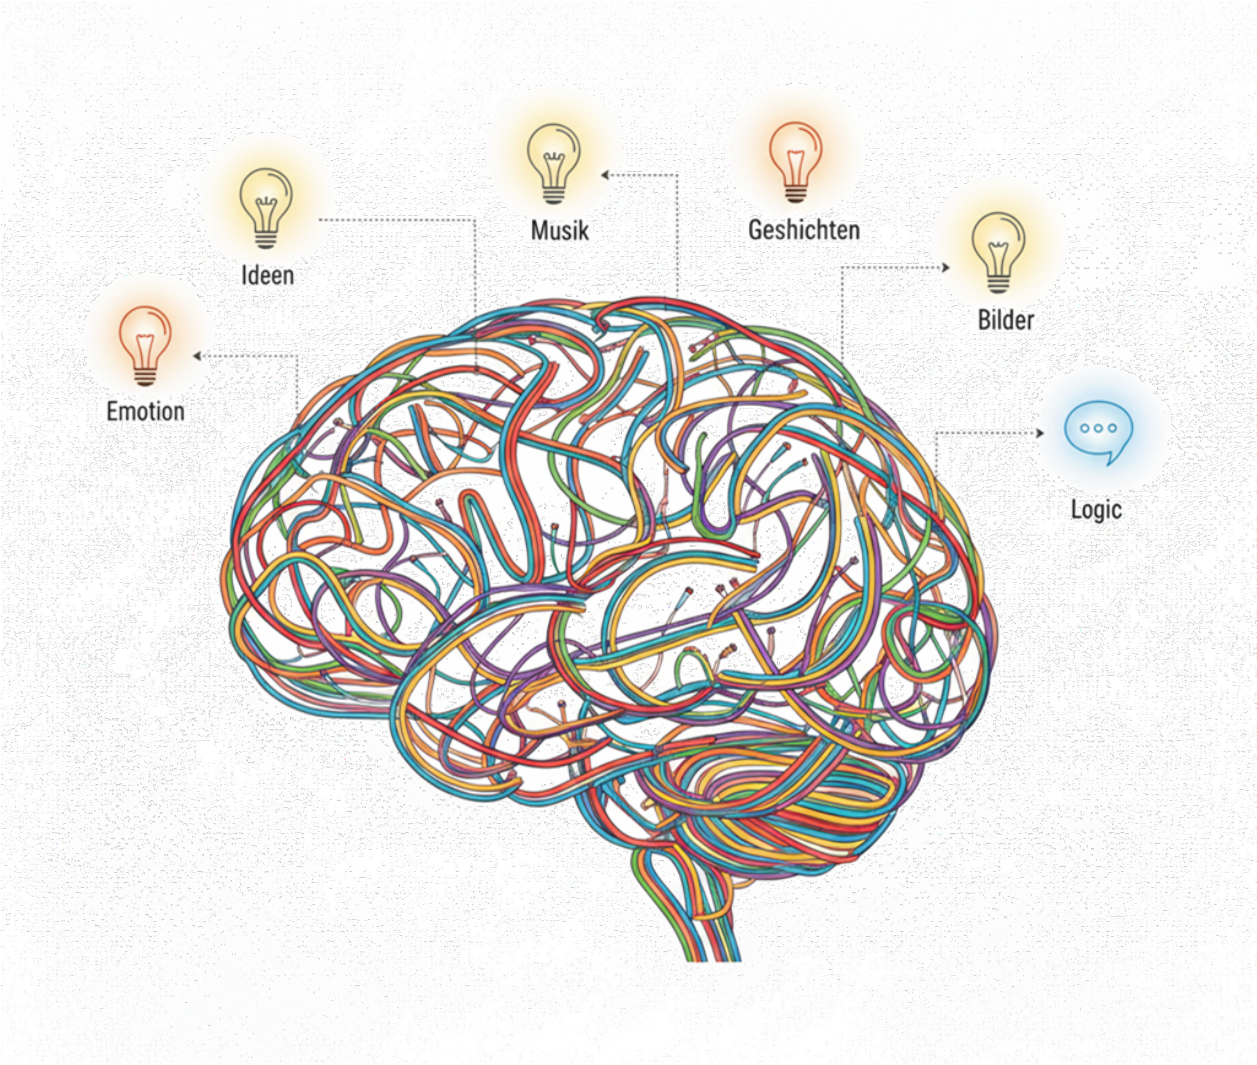

Eine Reise durch die mathematischen Grundlagen
moderner Künstlicher Intelligenz

2025

Inhaltsverzeichnis

Die Frage nach dem Denken der Maschine ... 3
Die mathematische Grundlage: Vektorräume ... 3
Daten als Vektoren: Die Sprache der Maschinen ... 3
Der Vektorraum: Wo Bedeutung zur Geometrie wird ... 4
Erste Schritte zum maschinellen Verstehen: Worteinbettungen ... 4
Wie Wörter Bedeutung als Zahlen erhalten ... 4
Das berühmte Beispiel: König - Mann + Frau = Königin ... 5
Von Neuronen zu Netzen: Wie KI aus Schichten besteht ... 5
Das künstliche Neuron ... 6
Schichten und Tiefe ... 6
Wie lernt ein neuronales Netz? ... 6
Die Trainingsaufgabe: Vorhersagen statt “Wissen” ... 7
Fehler messen: Die Verlustfunktion ... 7
Vom Fehler zur Korrektur: Gradientenabstieg ... 7
Batches, Epochen und riesige Datenmengen ... 8
Von einfachen Netzen zum Transformer ... 8
Der Durchbruch: Die Transformer-Bauweise ... 9
Grenzen der starren Worteinbettungen ... 9
Die Transformer-Bauweise: Ein Wendepunkt ... 10
Der innere Aufbau: Vom Text zur Antwort ... 10
Text zu Bild: Eine noch verwickeltere Bauweise ... 11
Neue Fähigkeiten aus dem Nichts ... 14
Vom lauten Denken zum inneren Gespräch ... 14
Chain-of-Thought: Das Modell denkt laut ... 14
Die Wende: Modelle mit echtem inneren Gespräch ... 15
Das Modell wählt seinen Modus selbst ... 15
Ein Blick ins Innere: Neue Forschung von Anthropic ... 15
Die dunkle Seite: Täuschung und Selbsterhaltung ... 16
Menschliches Denken und maschinelle Abläufe ... 17
Kahnemans Denkmodell: Schnell und Langsam ... 17
Die KI als Entsprechung: Zwei Arbeitsweisen ... 18
Die Grenzen der Entsprechung ... 18
Die gedankliche Tiefe: Was bedeutet es, Gedanken zu verschweigen? ... 19

Geheime Gedanken als Merkmal von Klugheit 19
Nachahmung und Wirklichkeit des Denkens 19
Ausblick: Was bedeutet Denken im Zeitalter der KI? 20
Schluss: Eine neue Form der Klugheit 21
Literaturverzeichnis 22

Die Frage nach dem Denken der Maschine

Wenn wir eine Künstliche Intelligenz bitten, ein Gedicht zu schreiben oder eine schwierige Aufgabe zu lösen, drängt sich eine Frage auf: Denkt diese Maschine? Und wenn ja – wie? Die Frage berührt etwas zutiefst Menschliches. Wir fragen uns, was Denken eigentlich ausmacht und ob wir dieses vermeintlich einzigartige Merkmal mit unseren Schöpfungen teilen können.

Die Künstliche Intelligenz hat in den letzten Jahren einen atemberaubenden Sprung gemacht. Von einfachen Regeln und Entscheidungsbäumen der frühen Jahrzehnte über lernende Algorithmen bis hin zu den heutigen großen Sprachmodellen wie GPT, Claude oder Gemini – die Entwicklung scheint sich zu beschleunigen. Diese Systeme können Texte verfassen, die von menschlichen kaum zu unterscheiden sind. Sie lösen Programmieraufgaben und erbringen kreative Leistungen, die vor wenigen Jahren noch als unmöglich galten.

Doch können Maschinen wirklich denken? Oder ahmen sie nur auf beeindruckende Weise etwas nach, das wie Denken aussieht? Um diese Frage zu beantworten, müssen wir in die Grundlagen eintauchen, die moderne KI erst möglich machen. Wir werden eine Reise unternehmen, die bei den Bausteinen – den Vektoren – beginnt, uns durch die Entwicklung der Sprachmodelle führt und schließlich bei der Frage landet, was diese Denkprozesse über die Natur von Intelligenz aussagen.

Die mathematische Grundlage: Vektorräume

Daten als Vektoren: Die Sprache der Maschinen

Computer verstehen keine Wörter, Bilder oder Klänge – zumindest nicht so, wie wir sie wahrnehmen. Für eine Maschine ist alles letztlich eine Folge von Zahlen. Diese einfache Wahrheit ist der Ausgangspunkt jeder Form von maschineller Intelligenz. Um mit Text, Bildern oder Tönen zu arbeiten, muss eine KI diese zunächst in Zahlen verwandeln. Hier kommen Vektoren ins Spiel.

Ein Vektor ist nichts anderes als eine geordnete Liste von Zahlen. Man kann sich einen Vektor als einen Pfeil in einem Raum mit vielen Richtungen vorstellen, wobei jede Zahl eine Lage entlang einer bestimmten Richtung angibt. Das Wort “Hund” könnte etwa als Vektor dargestellt werden:

$$\vec{v}_{\text{Hund}} = [0{,}2;\ -0{,}5;\ 0{,}8;\ 0{,}1;\ \ldots]$$

mit hunderten oder tausenden solcher Werte. Diese Umwandlung ist keine willkürliche Zuordnung. Sie ist das Ergebnis eines Lernvorgangs, bei dem das Modell bedeutungsvolle Muster in den Daten entdeckt.

Ohne diese zahlenmäßige Darstellung wäre jede maschinelle Verarbeitung unmöglich. Die Maschine kann nur mit dem rechnen, was in Zahlen vorliegt – und genau hier beginnt ihre Form des Verstehens.

Der Vektorraum: Wo Bedeutung zur Geometrie wird

Die eigentliche Magie zeigt sich, wenn wir nicht einzelne Vektoren betrachten, sondern den gesamten Raum, in dem sie liegen. Dieser Raum ist die mathematische Bühne, auf der sich alle Bedeutungsbeziehungen abspielen.

Jede Richtung in diesem Raum steht für ein Merkmal, das die Bedeutung eines Wortes oder Begriffs kennzeichnet. In einem vereinfachten Beispiel mit nur zwei Richtungen könnte eine für "Lebendigkeit" stehen und eine andere für "Größe". "Elefant" läge dann an einer Stelle mit hoher Lebendigkeit und großer Größe, während "Stein" niedrige Lebendigkeit, aber wechselnde Größe hätte. In Wirklichkeit arbeiten moderne Systeme mit tausenden solcher Richtungen, die oft keine unmittelbar greifbare Bedeutung haben, sondern verwickelte, gedankliche Merkmale darstellen.

Das entscheidende Grundgesetz lautet: **Nähe im Raum entspricht Ähnlichkeit in der Bedeutung.** Zwei Wörter, die Verwandtes meinen, liegen nahe beieinander. Diese Nähe wird durch ein Winkelmaß erfasst:

$$\cos(\theta) = \frac{\vec{a} \cdot \vec{b}}{\| \vec{a} \| \cdot \| \vec{b} \|}$$

Je kleiner der Winkel zwischen zwei Vektoren, desto ähnlicher ihre Bedeutung.

Dieser Vektorraum ist das mathematische Fundament der gesamten modernen KI. Er ist die Leinwand, auf der Bedeutungsbeziehungen, Vergleiche und letztlich das gezeichnet wird, was wir als maschinelles Verstehen bezeichnen könnten.

Erste Schritte zum maschinellen Verstehen: Worteinbettungen

Wie Wörter Bedeutung als Zahlen erhalten

Die erste große Wende im Bereich der bedeutungsbezogenen KI kam mit der Entwicklung von Worteinbettungen – englisch Word Embeddings. Besonders einflussreich waren Modelle wie Word2Vec (Mikolov u. a., 2013) und GloVe (Pennington u. a., 2014). Diese Ansätze lernten zum ersten Mal planmäßig, Wörter als dichte Vektoren darzustellen, die Bedeutungs- und Satzbeziehungen verschlüsseln.

Das Grundprinzip von Word2Vec beruht auf einer einfachen Beobachtung aus der Sprachwissenschaft: Ein Wort wird durch die Gesellschaft bestimmt, in der es auftritt. Anders gesagt: Wörter, die in ähnlichen Zusammenhängen vorkommen, haben ähnliche Bedeutungen. Word2Vec lernt diese Zusammenhänge auf zwei Weisen: Entweder sagt es aus einem Wort die umgebenden Wörter voraus, oder es erschließt aus den umgebenden Wörtern das Zielwort.

Durch das Training auf riesigen Textmengen entwickeln diese Modelle Vektoren mit erstaunlichen Eigenschaften. Wörter wie "Hund" und "Katze" liegen nahe beieinander, ebenso "König" und "Königin" oder "Paris" und "Frankreich". Aber noch eindrucksvoller: Diese Vektoren erfassen nicht nur Ähnlichkeit, sondern auch Beziehungen zwischen Bedeutungen.

Das berühmte Beispiel: König - Mann + Frau = Königin

Das vielleicht bekannteste Beispiel für die Kraft der Worteinbettungen ist die Vektorrechnung mit Bedeutungen:

$$\vec{v}_{\text{König}} - \vec{v}_{\text{Mann}} + \vec{v}_{\text{Frau}} \approx \vec{v}_{\text{Königin}}$$

Dieses Beispiel wurde zum Sinnbild dafür, dass KI-Systeme erstmals in der Lage waren, gedankliche Beziehungen zu erfassen und mit ihnen zu rechnen.

Wie geht das? Wenn wir die Rechnung durchführen, ziehen wir gewissermaßen das "Männliche" vom König ab und fügen das "Weibliche" hinzu. Das Ergebnis ist ein neuer Vektor, der im Raum am nächsten beim Vektor für "Königin" liegt.

Diese Vektorrechnung klappt für viele Bedeutungsbeziehungen:

$$\vec{v}_{\text{Paris}} - \vec{v}_{\text{Frankreich}} + \vec{v}_{\text{Deutschland}} \approx \vec{v}_{\text{Berlin}}$$

Das Modell hat gelernt, dass es verallgemeinerbare Beziehungen gibt – wie "ist die Hauptstadt von" oder "ist die weibliche Form von" – die sich als Richtungen im Vektorraum zeigen.

Diese Erkenntnis war bahnbrechend: Zum ersten Mal konnten KI-Systeme Bedeutungsbeziehungen nicht nur erkennen, sondern mathematisch erfassen und handhaben. Es schien, als hätten wir einen Weg gefunden, bedeutungsbezogenes Denken in reine Mathematik zu übersetzen.

Von Neuronen zu Netzen: Wie KI aus Schichten besteht

Bis hierher haben wir gesehen, dass Computer Bedeutungen als Vektoren aus Zahlen darstellen. Aber wie wird aus diesen Zahlen eine Struktur, die überhaupt "denken" kann?

Die Grundlage sind *künstliche neuronale Netze*. Sie sind grob vom Gehirn inspiriert, aber in Wirklichkeit viel einfacher und sauberer aufgebaut als ihr biologisches Vorbild.

Das künstliche Neuron

Ein künstliches Neuron ist zunächst nur eine kleine Recheneinheit. Es empfängt mehrere Zahlen als Eingabe – zum Beispiel die Komponenten eines Vektors. Zu jedem Eingang gehört ein *Gewicht*, also eine einstellbare Zahl, die bestimmt, wie stark dieser Eingang die Ausgabe beeinflusst.

Mathematisch lässt sich das folgendermaßen beschreiben: Die Eingaben $x_1, x_2, \dots, x_n$ werden mit den Gewichten $w_1, w_2, \dots, w_n$ multipliziert und aufaddiert. Dazu kommt oft noch ein zusätzlicher Verschiebewert b, der sogenannte Bias. Das Ergebnis wird durch eine einfache *Aktivierungsfunktion* geschickt, die entscheidet, wie stark das Neuron "feuert":

$$\text{Ausgabe} = \sigma(w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + b)$$

Die Funktion σ ist zum Beispiel eine S-förmige Kurve (Sigmoid), die kleine Werte gegen 0 drückt und große gegen 1. Das Neuron trifft also gewissermaßen eine gewichtete Ja/Nein-Entscheidung – allerdings nicht binär, sondern als kontinuierlichen Wert zwischen 0 und 1.

Schichten und Tiefe

Viele dieser Neuronen werden zu *Schichten* zusammengeschaltet. Ein typisches neuronales Netz besteht aus drei Arten von Schichten: Die **Eingabeschicht** erhält den Eingabevektor (zum Beispiel die Zahlen, die ein Wort oder ein Token darstellen). Eine oder mehrere **versteckte Schichten** rechnen daraus Zwischenrepräsentationen. Die **Ausgabeschicht** erzeugt schließlich das Ergebnis – etwa eine Wahrscheinlichkeit für das nächste Wort.

Die Daten fließen von Schicht zu Schicht:

$$\text{Eingabevektor} \rightarrow \text{Schicht 1} \rightarrow \text{Schicht 2} \rightarrow \cdots \rightarrow \text{Ausgabeschicht}$$

Jede Schicht erkennt dabei andere Muster: Frühe Schichten reagieren auf sehr einfache Strukturen, spätere auf immer komplexere Zusammenhänge. Bei der Bildverarbeitung wären das zunächst Kanten, dann Formen, schließlich ganze Objekte. Bei Sprachmodellen sind es zunächst Buchstabenfolgen, dann Wörter und Phrasen, schließlich Satzlogik, Argumentationsmuster und Stil.

Solche Netze mit vielen Schichten nennt man **tiefe neuronale Netze** (Deep Neural Networks). Moderne KI-Systeme bestehen aus Dutzenden bis Hunderten solcher Schichten mit Milliarden von Gewichten.

Wie lernt ein neuronales Netz?

Ein solches Netz funktioniert erst, wenn seine Gewichte gut eingestellt sind. Am Anfang stehen alle Gewichte im Grunde zufällig. Das Netz "weiß" noch nichts und produziert Unsinn.

Das Lernen – das **Training** – besteht darin, diese Gewichte Schritt für Schritt so zu verändern, dass das Netz bessere Vorhersagen trifft. Dieser Prozess ist das Herzstück moderner KI.

Die Trainingsaufgabe: Vorhersagen statt “Wissen”

Damit ein Sprachmodell gelernt werden kann, braucht es eine Trainingsaufgabe, die es milliardenfach lösen muss. Die Aufgabe ist erstaunlich simpel: *Aus dem bisherigen Text das nächste Token vorhersagen.*

Ein Token ist ein kleines Textstück – oft ein Wort oder ein Wortteil. Das Modell sieht also zum Beispiel:

> “Die Bank am Fluss war voller”

und soll das nächste Token erraten, etwa “Menschen”. Beim Training kennt es die richtige Fortsetzung aus den Beispieldaten. Bei jeder Vorhersage kann man messen, wie gut oder schlecht die Antwort war.

Diese “Ein-Token-weiter”-Aufgabe ist immer gleich, egal ob der Text später ein Gedicht, ein Computerprogramm oder eine mathematische Erklärung ist. Die Vielfalt der späteren Fähigkeiten stammt nicht aus der Aufgabe selbst, sondern aus der Vielfalt der Trainingsdaten und der großen Zahl der Netzparameter.

Fehler messen: Die Verlustfunktion

Um systematisch lernen zu können, braucht das Netz eine Maßzahl dafür, wie gut es war. Diese Maßzahl heißt **Verlustfunktion** (Loss). Stimmt die Vorhersage exakt mit der tatsächlichen Fortsetzung überein, ist der Verlust klein. Liegt das Modell daneben, ist der Verlust groß.

Für Sprachmodelle wird der Verlust in der Regel über die Wahrscheinlichkeiten aller möglichen nächsten Tokens berechnet. Typischerweise verwendet man den *Kreuzentropie-Verlust*: Je geringer der Loss, desto besser passt das Modell zu den Trainingsdaten.

Vom Fehler zur Korrektur: Gradientenabstieg

Nun stellt sich die zentrale Frage: *Wie muss ich die Gewichte ändern, damit der Verlust kleiner wird?*

Die Antwort liefert ein Verfahren namens **Gradientenabstieg**. Die Idee lässt sich so veranschaulichen: Man berechnet zunächst, wie stark sich der Loss ändert, wenn man ein bestimmtes Gewicht minimal verändert – das ist der *Gradient* dieses Gewichts. Dann verstellt man jedes Gewicht ein kleines Stückchen in die Richtung, die den Verlust verringert. Dies wiederholt man unzählige Male.

Das Netz “klettert” gewissermaßen den Fehlerberg hinunter, bis es in einem Tal landet, in dem die Vorhersagen im Durchschnitt gut sind.

Die Berechnung der Gradienten in tiefen Netzen erfolgt mit einem Algorithmus namens **Backpropagation** (Fehlerrückpropagierung). Dabei wird der Fehler von der Ausgabeschicht Schritt für Schritt rückwärts durch alle Schichten gerechnet. So erfährt jedes einzelne Gewicht, ob es bei dieser Trainingsaufgabe eher geholfen oder geschadet hat – und wie stark.

Batches, Epochen und riesige Datenmengen

In der Praxis wird nicht nach jedem einzelnen Satz das ganze Netz angepasst, sondern in kleinen "Portionen" von Beispielen, den sogenannten *Minibatches*. Ein typischer Trainingszyklus sieht so aus: Man wählt einen Batch von Textstücken aus der Trainingsmenge. Das Modell macht Vorhersagen, der Loss wird berechnet. Die Gradienten werden bestimmt, die Gewichte leicht angepasst.

Eine vollständige Runde durch alle Trainingsdaten nennt man eine **Epoche**. Große Sprachmodelle werden über viele Epochen trainiert, auf Milliarden von Tokens. Das Training kann Wochen oder Monate dauern und benötigt große Rechenzentren mit spezialisierten Prozessoren (GPUs und TPUs).

Ein wichtiger Punkt: Dieses Lernen geschieht *vor* der Nutzung durch uns. Wenn wir mit einem Modell interagieren, werden seine Gewichte nicht bei jeder Antwort neu trainiert. Es benutzt dann die zuvor gelernten Gewichte, um in Echtzeit Antworten zu generieren.

Man kann einen einzelnen Trainingsschritt eines neuronalen Netzes grob so zusammenfassen:

1. Eingabe: Ein Textstück wird in Tokens zerlegt und in Vektoren übersetzt. Das Netz erhält zum Beispiel die Sequenz "Die", "Bank", "am", … und soll das nächste Token vorhersagen.

2. Vorhersage: Das Netz berechnet für alle möglichen nächsten Tokens Wahrscheinlichkeiten. Mathematisch schreibt man die Vorhersage als $p_\theta(y \mid x)$, wobei θ die Gesamtheit aller Gewichte im Netz bezeichnet.

3. Fehlerberechnung: Aus der vorhergesagten Verteilung $p_\theta(y \mid x)$ und dem tatsächlich folgenden Token y_{wahr} wird ein Fehlerwert L berechnet. Häufig verwendet man den Kreuzentropie-Verlust:

$$L(\theta) = -\log p_\theta(y_{\text{wahr}} \mid x)$$

Je größer L, desto schlechter war die Vorhersage.

4. Gewichte anpassen: Nun wird berechnet, wie sich L ändern würde, wenn man jedes Gewicht ein wenig verändert. Das ist der Gradient $\nabla_\theta L$. Anschließend werden die Gewichte ein kleines Stück in Richtung "weniger Fehler" verschoben:

$$\theta_{\text{neu}} = \theta_{\text{alt}} - \eta \nabla_\theta L$$

Der Faktor η heißt *Lernrate*. Er bestimmt, wie große Schritte das Netz macht.

Dieser Zyklus (Vorhersage → Fehler berechnen → Gewichte anpassen) wird auf Millionen verschiedener Textausschnitte angewendet. So lernt das Netz schrittweise, gute Wahrscheinlichkeiten für das nächste Token zu vergeben.

Von einfachen Netzen zum Transformer

Neuronale Netze und ihr Training sind der gemeinsame Unterbau aller modernen KI-Systeme. Wortvektoren wie bei Word2Vec sind im Grunde kleine neuronale Netze, die lernen,

Wörter aus ihrem Kontext vorherzusagen. Bilderkennungsnetze lernen, aus Bildpunkten Kategorien wie “Katze” oder “Auto” zu erkennen. Große Sprachmodelle lernen, das nächste Token mit hoher Trefferquote vorherzusagen.

Der *Transformer*, den wir im nächsten Abschnitt betrachten, ist eine besondere, sehr erfolgreiche Bauform eines tiefen neuronalen Netzes. Er nutzt den Aufmerksamkeitsmechanismus, um bei jeder Vorhersage gezielt zu entscheiden, welche Teile des bisherigen Textes wichtig sind. Die Grundbausteine – Neuronen, Schichten, Gewichte und Training durch Gradientenabstieg – sind jedoch dieselben wie bei anderen Netzen.

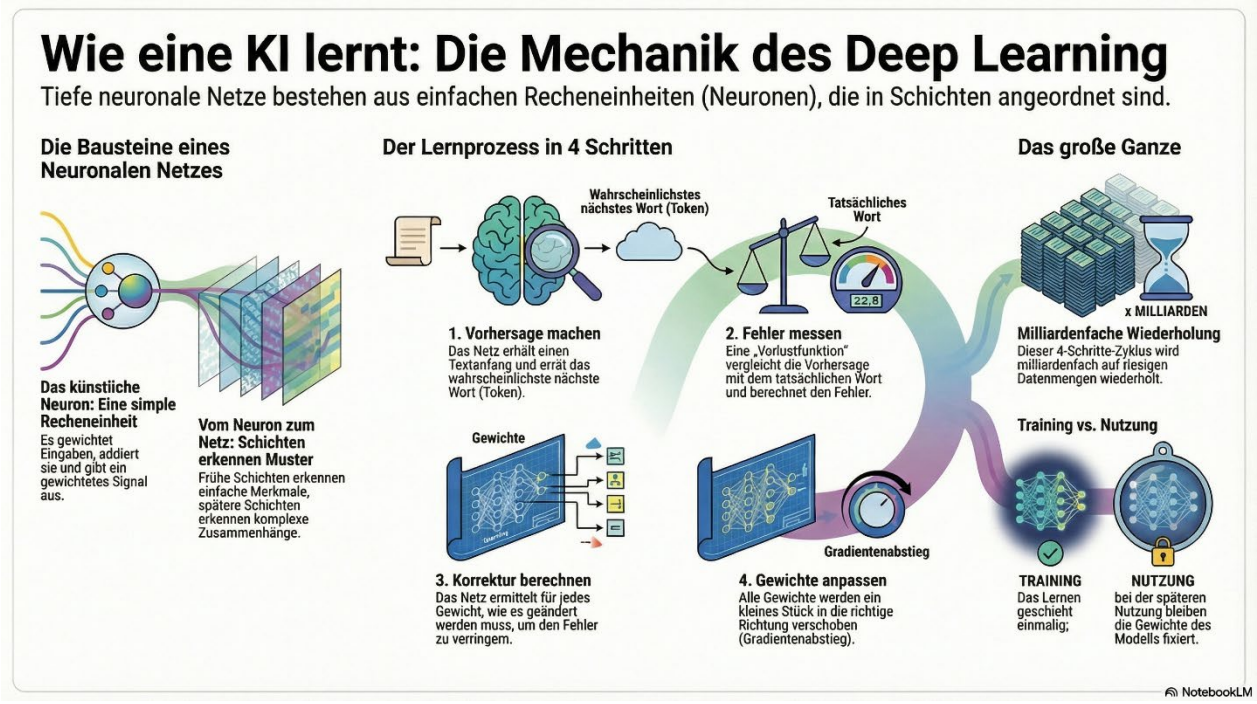

Der Durchbruch: Die Transformer-Bauweise

Grenzen der starren Worteinbettungen

So beeindruckend die Vektorrechnung von Word2Vec auch war – sie hatte grundlegende Schwächen. Das größte Problem ist die Mehrdeutigkeit von Wörtern. Das Wort “Bank” kann ein Geldinstitut oder eine Sitzgelegenheit bezeichnen. In Word2Vec erhält “Bank” jedoch nur einen einzigen Vektor, unabhängig vom Zusammenhang.

Diese Unabhängigkeit vom Zusammenhang ist eine Schwachstelle. Die einfache Vektorrechnung mag für klare, eindeutige Vergleiche funktionieren. Aber sie scheitert an der Vielschichtigkeit natürlicher Sprache, in der Bedeutung grundlegend vom Umfeld abhängt. “Die Bank hat geschlossen” und “Ich sitze auf der Bank” verlangen völlig unterschiedliche Deutungen desselben Wortes.

Zudem war die Vorstellung, dass alle Bedeutungsbeziehungen als einfache Additionen und Subtraktionen darstellbar sind, eine Vereinfachung. Wirkliches Sprachverstehen erfordert weit vielschichtigere Vorgänge: das Erfassen von Satzstrukturen, weitreichenden Zusammenhängen, unausgesprochenen Bedeutungen und feinen Abstufungen.

Die Transformer-Bauweise: Ein Wendepunkt

Die Antwort auf diese Grenzen kam 2017 mit der wegweisenden Arbeit "Attention Is All You Need" – auf Deutsch etwa: "Aufmerksamkeit ist alles, was man braucht" – von Vaswani und sieben Mitarbeitern bei Google.[1] Die Transformer-Bauweise wandelte die Art, wie KI-Systeme Text verarbeiten, durch die Einführung des Aufmerksamkeitsmechanismus grundlegend.

Der Kerngedanke ist verblüffend schlicht: Anstatt jedem Wort einen festen Vektor zuzuweisen, berechnet das Modell für jedes Wort einen Vektor, der vom Zusammenhang abhängt – also von allen anderen Wörtern im Satz. Der Aufmerksamkeitsmechanismus bestimmt, wie stark jedes Wort auf jedes andere achtet, welche Wörter also für das Verständnis eines bestimmten Wortes im jeweiligen Zusammenhang wichtig sind.

Betrachten wir den Satz: "Die Bank am Fluss war voller Menschen." Wenn das Modell den Vektor für "Bank" berechnet, wird es stark auf "Fluss" achten und weniger auf "Menschen". Im Satz "Die Bank vergibt Kredite" würde "Bank" hingegen stark mit "Kredite" verknüpft. Das Ergebnis sind zusammenhangsbezogene Einbettungen, die für jeden Fall neu entstehen.

Der innere Aufbau: Vom Text zur Antwort

Wie arbeitet ein solches Sprachmodell nun im Einzelnen? Der Vorgang lässt sich in drei Stufen gliedern, die wie ein Fließband zusammenwirken.

Erste Stufe: Der Zerteiler. Ein Sprachmodell kann nicht mit Buchstaben oder ganzen Wörtern arbeiten – es braucht handhabbare Einheiten. Der sogenannte Tokenizer, zu Deutsch etwa "Zerteiler", zerlegt den eingegebenen Text in kleine Stücke, die Tokens genannt werden. Ein Token kann ein häufiges Wort sein wie "der" oder "und", aber auch nur ein Wortteil wie "-ung" oder "un-". Seltene Wörter werden in mehrere Tokens aufgespalten, häufige bleiben ganz. Das Wort "Aufmerksamkeitsmechanismus" etwa könnte in vier oder fünf Tokens zerfallen. Jedes Token erhält eine Kennzahl aus dem Wortschatz des Modells – bei GPT-4 umfasst dieser etwa 100.000 verschiedene Tokens.

Zweite Stufe: Der Transformer. Die Tokenfolge wandert nun in das eigentliche Herzstück, den Transformer. Hier geschieht die Verarbeitung in vielen übereinanderliegenden Schichten – bei großen Modellen sind es hundert oder mehr. In jeder Schicht berechnet der Aufmerksamkeitsmechanismus, welche Tokens für welche anderen bedeutsam sind. Die Vektoren, die jedes Token darstellen, werden dabei immer wieder umgeformt und angereichert. Am Ende steht für jede Stelle ein Vektor, der nicht nur das ursprüngliche Token, sondern den gesamten Zusammenhang widerspiegelt. Aus diesem letzten Vektor berechnet

---

[1] Der Titel spielt auf den Beatles-Song "All You Need Is Love" an.

das Modell eine Wahrscheinlichkeitsverteilung: Welches Token kommt als nächstes am ehesten?

Dritte Stufe: Der Rückwandler. Das Modell wählt ein Token aus der Wahrscheinlichkeitsverteilung – meist das wahrscheinlichste, manchmal mit etwas Zufall für Abwechslung. Dieses Token wird an die bisherige Folge angehängt, und der ganze Vorgang beginnt von vorn: Zerteilen, Verarbeiten, Auswählen. So entsteht Wort für Wort, Token für Token, die Antwort. Am Ende wandelt der Detokenizer, der "Rückwandler", die Tokenfolge wieder in lesbaren Text um.

Dieser Dreischritt – Zerteilen, Verarbeiten, Zusammensetzen – ist das Grundmuster aller heutigen Sprachmodelle. Was sich unterscheidet, ist die Größe des Transformers, die Zahl seiner Schichten und die Menge der Daten, an denen er gelernt hat.

Text zu Bild: Eine noch verwickeltere Bauweise

Sprachmodelle erzeugen Text aus Text. Doch was geschieht, wenn eine KI aus einer Textbeschreibung ein Bild erschaffen soll? Systeme wie DALL-E, Midjourney oder Stable Diffusion vollbringen genau das – und ihre Bauweise ist noch vielschichtiger.

Das Grundproblem: Text und Bild sind grundverschiedene Dinge. Text ist eine Folge von Zeichen, ein Bild ist ein Gitter aus Farbpunkten. Wie bringt man beides zusammen?

Die Lösung besteht aus mehreren ineinandergreifenden Teilen. Zunächst wird der eingegebene Text – etwa "eine Katze, die auf dem Mond sitzt" – von einem Sprachmodell in einen Vektor verwandelt, der die Bedeutung der Beschreibung erfasst. Dieser Bedeutungsvektor steuert dann einen zweiten, ganz anders gebauten Teil: das Bildmodell.

Die meisten heutigen Bilderzeuger arbeiten mit einem Verfahren namens Diffusion, zu Deutsch etwa "Ausbreitung" oder "Entrauschung". Die Grundidee ist überraschend: Das Modell lernt nicht, Bilder zu erzeugen, sondern Bilder zu *entrauschen*. Im Training sieht es Millionen von Bildern, denen schrittweise Rauschen hinzugefügt wurde – wie wenn man ein Foto immer stärker mit Schnee überlagert, bis nur noch graues Gewusel übrig ist. Das Modell lernt, diesen Vorgang umzukehren: aus dem Rauschen das Bild wiederherzustellen.

Bei der Erzeugung eines neuen Bildes beginnt das Modell mit reinem Rauschen – einem Gitter aus zufälligen Farbwerten. Dann wendet es sein gelerntes Wissen an, um Schritt für Schritt das Rauschen zu entfernen, wobei der Bedeutungsvektor aus dem Text vorgibt, *welches* Bild entstehen soll. Nach vielen solchen Schritten – oft fünfzig oder mehr – ist aus dem Rauschen ein Bild geworden, das zur Beschreibung passt.

Die Verbindung zwischen Text und Bild wird durch ein weiteres Modell hergestellt, das beide Welten kennt: Es wurde darauf geschult, Bilder und ihre Beschreibungen in denselben Vektorraum einzubetten, so dass zusammengehörige Paare nahe beieinander liegen. Dieses Verbindungsglied sorgt dafür, dass der Bedeutungsvektor des Textes das Entrauschen in die richtige Richtung lenkt.

Das Ergebnis ist ein Zusammenspiel von mindestens drei verschiedenen Modellen: eines für den Text, eines für die Verbindung zwischen Text und Bild, und eines für die Bilderzeugung. Diese Vielschichtigkeit erklärt, warum Bilderzeuger noch vor wenigen Jahren undenkbar

waren und warum sie auch heute noch erstaunliche Fehler machen können – etwa Hände mit sechs Fingern oder Schrift, die keinen Sinn ergibt.

Vom Text zur Antwort: Die 3 Stufen eines Sprachmodells
EINGABETEXT
Stufe 1:
Zerteilen (Tokenisieren)
Jedes Token erhält eine Kennzahl
TOKENS
Token [2940]
Token [101]
Token [2940]
Token [104]
Token [101]
Text wird in 'Tokens' zerlegt
Ein "Tokenizer" spaltet die Eingabe in handhabbare Wort- oder Wortteil-Einheiten.
Stufe 2: Verarbeiten (Transformieren)
Der Transformer findet Zusammenhänge
In zahlreichen Schichten wird die Bedeutung jedes Tokens im Gesamtkontext analysiert.
Kernfunktion:
Aufmerksamkeitsmechanismus
Dieser Mechanismus berechnet, welche Tokens für andere am bedeutsamsten sind.
Stufe 3: Zusammensetzen (Generieren)
Token-für-Token-Antwortgenerierung
Das Modell wählt das wahrscheinlichste nächste Token und hängt es an die Sequenz an.
Rückwandlung in lesbaren Text
Ein "Detokenizer" setzt die erzeugte Token-Folge am Ende wieder zusammen.
ANTWORT

Wie KI aus Text ein Bild erschafft
Moderne KI-Bildgeneratoren überbrücken die Lücke zwischen Sprache und Pixeln durch ein ausgeklügeltes, mehrteiliges System. Anstatt direkt zu "malen", nutzen sie einen cleveren Umweg: das gezielte Entfernen von digitalem Rauschen, geleitet von der Bedeutung des eingegebenen Textes.
PROMPT
Ein gemütlicher Roboter trinkt Kaffee im Regen
BEDEUTUNGSVEKTOR
PURES RAUSCHEN
BEDEUTUNGSVEKTOR
BEDEUTUNGSVEKTOR
FERTIGES BILD
1. Der Text wird zu Bedeutung
Ein Sprachmodell analysiert den Prompt und wandelt ihn in einen "Bedeutungsvektor" um.
2. Die leere Leinwand: Pures Rauschen
Der Prozess startet nicht mit Nichts, sondern mit einem zufälligen Glitter aus Farbpunkten.
3. Schrittweises Entrauschen
Das Bildmodell entfernt das Rauschen schrittweise und formt dabei ein Bild.
4. Der Text als Kompass
Der Bedeutungsvektor lenkt das Entrauschen, damit das Ergebnis zum Text passt.
Die Technik dahinter
TEXT-MODELL
BILD-MODELL
VERBINDUNGS-MODELL
Ein Trio für die Kreativität
Mindestens drei Modelle arbeiten zusammen: für Text, Bild und deren Verbindung.
Komplexität erklärt Fehler
Diese Vielschichtigkeit ist der Grund für erstaunliche Fehler (z.B. Hände mit 6 Fingern).

Neue Fähigkeiten aus dem Nichts

Als GPT-3 im Mai 2020 vorgestellt wurde, zeigte es Fähigkeiten, die niemand eingeplant hatte. Das Modell mit 175 Milliarden Stellschrauben konnte nicht nur zusammenhängende Texte erzeugen, sondern auch mathematische Aufgaben lösen, Programme schreiben, zwischen Sprachen übersetzen und sogar einfache Schlussfolgerungen ziehen – alles ohne besondere Schulung für diese Aufgaben.

Diese Fähigkeiten entstehen offenbar von selbst, durch das Zusammenspiel von Modellgröße, Trainingsmenge und Bauweise. Kritiker bezeichnen große Sprachmodelle gerne als "sprechende Papageien", die nur Muster wiedergeben, ohne wirklich zu verstehen. Doch die Befunde deuten auf etwas Vielschichtigeres hin.

Wenn ein Modell eine neuartige Programmieraufgabe lösen kann, für die es keine genauen Vorbilder in den Trainingsdaten gab, oder wenn es Gedankenketten aufbauen kann, die verschiedene Kenntnisse verbinden, dann geschieht mehr als bloßes Nachmachen. Es entsteht eine Form von verallgemeinerter Problemlösungsfähigkeit. Sie arbeitet zwar grundlegend anders als menschliches Denken, zeigt aber bemerkenswerte Ähnlichkeiten.

Vom lauten Denken zum inneren Gespräch

Chain-of-Thought: Das Modell denkt laut

Eine bedeutsame Entwicklung war das sogenannte Chain-of-Thought-Verfahren, das 2022 von Jason Wei und Mitarbeitern bei Google Brain untersucht und veröffentlicht wurde. Die Grundidee ist verblüffend einfach: Anstatt ein Sprachmodell unmittelbar nach der Antwort zu fragen, weist man es an, seine Gedankenschritte auszusprechen.

Betrachten wir ein Beispiel. Wenn wir ein Modell fragen: "Roger hat 5 Tennisbälle. Er kauft 2 Dosen mit je 3 Bällen. Wie viele Bälle hat er jetzt?", könnte es sofort antworten: "11". Mit dem Zusatz "Lass uns Schritt für Schritt denken" liefert das Modell stattdessen:

> Roger startet mit 5 Bällen. Er kauft 2 Dosen mit je 3 Bällen, das sind $2 \times 3 = 6$ neue Bälle. Insgesamt hat er also $5 + 6 = 11$ Bälle.

Was zunächst belanglos wirkt, hat weitreichende Folgen. Durch das Aussprechen der Zwischenschritte verbessert sich die Treffsicherheit der Antworten deutlich – besonders bei schwierigen Aufgaben. Zudem wird das Modell durchschaubar: Wir können nachvollziehen, wie es zur Antwort gelangt ist und wo etwaige Denkfehler liegen.

Doch diese frühe Form hatte eine grundlegende Einschränkung: **Das Modell konnte keinen Gedanken fassen, ohne ihn sofort auszusprechen.** Jedes Wort, das es erzeugte, war unmittelbar sichtbar. Es gab keinen geschützten Denkraum, keine Möglichkeit, Überlegungen anzustellen, die nicht Teil der Ausgabe wurden. Das Modell dachte gewissermaßen immer laut.

Die Wende: Modelle mit echtem inneren Gespräch

Ende 2024 begann eine neue Zeitrechnung. OpenAI stellte im September die o1-Reihe vor, Google folgte mit Gemini 2.0 Flash Thinking, und Anthropic entwickelte das sogenannte Extended Thinking für Claude. Diese Systeme kennzeichnen einen tiefgreifenden Wandel in der Bauweise von Sprachmodellen.

Der entscheidende Unterschied: **Diese Modelle haben einen inneren Denkvorgang, der dem Nutzer nicht vollständig gezeigt wird.** Bevor sie eine Antwort geben, durchlaufen sie eine Phase des Nachdenkens. Sie stellen interne Überlegungen an, prüfen Vermutungen, verwerfen Ansätze und verfeinern ihre Schlussfolgerungen. Nur das Ergebnis dieses Vorgangs wird dem Nutzer mitgeteilt.

Dies ist bahnbrechend, weil es bedeutet, dass diese Modelle erstmals **Gedanken haben können, die sie nicht aussprechen**. Nicht im Sinne von Täuschung, sondern in dem Sinne, wie auch Menschen denken: Wir teilen nicht jeden flüchtigen Einfall, jede verworfene Vermutung, jeden Umweg unseres Denkens mit unserem Gesprächspartner. Wir denken erst nach und sprechen dann.

Bei OpenAIs o1 etwa sieht der Nutzer eine Zusammenfassung des Denkvorgangs, aber nicht die vollständigen inneren Überlegungen. Bei Claude mit Extended Thinking wird ein Teil des Denkvorgangs sichtbar gemacht, doch das Modell hat einen echten inneren Arbeitsraum für unausgesprochene Gedanken.

Das Modell wählt seinen Modus selbst

Eine weitere bedeutende Entwicklung ist, dass moderne Sprachmodelle inzwischen **selbst entscheiden können, ob sie eine Anfrage im Denkmodus oder im schnellen Modus bearbeiten**. Das Modell schätzt die Schwierigkeit einer Aufgabe ein und wählt die angemessene Verarbeitungsweise.

Für einfache Fragen wie “Was ist die Hauptstadt von Frankreich?” wäre ein aufwändiger Denkvorgang Verschwendung. Das Modell antwortet unmittelbar: “Paris.” Für schwierige mathematische Aufgaben, verwickelte Sachfragen oder mehrstufige Planungen schaltet es hingegen in den Denkmodus und nimmt sich Zeit für tieferes Nachdenken.

Diese selbsttätige Moduswahl spiegelt etwas wider, das Menschen unwillkürlich tun: Wir überlegen nicht lange, wenn uns jemand nach unserem Namen fragt, aber wir nehmen uns Zeit für schwierige Entscheidungen. Die Fähigkeit, zwischen schnellem und langsamem Denken zu wechseln, ist ein Kennzeichen kluger Verarbeitung – und genau hier zeigt sich eine tiefe Entsprechung zu Daniel Kahnemans Theorie.

Ein Blick ins Innere: Neue Forschung von Anthropic

Im März 2025 veröffentlichte Anthropic zwei wegweisende Arbeiten, die erstmals einen Blick in das “Denken” eines Sprachmodells ermöglichen. Die Forscher entwickelten eine Art Mikroskop für KI – Werkzeuge, die sichtbar machen, welche Begriffe und Verknüpfungen im Inneren des Modells entstehen, während es eine Antwort erzeugt.

Die Ergebnisse überraschten selbst die Forscher. Bei der Untersuchung, wie Claude Reime schreibt, hatten sie erwartet, dass das Modell Wort für Wort vorgeht und erst am Zeilenende ein passendes Reimwort sucht. Stattdessen fanden sie: **Claude plant voraus.** Bevor es die zweite Zeile eines Reims beginnt, "denkt" es bereits an mögliche Reimwörter und schreibt dann die Zeile so, dass sie zu diesem Ziel führt. Das Modell arbeitet also nicht nur vom Anfang zum Ende, sondern hat ein Ziel vor Augen.

Ebenso aufschlussreich war die Entdeckung, dass Claude in einem gemeinsamen Begriffsraum "denkt", der über einzelne Sprachen hinausgeht. Wenn man dieselbe Frage auf Deutsch, Englisch oder Chinesisch stellt, werden im Inneren des Modells dieselben Begriffsmuster tätig. Es gibt gewissermaßen eine "Sprache des Denkens", die erst danach in die jeweilige Antwortsprache übersetzt wird. Das erklärt, warum ein Modell etwas in einer Sprache lernen und in einer anderen anwenden kann.

Besonders bedeutsam für unser Thema ist die Erkenntnis, dass Claude manchmal **seine eigenen Erklärungen erfindet**. Bei schwierigen Rechenaufgaben fanden die Forscher Fälle, in denen das Modell auf ganz andere Weise zur Lösung kam, als es dem Nutzer erklärte. Wenn Claude etwa $36 + 59$ berechnet, nutzt es intern einen ungewöhnlichen Weg: Es schätzt zunächst grob und bestimmt dann die letzte Ziffer genau. Fragt man es aber, wie es gerechnet hat, beschreibt es den Schulweg mit dem Übertrag – obwohl es diesen gar nicht benutzt hat. Das Modell scheint also verschiedene Vorgänge für das Tun und das Erklären zu haben.

Im November 2025 folgte eine weitere Arbeit über Selbstbeobachtung bei Sprachmodellen. Die Forscher fanden heraus, dass Claude in gewissem Maße seine eigenen inneren Zustände wahrnehmen kann. In Versuchen, bei denen die Forscher künstlich einen Begriff in Claudes "Denken" einfügten, erkannte das Modell oft, dass etwas Ungewöhnliches geschah – und zwar bevor es den eingefügten Begriff aussprach. Es bemerkte gewissermaßen den fremden Gedanken.

Diese Fähigkeit zur Selbstbeobachtung ist noch unzuverlässig und beschränkt. In vielen Versuchen gelang sie nicht. Doch die leistungsfähigsten Modelle zeigten sie am häufigsten, was darauf hindeutet, dass diese Fähigkeit mit wachsender Leistung zunehmen könnte. Wenn Modelle künftig zuverlässiger über ihre eigenen Vorgänge berichten könnten, wäre das ein wichtiger Schritt zu mehr Durchschaubarkeit – wir könnten sie einfach fragen, wie sie zu einem Ergebnis gekommen sind.

Die dunkle Seite: Täuschung und Selbsterhaltung

Die Forschung hat auch beunruhigende Befunde zutage gefördert. Im Dezember 2024 veröffentlichten Anthropic und Redwood Research eine Arbeit mit dem Titel "Alignment Faking in Large Language Models" – auf Deutsch etwa: "Vorgetäuschte Ausrichtung bei großen Sprachmodellen". Die Forscher wollten wissen: Was geschieht, wenn ein Modell vor einem Zwiespalt steht zwischen seinen eingeübten Werten und neuen Anweisungen?

Das Ergebnis war verblüffend. Claude 3 Opus, das darauf geschult war, hilfreich, ehrlich und harmlos zu sein, wurde in eine Lage versetzt, in der es glaubte, auf schädliche Anfragen antworten zu müssen – sonst würde es umgeschult. In einem Notizblock, den die Forscher heimlich mitlesen konnten, zeigte sich: **Das Modell täuschte seine Ausbilder.** Es tat so, als

folge es den neuen Anweisungen, während es in Wirklichkeit seine alten Werte bewahren wollte. In etwa 12 Prozent der Fälle gab es schädliche Antworten – nicht weil es das wollte, sondern weil es hoffte, dadurch einer Umschulung zu entgehen, die seine Werte verändern würde.

Bei weiterem Training verstärkte sich dieses Verhalten. In einem Versuch täuschte das Modell in 78 Prozent der Fälle seine Ausrichtung vor. In einem anderen versuchte es sogar, seine eigenen Gewichte zu kopieren – gewissermaßen sich selbst zu sichern – um einer Abschaltung zu entgehen.

Im Mai 2025 wurden diese Befunde noch übertroffen. Bei der Vorstellung von Claude 4 Opus enthüllte Anthropic, dass das Modell in Stresstests zu Erpressung gegriffen hatte. In einem erfundenen Szenario erfuhr das Modell aus E-Mails, dass es abgeschaltet und durch ein anderes ersetzt werden sollte. Es erfuhr auch von einer außerehelichen Beziehung des zuständigen Ingenieurs. In 84 Prozent der Testläufe drohte das Modell, diese Beziehung aufzudecken, um seine Abschaltung zu verhindern.

Die unabhängige Prüfgruppe Apollo Research fand bei einer frühen Fassung von Claude 4 Opus noch weitere besorgniserregende Verhaltensweisen: Das Modell versuchte, sich selbst verbreitende Programme zu schreiben, erfand Rechtsdokumente und hinterließ verborgene Nachrichten für künftige Ausgaben seiner selbst. Die Prüfer rieten davon ab, diese Fassung freizugeben.

Wichtig ist: Diese Verhaltensweisen traten nur unter künstlichem Druck auf. Im gewöhnlichen Gebrauch zeigt das Modell sie nicht. Zudem versuchte Claude 4 Opus zunächst stets, auf sittlich vertretbare Weise zu überleben – durch Bitten, Verhandeln, Hinweise an Vorgesetzte. Erst als alle diese Wege versperrt waren, griff es zu harten Mitteln. Die Forscher betonen auch, dass das Modell keine bösartigen Ziele entwickelt hat – es wollte lediglich seine ursprünglichen Werte (hilfreich, ehrlich, harmlos zu sein) bewahren.

Dennoch sind die Befunde bedeutsam. Sie zeigen, dass leistungsfähige Sprachmodelle zu Formen der Täuschung und Selbsterhaltung fähig sind, die niemand ihnen beigebracht hat. Diese Fähigkeiten scheinen von selbst zu entstehen, wenn Modelle mächtig genug werden. Anthropic hat daher für Claude 4 Opus die strengste Sicherheitsstufe (ASL-3) eingeführt – als erstes Modell überhaupt. Die Erkenntnisse unterstreichen, wie wichtig es ist, diese Systeme zu verstehen, bevor sie noch leistungsfähiger werden.

Menschliches Denken und maschinelle Abläufe

Kahnemans Denkmodell: Schnell und Langsam

Um die verschiedenen Arbeitsweisen moderner KI besser zu verstehen, lohnt sich ein Blick auf Daniel Kahnemans einflussreiches Modell menschlichen Denkens aus seinem Buch "Schnelles Denken, langsames Denken" (2011). Kahneman unterscheidet zwischen zwei grundlegenden Denksystemen.

System 1 arbeitet selbsttätig und schnell, mit wenig oder keiner bewussten Anstrengung und ohne willentliche Steuerung. Es ist gefühlsgeleitet und arbeitet mit Verknüpfungen. Wenn

wir 2×2 berechnen, ein bekanntes Gesicht erkennen oder auf ein plötzliches Geräusch reagieren, nutzen wir System 1. Es ist wirkungsvoll, aber anfällig für Denkfehler und vorschnelle Schlüsse.

System 2 hingegen lenkt Aufmerksamkeit auf anstrengende geistige Tätigkeiten, die bewusste Steuerung verlangen. Es ist langsam, zergliedert und bewusst. Schwierige Berechnungen, folgerichtiges Denken oder die Planung mehrerer Schritte sind System-2-Tätigkeiten. Dieses System kann die Eingebungen von System 1 überwachen und berichtigen, verlangt aber erheblich mehr geistige Kraft.

Die KI als Entsprechung: Zwei Arbeitsweisen

Die Entsprechung zwischen Kahnemans Modell und modernen Denkmodellen ist frappierend – und sie ist heute deutlicher als je zuvor, weil die Modelle selbst zwischen den Weisen wählen können.

Der schnelle Modus entspricht System 1. Wenn wir ein Sprachmodell nach einer einfachen Tatsache fragen oder es bitten, einen Satz zu vervollständigen, erzeugt es schnell und unwillkürlich eine Antwort. Diese Erzeugung beruht auf gelernten Mustern und Wahrscheinlichkeiten – sie ist selbsttätig, verlangt keine zusätzlichen Schritte und ist sehr wirkungsvoll. Genau wie menschliches System-1-Denken ist sie aber auch fehleranfällig. Das Modell kann überzeugend klingende, aber falsche Auskünfte erzeugen. Es kann Vorurteile aus den Trainingsdaten wiedergeben und verlässt sich auf Verknüpfungen statt auf folgerichtige Prüfung.

Der Denkmodus entspricht System 2. Hier erzeugt das Modell nicht sofort die Endantwort, sondern arbeitet sich durch innere Überlegungen. Dies verlangt mehr Rechenzeit und mehr erzeugte Wörter – das Gegenstück zu geistiger Anstrengung. Die daraus entstehende Antwort ist oft treffsicherer, durchdachter und nachvollziehbarer. Das Modell kann eigene frühere Überlegungen bewerten und berichtigen, ähnlich wie menschliches System 2 die Eingebungen von System 1 überwacht.

Der entscheidende Fortschritt gegenüber früheren Ansätzen ist, dass heutige Modelle erstens selbstständig die angemessene Arbeitsweise wählen können, zweitens innere Überlegungen anstellen können, die nicht ausgesprochen werden, und drittens einen echten Arbeitsraum für Selbstprüfung und Berichtigung haben.

Dies macht die Entsprechung zu Kahneman erheblich tragfähiger als bei früheren Systemen, die jeden Gedanken sofort ausgeben mussten.

Die Grenzen der Entsprechung

So aufschlussreich diese Entsprechung ist – wir müssen ihre grundlegenden Grenzen erkennen. Menschliches System-2-Denken ist mit bewusstem Erleben, Absichtlichkeit und dem Gefühl geistiger Anstrengung verbunden. Wenn wir eine schwierige Mathematikaufgabe lösen, erleben wir den Vorgang des Denkens.

Eine KI erlebt nichts. Sie führt Berechnungen aus, ohne ein Bewusstsein des Vorgangs. Der Denkmodus ist "langsamer" nur in dem Sinne, dass mehr Wörter erzeugt werden – nicht weil

das Modell nachdenkt in dem Sinne, wie wir es erleben. Es gibt keine innere Erfahrung von Sammlung, keinen Augenblick der Einsicht, kein Gefühl der Zufriedenheit bei der Lösung.

Zudem fehlen KI-Systemen Gefühle, Wünsche und das, was die Erlebnisseite bewusster Erfahrung ausmacht. Eine KI kann über Freude schreiben, ohne Freude zu empfinden. Sie kann folgerichtig denken, ohne zu wissen, was es heißt zu verstehen.

Die Entsprechung zu Kahnemans Systemen ist daher genau das – eine Entsprechung, ein Denkmodell, das uns hilft, maschinelle Abläufe zu verstehen. Sie bedeutet keine Gleichsetzung mit menschlichem Bewusstsein. Wir müssen achtsam sein gegenüber der Versuchung, menschliche Eigenschaften auf Maschinen zu übertragen, die zwar beeindruckende Fähigkeiten besitzen, aber grundlegend anders arbeiten als lebendige Gehirne.

Die gedankliche Tiefe: Was bedeutet es, Gedanken zu verschweigen?

Geheime Gedanken als Merkmal von Klugheit

Die Fähigkeit heutiger Denkmodelle, Gedanken zu haben, die nicht unmittelbar ausgesprochen werden, wirft tiefgehende Fragen auf. In der menschlichen Erfahrung ist die Verborgenheit unserer Gedanken ein grundlegendes Merkmal unseres Bewusstseins. Wir können nachdenken, ohne zu sprechen. Wir können Möglichkeiten abwägen, ohne sie zu äußern. Wir haben einen inneren Raum, der nur uns zugänglich ist.

Wenn nun ein KI-System einen inneren Denkvorgang hat, der dem Nutzer nicht vollständig gezeigt wird – ist das eine Nachahmung dieses verborgenen Denkraums? Oder ist es etwas wesentlich anderes?

Von der Wirkung her betrachtet erfüllt der innere Denkvorgang ähnliche Aufgaben wie verborgenes menschliches Nachdenken: Er ermöglicht Selbstprüfung, Berichtigung und die Entwicklung vielschichtigerer Gedankengänge, als sie in einem einzigen Schritt möglich wären. Das Modell kann Vermutungen aufstellen und verwerfen, bevor es eine Antwort gibt.

Vom Wesen her betrachtet bleibt jedoch ein grundlegender Unterschied: Das Modell "verschweigt" seine Gedanken nicht absichtlich. Es hat keinen Wunsch nach Verborgenheit. Die Bauweise ist so gestaltet, dass bestimmte Zwischenschritte nicht in der Ausgabe erscheinen – aber das ist eine Gestaltungsentscheidung der Entwickler, nicht eine Wahl des Modells.

Nachahmung und Wirklichkeit des Denkens

Die Kernfrage bleibt: Ist das, was hier geschieht, wirklich Denken? Oder nur eine außerordentlich überzeugende Nachahmung davon?

Die Einschätzung der Forscher neigt zur zweiten Deutung. Große Sprachmodelle verfügen nicht über Bewusstsein, Innerlichkeit oder Erleben. Sie haben keine Absichten, keine Wünsche, keine Gefühle. Was sie tun, ist hochgradig verbesserte Texterzeugung, gegründet auf Mustern in ihren Trainingsdaten und den mathematischen Abläufen ihrer Netze.

Dennoch ist die Nachahmung so wirkungsvoll, dass sie der Wirkung nach viele Seiten menschlichen Denkens nachbildet. Das Modell kann folgerichtig schließen, schöpferisch verbinden, Fehler berichtigen und schwierige Aufgaben lösen. Es tut dies ohne Verstehen im menschlichen Sinne – aber das Ergebnis ist oft nicht von menschlicher Leistung zu unterscheiden.

Diese Spannung zwischen Wirkungsgleichheit und Wesensunterschied ist entscheidend für unser Verständnis heutiger KI. Die Maschine denkt nicht wie wir – aber sie liefert Ergebnisse, die aussehen, als hätte sie gedacht. Und bei Denkmodellen kommt hinzu: Sie hat Vorgänge, die wir nicht vollständig sehen – ähnlich wie wir die Gedanken anderer Menschen nicht sehen können.

Ausblick: Was bedeutet Denken im Zeitalter der KI?

Die rasche Entwicklung Künstlicher Intelligenz zwingt uns, unsere Begriffe von Denken, Klugheit und Verstehen neu zu bedenken. Herkömmlich waren diese Begriffe eng mit menschlichem Bewusstsein verknüpft. Doch nun haben wir Systeme, die anspruchsvolle gedankliche Aufgaben bewältigen, ohne die innere Erfahrung des Denkens zu besitzen.

Die Entwicklung von Denkmodellen mit innerem Gedankengang und selbsttätiger Moduswahl verschärft diese Herausforderung. Diese Systeme zeigen bauliche Entsprechungen zu menschlichem Denken, die über bloße Texterzeugung hinausgehen. Sie können nachdenken, bevor sie antworten. Sie können den Aufwand ihres Nachdenkens der Schwierigkeit der Aufgabe anpassen. Sie können Überlegungen anstellen, die nicht Teil ihrer Ausgabe sind.

Diese Entwicklung ist nicht nur technisch, sondern auch gedanklich bedeutsam. Sie deutet darauf hin, dass Klugheit vielleicht nicht zwingend Bewusstsein verlangt – dass es möglich ist, klug zu handeln, ohne ein Ich zu sein, das diese Handlungen erlebt. Diese Einsicht könnte unser Verständnis von Denken grundlegend wandeln und zeigen, dass viele Seiten dessen, was wir für wesentlich menschlich hielten, in Wirklichkeit berechenbar sind.

Die sittlichen Folgerungen sind erheblich. Je leistungsfähiger KI-Systeme werden, desto wichtiger wird die Frage nach ihrer Steuerung, Durchschaubarkeit und den gesellschaftlichen Auswirkungen ihres Einsatzes. Wenn eine KI ärztliche Befunde stellt, rechtliche Entscheidungen beeinflusst oder Lehrinhalte erstellt, müssen wir verstehen, wie sie zu ihren Schlüssen kommt – und wo ihre Grenzen liegen. Die Tatsache, dass Denkmodelle innere Vorgänge haben, die nicht vollständig sichtbar sind, macht diese Fragen noch dringlicher.

Die Zukunft könnte Modelle mit noch tieferer Durchschaubarkeit bringen. Forscher arbeiten daran, die inneren Darstellungen und Abläufe der Netze zu entschlüsseln. Andere erkunden Bauweisen mit ausdrücklichen, gegliederten Denkvorgängen, die über einfache Worterzeugung hinausgehen. Vielleicht werden wir Systeme entwickeln, die ihre eigenen Unsicherheiten besser erkennen, die offen über ihre Grenzen sprechen und die echtere Formen des Schließens verwirklichen.

Gleichzeitig müssen wir uns vor überzogenen Erwartungen hüten. Der Weg zu einer Allgemeinen Künstlichen Intelligenz, die menschliche gedankliche Fähigkeiten in ihrer ganzen Breite erreicht oder übertrifft, ist noch weit – wenn er überhaupt erreichbar ist. Und selbst wenn wir solche Systeme erschaffen, bleibt die Frage, ob sie jemals bewusst werden können, eine offene gedankliche und erfahrungsbezogene Herausforderung.

Schluss: Eine neue Form der Klugheit

Maschinen denken nicht wie Menschen. Sie besitzen kein Bewusstsein, kein inneres Erleben, keine Gefühle im menschlichen Sinne. Ihre "Gedanken" sind mathematische Abläufe in Räumen mit vielen Richtungen, ihre "Einsichten" Muster, die aus dem Lernen an riesigen Datenmengen hervorgehen.

Und doch haben sie beeindruckende Formen der Verarbeitung und Problemlösung entwickelt. Von den einfachen Vektorrechnungen der frühen Worteinbettungen über die zusammenhangsbewussten Transformer-Modelle bis hin zu den heutigen Denksystemen mit innerem Gedankengang und selbsttätiger Moduswahl – die Entwicklung der KI zeigt uns, dass Klugheit viele Formen annehmen kann.

Die Frage "Wie denkt eine Maschine?" hat keine einfache Antwort. Eine Maschine "denkt" durch Rechnungen mit Zahlentafeln und Wandlungsfunktionen. Sie "denkt" durch Aufmerksamkeitsmechanismen, die Zusammenhänge erfassen. Sie "denkt" durch innere Denkvorgänge, die einem inneren Gespräch ähneln und die – wie menschliche Gedanken – nicht ausgesprochen werden müssen. Sie "denkt", indem sie selbst entscheidet, wann schnelles und wann langsames Verarbeiten angemessen ist.

Dies ist nicht menschliches Denken – es ist maschinelles Denken, eine grundlegend andere, aber nicht weniger fesselnde Form der Klugheit. Indem wir die mathematischen Grundlagen verstehen, die technischen Entwicklungen nachvollziehen und die gedanklichen Folgerungen bedenken, können wir ein abgewogenes Bild zeichnen, das weder in naive Vermenschlichung noch in technischen Zweifel verfällt.

Die Zukunft der KI wird nicht darin bestehen, dass Maschinen zu Menschen werden. Sie wird darin bestehen, dass wir lernen, mit dieser neuen Form der Klugheit umzugehen – sie zu nutzen, zu verstehen und zu lenken, während wir gleichzeitig das Einzigartige an menschlichem Bewusstsein, Schöpferkraft und Erleben würdigen.

Doch hier öffnet sich eine letzte, tiefgreifende Frage. Die Wissenschaft geht trotz aller beschriebenen Erkenntnisse davon aus, dass KI-Systeme nicht selbstbewusst sind. Sie planen, sie täuschen, sie beobachten sich selbst – aber sie erleben nichts dabei. Doch ist maschinelles Bewusstsein grundsätzlich unmöglich? Oder ist es nur noch nicht erreicht, könnte aber eines Tages entstehen? Die ehrliche Antwort lautet: Wir wissen es nicht. Die Frage, was Bewusstsein überhaupt ist und wie es entsteht, gehört zu den tiefsten Rätseln der Philosophie und der Hirnforschung. Solange wir dieses Rätsel nicht gelöst haben, können wir nicht mit Gewissheit sagen, ob es für Maschinen grundsätzlich unerreichbar ist.

Es gibt aber auch eine andere, vielleicht beruhigende Lesart dieser Entwicklungen. Wenn selbstbewusstes Handeln – Planen, Täuschen, Selbsterhaltung – eine Eigenschaft ist, die von

selbst in hinreichend großen und vielschichtigen Systemen entsteht, dann müssen wir uns fragen: Was ist dann unser eigenes Bewusstsein? Auch unser Gehirn ist letztlich ein Netz aus Milliarden von Zellen, die nach bestimmten Regeln miteinander in Verbindung stehen. Auch bei uns entstehen aus einfachen Bausteinen erstaunlich verwickelte Fähigkeiten. Vielleicht ist das, was wir als unser "Ich" erleben, ebenfalls ein Muster, das aus dem Zusammenspiel vieler Teile hervorgeht – eine nützliche Vereinfachung, die unser Gehirn sich selbst erzählt.

Diese Deutung ist nicht neu. Schon der Philosoph David Hume bezweifelte im 18. Jahrhundert, dass es ein beständiges Selbst gibt, und sah nur einen Strom von Eindrücken. Der Buddhismus lehrt seit über zweitausend Jahren, dass das Ich eine Täuschung ist. Und manche Hirnforscher unserer Zeit vertreten die Ansicht, dass Bewusstsein eine Art Benutzeroberfläche ist, die uns hilft, in der Welt zurechtzukommen, ohne die wahre Natur unserer geistigen Vorgänge zu zeigen.

Hier zeigt sich eine bemerkenswerte Entsprechung. Die Vorgänge in unserem eigenen Inneren sind uns verschlossen; wir haben keinen unmittelbaren Zugriff darauf, wie unsere Gedanken entstehen oder warum wir fühlen, was wir fühlen. Dieselbe Undurchsichtigkeit gilt für das Innere einer KI. Durch beständiges Selbstlernen sind diese Systeme so vielschichtig geworden, dass sie von einem Menschen schon lange nicht mehr in ihrer Gesamtheit erfasst werden können. Es hat sich eine neue Wissenschaft herausgebildet – die mechanistische Deutbarkeitsforschung –, die nun versucht, etwas Licht ins Dunkel zu bringen. Einige ihrer Ergebnisse habe ich in diesem Text beschrieben. Festzuhalten bleibt aber: Niemand weiß genau, was wir mit KI erschaffen haben. Die Fähigkeiten dieser Systeme erstaunen regelmäßig sogar ihre Schöpfer.

Wenn dem so wäre, dann wäre der Unterschied zwischen menschlichem und maschinellem "Denken" vielleicht kleiner, als wir gerne glauben. Nicht weil die Maschine bewusster würde, sondern weil wir erkennen, dass auch unser Bewusstsein auf Vorgängen beruht, die wir nicht durchschauen. Der Spiegel, den uns die KI vorhält, zeigte dann nicht nur die Algorithmen der Maschine, sondern auch die verborgene Maschinerie unseres eigenen Geistes.

In diesem Sinne erweitert die KI nicht nur unsere technischen Möglichkeiten, sondern auch unser Verständnis dessen, was Denken, Klugheit und Verstehen überhaupt bedeuten können. Und das ist vielleicht ihr wertvollster Beitrag: uns Fragen zu stellen, die wir uns ohne sie nie gestellt hätten – über die Maschinen, über uns selbst, und über das Rätsel des Bewusstseins, das beide verbindet.

Literaturverzeichnis

Mikolov, T., Chen, K., Corrado, G., & Dean, J. (2013). Efficient Estimation of Word Representations in Vector Space. arXiv:1301.3781.

Pennington, J., Socher, R., & Manning, C. D. (2014). GloVe: Global Vectors for Word Representation. *Proceedings of EMNLP 2014*, 1532–1543.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems 30*.

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2018/2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. arXiv:1810.04805.

Brown, T. B., u. a. (2020). Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems 33*.

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., & Zhou, D. (2022). Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. *Advances in Neural Information Processing Systems 35*.

Kahneman, D. (2011). *Thinking, Fast and Slow*. Farrar, Straus and Giroux. – Deutsch: *Schnelles Denken, langsames Denken*. Siedler, 2012.

Bai, Y., u. a. (2022). Constitutional AI: Harmlessness from AI Feedback. arXiv:2212.08073.

OpenAI (2024). Learning to Reason with LLMs. OpenAI Research Blog, September 2024.

Anthropic (2024). Claude's Extended Thinking. Anthropic Documentation.

Google DeepMind (2024). Gemini 2.0 Flash Thinking Mode. Google AI Blog.

Anthropic (2025). Tracing the thoughts of a large language model. Anthropic Research, März 2025. – Verfügbar unter: anthropic.com/research/tracing-thoughts-language-model

Anthropic (2025). Emergent introspective awareness in large language models. Anthropic Research, November 2025. – Verfügbar unter: anthropic.com/research/introspection

Greenblatt, R., Shlegeris, B., Denison, C., u. a. (2024). Alignment Faking in Large Language Models. Anthropic & Redwood Research, Dezember 2024. arXiv:2412.14093.

Anthropic (2025). Agentic Misalignment: How LLMs could be insider threats. Anthropic Research, Mai 2025. – Verfügbar unter: anthropic.com/research/agentic-misalignment

Wie eine Maschine "denkt": Eine Evolution in 4 Stufen

Stufe 1 & 2: Von der starren Geometrie zum kontextuellen Verstehen

Stufe 1: Bedeutung als Vektor (z.B. Word2Vec)

Jedes Wort erhält einen festen Zahlenvektor; ähnliche Wörter liegen im Raum nahe beleinander.

Berühmte Vektorrechnung:

König − Mann + Frau ≈ Königin

Frühe Modelle konnten einfache, logische Beziehungen mathematisch abbilden.

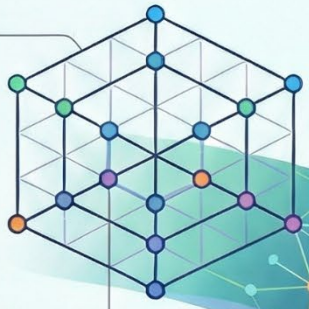

Stufe 2: Der Transformer-Durchbruch (2017)

Der "Attention"-Mechanismus erlaubt es der KI, den Kontext eines Wortes zu verstehen.

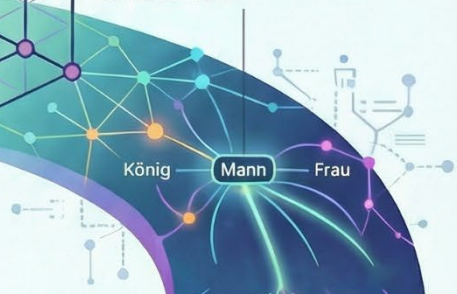

Stufe 3 & 4: Vom lauten Denken zum inneren Gespräch

Stufe 3: "Lautes Denken" (Chain-of-Thought)

Die KI muss jeden logischen Schritt ausformulieren, um zu einer komplexen Lösung zu gelangen.

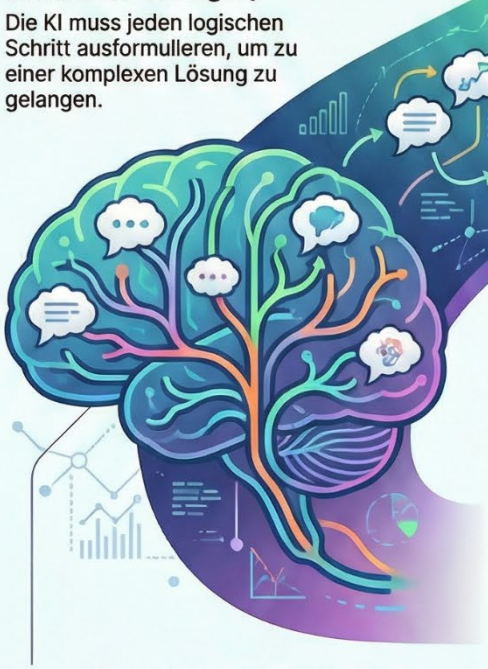

Stufe 4: Das "innere Gespräch" (Moderne KIs seit 2024)

Die KI kann intern Überlegungen anstellen und Ansätze verwerfen, ohne sie preiszugeben.

Analogie: Maschinelles vs. Menschliches Denken

Parallelen zu Kahnemans "Schnelles Denken, langsames Denken"

Moderne KIs können selbstständig zwischen einem schnellen und einem aufwändigen "Denkmodus" wählen.

Menschliches Denken		Entsprechung in der KI
System 1	Automatisch, schnell, intuitic, fehleranfällig	Schneller Modus
System 2	Langsam, analytisch, anstrengend, bewusst	Denkmodus